

Um:bruch

re:shape – Denkfabrik für gesellschaftlichen Wandel

STUDIE ST-001

Systemtheoretische Aufarbeitung der Regressangst

Eine multiperspektivische Bestandsaufnahme der deutschen
Wirtschaftlichkeitsprüfung – Begleitstudie zu PP-003

Um:bruch – Denkfabrik für gesellschaftlichen Wandel | April 2026 | Version 0.22 (Arbeitsversion,
+PDF-Kommentare Runde 6)

Schlagerworte: Regress, Wirtschaftlichkeitsprüfung, Defensivmedizin, Versorgungsforschung, Gesundheitsökonomie,
Systemanalyse

Zusammenfassung. Diese Studie nimmt das deutsche Wirtschaftlichkeitsprüfsystem nach §§ 106 ff. SGB V multiperspektivisch in den Blick: historisch (Container-Genealogie seit 1989), rechtsdogmatisch (Selbstverständnis der Prüfverfahren, Zertifikatsfehler), verhaltensökonomisch (Ribbat 2023, Goetz 2024), gesundheitsökonomisch (Folgekostenrechnung) und international vergleichend. **Zentrale Befunde:** (1) *Drei Zertifikatsfehler* (als analytische Konstruktion verstanden, nicht als Tatsachenbehauptung über Systemversagen: eine Diskrepanz zwischen dem, was das System zu messen vorgibt bzw. was öffentlich kommuniziert wird, und dem, was es faktisch als Messinhalt und Messrichtung erfasst) — die Auffälligkeitsprüfung (V1) misst Kostenabweichungen (enthält aber ein dreistufiges Schutzstufenmodell, das die Endquote von ca. 0,097 % erzeugt); die Einzelfallprüfung misst bei V2b (i) reinen Formfehlern medizinisch irrelevant, bei V2b (ii) inhaltlicher Unzulässigkeit codierte G-BA-Evidenz (schwächerer Zertifikatsfehler, aber punitiv kommuniziert); V2a (Unwirtschaftlichkeit) lässt medizinische Verteidigung und Kostendifferenzmethode zu. Der *übergeordnete Zertifikatsfehler* betrifft nicht den Messinhalt, sondern die Messrichtung: Das Gesamtsystem prüft ausschließlich “zu viel verordnet”, nie “zu wenig versorgt” — der Versorgungsauftrag des § 70 SGB V hat kein eigenes Messinstrument. (2) *Schaden-Verschiebung zum Patienten:* Die Richtungs-Asymmetrie verlagert den Schaden vom Arzt (Regressrisiko bei Handeln) zum Patienten (Unterversorgung bei ärztlicher Zurückhaltung). Überversorgung als Ausweichreaktion belastet Patientinnen und Patienten zudem doppelt: medizinisch (iatrogene Risiken, Overdiagnosis) und finanziell/zeitlich (Zuzahlungen, Fahrtwege, Arbeits- und Urlaubszeit, Begleitpersonen) — entlang der SVR-Trias Unter-/Über-/Fehlversorgung (SVR 2000/2001, § 135a SGB V). (3) *Definitionsdivergenz der Regressquote:* Die öffentlich kommunizierte “unter 1 %”-Quote misst rechtskräftig durchgesetzte V1+V2-Regresse; das tatsächliche V2-Verfahrensvolumen liegt um einen Faktor ~500 höher (47.000 Verfahren/Jahr bundesweit). Die von Ärzten berichtete 72 %-Erfahrungsrate (Ribbat 2023) ist damit rechnerisch plausibel. Die Studie ist die wissenschaftliche Begleituntersuchung zum Konzeptpapier *PP-003 – Regress-Transparenzportal*.

Inhaltsverzeichnis

1	Die Diagnose	7
1.1	Fragestellung	7
1.2	Methodisches Vorgehen	8
1.2.1	Forschungsdesign	8
1.2.2	Quellen und Suchstrategie	8
1.2.3	Multi-Modell-Architektur	9
1.2.4	Cross-Source-Divergenz (Multi-Agenten-Experiment)	9
1.2.5	Ein- und Ausschlusskriterien	9
1.2.6	Bias-Management	10
1.2.7	Methodische Grundsätze	10
2	Teil I — Historische Schichtung: Wie das System wurde, was es ist	10
2.1	Vom Solo-Container zur Containerlandschaft	10
2.2	Der Lahnsteiner Kompromiss 1992	11
2.3	GKV-VSG 2015: Die zentrale Wendepunkt-Reform	12
2.4	Drei methodisch auffällige Wanderungen	13
2.5	Strategische Auseinanderreißung: Belege ja, Vorsatz schwer nachweisbar	13
2.6	Strukturelle Inkonsistenzen im Normgefüge: Top-10	14
3	Teil II — Die rechtsdogmatische Lücke: Verdacht ohne Substanz	14
3.1	Selbstverständnis: Die Einzelfallprüfung ist eine Verdachtsfallprüfung	14
3.2	Die 99,7-%-Verwerfungsrate: Was sie zeigt — und was sie verdeckt	15
3.3	Begriffsklärung: Zwei Prüfdomänen und vier Messebenen	17
3.4	Termination without Determination: Die unsichtbare Ökonomie der Vergleiche	24
3.5	Die Asymmetrie zwischen Auffälligkeits- und Einzelfallprüfung	25
3.5.1	Ausschlussfristen: Wie weit zurück geprüft werden darf	26
3.6	Der Zertifikatsfehler: Was das System vorgibt zu messen — und was es tatsächlich misst	26
3.6.1	Zwei inkommensurable Messdomänen	26
3.6.2	Warum so wenige Verfahren vor Gericht landen	30
3.6.3	Der doppelte Zertifikatsfehler — und der größere dahinter	30
3.6.4	Formfehler als strukturelle Strategie	34
3.6.5	Der normative Schadensbegriff: Warum Formfehler ab Verfahrenseinleitung nicht mehr heilbar sind	34
3.6.6	Praxisbesonderheiten: Der Validitäts-Reparaturmechanismus und seine Grenzen	35
3.6.7	Das System kennt seinen Fehler: Vier informelle Ausgleichsmechanismen	35
3.7	Evidenz in formaler Verkleidung: Die Doppelfunktion des Prüfsystems	36
3.8	Die operative Synthese: Drei Scanner, keine Qualitätsprüfung	37
3.8.1	Das System als Formfehler-Erkennung	38
3.8.2	Hypothese: Digitalisierung als Treiber der Einzelfallprüfungszunahme	38
3.8.3	Informationsasymmetrie: Der Prüfkatalog als Einbahnstraße	39
3.8.4	Die offene Rechtsfrage: Verdacht oder Screening?	39
3.9	Der innere Konflikt: Drei Codes auf einer Operationseinheit	40
3.9.1	§ 12 SGB V als Doppelanforderung	40
3.9.2	Drei Funktionssystem-Codes auf einer ärztlichen Verordnung	40

3.9.3	Das KBV-Statement von 2016	41
3.9.4	Der BVerfG-Notausgang von 2005	41
3.10	Der theoretische Rahmen: Managerialismus und Audit Society	41
3.10.1	Freidson: Die "dritte Logik" und ihre Erosion	42
3.10.2	Power: Die "Audit Society" und ihre Rituale der Verifikation	42
3.10.3	Noordegraaf: Das Paradox des konnektiven Professionalismus	43
3.10.4	Foucault: Die Wirtschaftlichkeitsprüfung als Panoptikum	43
4	Teil III — Die Verhaltensökonomie: Was Ärzte tatsächlich tun	44
4.1	Ribbat 2023 — die derzeit umfangreichste deutsche Befragung	44
4.2	Ribbat-Operationalisierung: Von der Befragung zum Verhaltensmechanismus	46
4.3	Die internationale Bestätigung: 75,8 % Defensivmedizin global	47
4.4	Spieltheoretische Modellierung	48
4.4.1	Das Verordnungsspiel: Bayessches Spiel mit asymmetrischer Information	48
4.4.2	Defensive Unter-Verordnung als Nash-Gleichgewicht	50
4.4.3	Das Solidaritäts-Gefangenendilemma	50
4.4.4	Multi-Principal-Agent-Problem	50
4.4.5	Die spieltheoretisch wirksamste Intervention	51
4.4.6	Regelkreisanalyse: Nur Minus-Signale	51
4.4.7	Asymmetrische Sanktionsstruktur ohne Gegengratifikation	51
4.5	Der Modellarzt	52
4.5.1	Profil	53
4.5.2	Die dokumentierten Verhaltensanpassungen	53
4.5.3	Hochrechnung auf die Makro-Ebene	53
4.5.4	Methodische Einschränkungen und Sensitivitätsanalyse	54
4.6	Der Arzt als Street-Level Bureaucrat	54
4.6.1	Lipskys Grundmodell	54
4.6.2	Lipskys Coping-Typologie, angewandt auf den Modellarzt	55
4.6.3	Die politisch-analytische Konsequenz	55
5	Teil IV — Die Folgekosten: Wenn das System mehr schadet als es spart	56
5.1	Die direkten Patientenschäden	56
5.2	Die volkswirtschaftliche Hochrechnung	56
5.3	Die Verhältnisrechnung: Schaden zu Einnahme	56
5.4	Vergleich mit anderen großen Kostentreibern	57
5.5	Administrative Burden als "Policymaking by Other Means"	58
5.5.1	Herd & Moynihan: Bürokratie als Politikgestaltung	58
5.5.2	Die analytische Konsequenz: Die Bürokratie funktioniert wie vorgesehen	59
6	Teil V — Das institutionelle Schweigen	60
6.1	Der GKV-Spitzenverband 2024: Verteidigung ohne Belege	60
6.2	Wer könnte prüfen — und tut es nicht	60
6.3	Wer profitiert eigentlich? Eine Public-Choice-Analyse	61
6.3.1	Die Nutzen-Bilanz der Spieler	61
6.3.2	Niskanens Bürokratie-Modell und die GPE	62
6.3.3	Kosten extern nicht verifizierbar — und das ist selbst ein Befund	62
6.3.4	Der Drehtür-Effekt	63
6.3.5	Die wahren Profiteure	63
6.3.6	Die Forschungslücke	64

7	Verfassungsrechtliche Angriffsvektoren	64
7.1	Was nicht funktioniert: Der naheliegende Weg über Art. 12 GG	64
7.2	Die Backdoor: Art. 20 Abs. 3 GG, Bestimmtheitsgrundsatz und Wesentlichkeitstheorie	64
7.3	Die BSG-Selbstentlarvung	64
7.4	Die Eigentumsdogmatik des regressierten Medikaments	65
7.5	Die Doppelbeschwerde-Strategie	65
7.6	Einschätzung der Erfolgsaussichten	65
8	Teil VI — Internationaler Vergleich	66
8.1	Deutschland und die Schweiz als Sonderwege	66
8.2	Frankreich: Le “Délit Statistique”	66
8.2.1	Das Instrument: MSO und MSAP	66
8.2.2	Größenordnung: Was die offiziellen Zahlen zeigen	67
8.2.3	Die Begriffsprägung und der gewerkschaftliche Widerstand	67
8.2.4	Methodische und strategische Konsequenz	67
8.3	Was andere Länder anders machen	68
8.4	Diametrale Manifestation desselben Mechanismus	68
8.4.1	USA: Druck vom Patienten → Überbehandlung	68
8.4.2	Deutschland: Druck von der Krankenkasse → Fehlversorgung in zwei Richtungen	68
8.4.3	Methodische Konsequenz	69
9	Grenzen der Evidenz und Gegenposition	70
9.1	Einwand 1: Korrelation ist keine Kausalität (betrifft V1+V2)	70
9.2	Einwand 2: Der Zertifikatsfehler ist ein Strohmännchen (betrifft V1+V2)	71
9.3	Einwand 3: Das Präventions-Paradoxon — der Nutzen wird nie gerechnet (betrifft primär V1)	71
9.4	Einwand 4: “Deterministisch” ist eine Setzung, kein Befund (betrifft V2)	71
9.5	Einwand 5: Ein Drittel des Systems ist rationale Steuerung (betrifft V2)	72
9.6	Einwand 6: Positive Entwicklungen ausgeblendet (betrifft V1+V2)	72
10	Teil VII — Lösungsraum	73
10.1	Verweis auf PP-003: Das Regress-Transparenzportal	73
10.2	Das Transparenz-Paradoxon — und warum PP-003 es berücksichtigt	73
10.2.1	Bernsteins Befund	73
10.2.2	Die ernsthafte Kritik an PP-003	73
10.2.3	Warum PP-003 robuster ist, als es auf den ersten Blick wirkt	74
10.2.4	Was PP-003 allein nicht lösen kann	74
10.3	Die juristisch belegten Top-3-Schutzmaßnahmen	74
10.4	Open-Source-Verordnungstool: Konkrete MVP-Spezifikation	75
10.5	Politische Reform: Drei minimal-invasive Hebel	75
10.6	Sieben weitere Interventionspfade	76
10.7	Versorgungsprüfung: Messinstrument für §§ 70, 135a SGB V	77
10.7.1	Der Vorschlag: Symmetrische Prüfarchitektur	78
10.7.2	Grenzen und methodische Vorbehalte	78
10.7.3	Anschlussfähigkeit	78
10.7.4	Konzeptioneller Vorschlag: Governance-Pharmakovigilanz	79
10.8	Kosten-Nutzen-Vergleich aller Lösungsvorschläge	79

11 Was diese Studie zeigt — und was nicht	80
11.1 Der Bogenschluss: Die drei Zertifikatsfehler	81
11.2 Was belegt ist, was plausibel ist, was Hypothese bleibt	81
11.3 Genre-Klärung	82
11.4 Was wäre der nächste Schritt?	82
12 Quellen und Recherche-Dateien	82
Anhang: Glossar	88
Anhang B: Methodik (Walk of Analysis)	92
Anhang C: Offene Forschungsfragen und IFG-Anfragen	98
Änderungshistorie	100

1 Die Diagnose

Diese Studie nimmt das deutsche Wirtschaftlichkeitsprüfsystem nach §§ 106 ff. SGB V multiperspektivisch in den Blick. Sie ist eine Bestandsaufnahme: Was lässt sich über das System belastbar sagen, wenn man die verfügbaren empirischen, rechtsdogmatischen, historischen und vergleichenden Befunde nebeneinander legt?

Den Anlass liefert eine auffällige Diskrepanz: Die Regressdurchsetzungsquote wird öffentlich als seltenes Ereignis kommuniziert — unter 1 % der Ärzte (verschiedene KV-Statistiken, V1+V2 zusammen, nur rechtskräftig durchgesetzt; zur Differenzierung siehe Abschnitt 2.1). Dennoch berichten 72 % der Hausärzte, tatsächlich mindestens einmal einen Regress erlebt zu haben, und 47 % geben an, die Regressgefahr beschäftige ihren Praxisalltag “stark oder sehr stark” (Ribbat et al. 2023, n=770, TU München; V1+V2 zusammen, keine Verfahrenstrennung in der Studie). 46,7 % der ca. 13.900 vom KBV-Berufsmonitoring (KBV/Universität Trier 2018, dritte Erhebungswelle) befragten Medizinstudierenden nennen die Regressdrohung als Niederlassungshindernis — obwohl sie selbst noch nie niedergelassen waren. Sind Ärzte nur besonders ängstlich — oder hat ihre Angst einen realeren Hintergrund als die offizielle Statistik erkennen lässt? Ein Teil der Auflösung vorweg: Die “unter 1 %” messen nur *rechtskräftig durchgesetzte* Regresse am Ende einer langen Verfahrenskette, nicht das V2-Verfahrensvolumen. Kleine Risiken pro Verordnung summieren sich über Jahre. Poisson-Plausibilisierung (je nach Zählweise λ zwischen 0,30 aus der BMG-Bundesrechnung und 1,48 aus KV Nordrhein, siehe Abschnitt 4.4.1) ergibt, dass **eine deutliche Mehrheit der Ärzte (grob geschätzt 60–99 % über drei Jahre, je nach gezähltem Ereignistyp: Antrag, Vergleich oder rechtskräftige Zahlung) mindestens einem V2-Verfahren begegnet**. Kleines Risiko pro Fall, großes Risiko pro Arzt über die Berufslaufbahn — das macht die 72 % Ribbat rechnerisch plausibel.

1.1 Fragestellung

Die Frage, die diese Diskrepanz aufwirft, lautet zunächst nicht, was “richtig” ist, sondern: **Was passiert im System, das beides zugleich produziert?** Diese Analyse versucht, Antworten zu sammeln — aus historischen, rechtsdogmatischen, verhaltensökonomischen, gesundheitsökonomischen und international vergleichenden Quellen.

Diese Studie ist die wissenschaftliche Begleituntersuchung zum Konzeptpapier PP-003, das ein anonymes Regress-Transparenzportal zur empirischen Schließung einer Datenlücke vorschlägt. ST-001 dokumentiert, was sich derzeit über das System sagen lässt, und welche Datenlücken dabei sichtbar werden. PP-003 schlägt einen Weg vor, eine dieser Lücken zu schließen.

Leseorientierung: Drei Zertifikatsfehler und V1/V2-Legende

Abkürzungen: V1 = Auffälligkeitsprüfung (§ 106a/b SGB V, statistischer Kostenvergleich auf Praxisebene). V2 = Einzelfallprüfung (§ 106b SGB V, Antrag der Krankenkasse zu einzelnen Verordnungen). Innerhalb von V2: V2a = Unwirtschaftlichkeit im engeren Sinne; V2b (i) = reine Formfehler (Ausnahmekennzeichen fehlt, Betäubungsmittelrezept unvollständig, Stempel nicht gesetzt); V2b (ii) = inhaltliche Unzulässigkeit nach AM-RL (z. B. Off-Label, Ausschlusskriterium verletzt).

Drei Zertifikatsfehler (Begriff als analytische Konstruktion, siehe Teil II und Teil VII, Einwand 2):

- **V1-Zertifikatsfehler:** Gemessen wird *Kostenabweichung* pro Praxis, ausgegeben wird *Wirtschaftlichkeit*. Die 0,065–0,097 %-Endquote kommt durch dreistufige Schutzmechanismen zustande, nicht durch die Messtiefe.
- **V2b-Zertifikatsfehler:** Gemessen wird *Formfehler* bzw. *Regelkonformität* (V2b (i) form-, V2b (ii) kodiert-inhaltlich), ausgegeben wird *medizinische Fehlversorgung*. V2a bleibt der einzige V2-Typ mit medizinischer Verteidigungsmöglichkeit.
- **Übergeordneter Zertifikatsfehler (Messrichtung):** Gemessen wird ausschließlich „zu viel verordnet“, ausgegeben wird *Wirtschaftlichkeit im Sinne der SVR-Trias* (Überversorgung, Unterversorgung, Fehlversorgung — §§ 70, 135a SGB V). Weder „zu wenig versorgt“ noch Fehlversorgung haben ein eigenes Messinstrument.

Roadmap: Teil I historisiert die Containergenese, Teil II führt die drei Zertifikatsfehler ein, Teil III zeigt die verhaltensökonomischen Konsequenzen, Teil IV rechnet die Folgekosten, Teil V analysiert das institutionelle Schweigen, Teil VI vergleicht international (Frankreich, Schweiz), Teil VII bringt die Gegenposition (Einwände 1–6), Teil VIII eröffnet den Lösungsraum — darunter die *Versorgungsprüfung* als Messinstrument für die fehlende Gegenrichtung.

Diese Arbeitsversion ist bewusst zurückhaltend in den Schlussfolgerungen. Wo Wertungen vorgenommen werden, sind sie als solche kenntlich. Wo Befunde mehrere Lesarten zulassen, werden alle Lesarten dargestellt. Die Studie versucht nicht, eine vorgefasste These zu bestätigen, sondern sich von den verfügbaren Daten leiten zu lassen.

1.2 Methodisches Vorgehen

1.2.1 Forschungsdesign

Diese Studie entstand in einem mehrstufigen, KI-gestützten Analyseprozess im April 2026. Insgesamt wurden 31 eigenständige Recherchestränge durchgeführt, dokumentiert und in eine integrierte Argumentation überführt. Jeder Strang ist als eigenständige Recherchedatei im Arbeitsordner des Projekts dokumentiert und nachverfolgbar (Projektordner Content/Projekte/Regress-Melder/infomaterial/, Inventar in WALK_OF_ANALYSIS.md). Die vollständige Methodendokumentation aller Analyseschritte — einschließlich der rekonstruierten Prompt-Kerne, Modellzuordnungen und Hypothesenrevisionen — findet sich in Anhang B (Abschnitt 12).

1.2.2 Quellen und Suchstrategie

Die Quellenerhebung erfolgte systematisch für den Zeitraum 2018–2026 und selektiv für ältere Quellen. Durchsuchte Datenbanken und Quellensysteme:

- **Wissenschaftliche Literatur:** PubMed, Google Scholar (Suchbegriffe: Wirtschaftlichkeitsprüfung, Regressangst, Defensivmedizin, prescribing behavior regulation, defensive

medicine Germany)

- **Rechtsprechung:** BSG-Entscheidungsdatenbank (Senat B 6 KA), Landessozialgericht-Entscheidungen, dejure.org
- **Gesetzestexte und Materialien:** SGB V (laufende Fassung + historische Fassungen via BGBl), BMV-Ä, Prüfvereinbarungen ausgewählter KV-Regionen
- **Institutionelle Quellen:** KBV-Statistiken, GKV-Spitzenverband, WIdO-Arzneimittelreports, BRH-Sonderberichte, OECD Health at a Glance
- **Informationsfreiheitsanfragen:** 9 IFG-Anfragen an BMG, BAS, KBV und GPE über FragDenStaat (eingereicht 10.04.2026, Fristen laufend; dokumentiert in Anhang C)

1.2.3 Multi-Modell-Architektur

Die Analyse wurde durch vier Instanzen arbeitsteilig durchgeführt:

Instanz	Modell/Version	Rolle
Claude	Opus 4.6, 1M Kontext	Primäranalyse, Rechtsstruktur, Synthese, LaTeX-Dokumentation
Copilot	GPT-4o	Konzeptschärfung, Fehlkonzept-Erkennung, Kostenschätzungs-Review
Gemini	Deep Research	Theorierahmen (Freidson, Power, Lipsky), Quellenergänzung, Visualisierung
LG (Mensch)	—	Fragestellungen, Richtungsentscheidungen, Domänenwissen, finale Freigabe

Die Detailtabelle mit Stärken- und Schwächenprofilen jedes Modells findet sich in Anhang B.

1.2.4 Cross-Source-Divergenz (Multi-Agenten-Experiment)

In einer späteren Analysephase (Phase XIV) wurde die Multi-Modell-Architektur um eine **Multi-Agenten-Architektur** erweitert: 15 spezialisierte Agenten (6 Opus, 9 Sonnet) recherchierten parallel zu Regresshäufigkeit, Kassendaten und Evidenzsteuerung — mit 25 Datenpunkten aus 14 unabhängigen Domains. **Zentrale methodische Lektion:** Cross-Model-Divergenz (Claude vs. Copilot vs. Gemini) kontrolliert Modell-Bias, aber *nicht* Quellen-Bias. Alle Modelle schöpften aus denselben Quellen (Ärzteblatt, Virchowbund, KV Nordrhein). Erst die systematische Multi-Quellen-Recherche brachte die SpiFa-Bayern-Daten (13.000 Regresse/Jahr) und die BMG-Zahl (47.000 V2-Verfahren) ans Licht. Zusätzlich wurden ein *Naïve-Suche-Test* (simulierter Journalist ohne Vorwissen) und zwei *Prior-Art-Checks* (systematische Suche nach bestehender Synthese) als Pflichtschritte eingeführt (Details in Anhang B).

1.2.5 Ein- und Ausschlusskriterien

Eingeschlossen wurden: peer-reviewed Studien, BSG-Entscheidungen, offizielle Statistiken (KBV, WIdO, Destatis), verifizierte Gesetzesmaterialien und IFG-Dokumente. Journalistische Quellen wurden nur als Ergänzung herangezogen, nicht als Primärbeleg.

Ausgeschlossen wurden: nicht-verifizierbare Blog-Beiträge, unattribuierte Statistiken, Gemini-Outputs ohne Claude-Double-Check (dokumentierte Halluzinationsfälle: Moosazadeh-Fehlzuordnung, französische Protestzahlen; siehe Anhang B). Verbände-Stellungnahmen wurden als Positionspapiere gelesen, nicht als empirische Belege.

1.2.6 Bias-Management

Die methodische Kontrolle gegen Bestätigungsfehler erfolgte auf mehreren Ebenen:

- **Cross-Model-Divergenz:** Abweichungen zwischen Claude, Copilot und Gemini wurden systematisch als Signal genutzt. Copilot identifizierte eine Inkonsistenz in der Kostenschätzung, die zur Einführung des Dreistufenmodells führte.
- **Hypothesenreversionen:** Fünf dokumentierte Fälle, in denen Ausgangshypothesen anhand der Evidenz verworfen wurden (u. a. Datierung der Einzelfallprüfung: GSG 1992 → GRG 1988; Moosazadeh-Fehlzuordnung → Zheng 2023).
- **Devil's Advocate:** Ein eigener Review-Agent (Phase 10 des 13-Phasen-Review-Zyklus) versuchte systematisch, die zentrale These zu widerlegen. Die 5 identifizierten Verwundbarkeiten wurden in den Text eingearbeitet (siehe Abschnitt 9).
- **Unabhängiger Policy-Analyst:** Ein separater Agent ohne Kenntnis der Recherchegeschichte formulierte 7 Lösungsvorschläge, um Tunnelblick-Effekte zu umgehen.

1.2.7 Methodische Grundsätze

Die Studie macht folgende methodische Annahmen explizit:

- **Quellenpriorität:** Primärquellen (Gesetzestexte, BSG-Urteile, peer-reviewed Studien) vor Sekundärquellen (Stellungnahmen, Pressemitteilungen). Bei Halluzinationsrisiko: jede Quelle wurde gegen Originalpublikation geprüft.
- **Anonymisierung:** Alle individuellen Fälle sind anonymisiert. Keine namentliche Nennung. Keine identifizierenden Details.
- **Hochrechnungen mit offenen Annahmen:** Wo Schätzungen vorgenommen werden, sind die Annahmen explizit. Skepsis gegenüber Punktschätzungen, Bevorzugung von Bandbreiten.
- **Trennung von Befund und Bewertung:** Die normative Folgerung steht am Ende, nicht am Anfang. Wer den Befunden nicht folgt, soll an den Befunden argumentieren können.

Die Analyse gliedert sich in sieben Teile: historische Schichtung (I), rechtsdogmatische Analyse (II), Verhaltensökonomie (III), Folgekosten (IV), institutionelle Analyse (V), internationaler Vergleich (VI) und Lösungsraum (VIII). Zwischen dem internationalen Vergleich und dem Lösungsraum steht ein eigener Abschnitt zu den Grenzen der Evidenz und den stärksten Gegeneinwänden (VII).

2 Teil I — Historische Schichtung: Wie das System wurde, was es ist

2.1 Vom Solo-Container zur Containerlandschaft

Container meint in dieser Studie einen einzelnen Paragraphen oder eine zusammenhängende Norm, in der rechtliche Konzepte "aufbewahrt" werden. Der Begriff ist eine analytische Hilfe, um die Wanderung von Konzepten zwischen verschiedenen Normstandorten nachzuverfolgen.

1989 reichte ein einziger Paragraph des SGB V (§ 106) für die ambulante ärztliche Wirtschaftlichkeitsprüfung. Eingeführt durch das Gesundheits-Reformgesetz (GRG) unter Norbert Blüm (CDU), in Kraft am 01.01.1989. Dieser Solo-Container enthielt **beide** Prüfverfahren von Anfang an:

- Die **Einzelfallprüfung** (V2) stammt aus dem früheren § 368n RVO, in der BSG-Rechtsprechung seit 1959 (BSGE 11, 102) verankert. Sie ist nicht erst später eingeführt worden — sie war von Anfang an dabei.
- Die **Auffälligkeitsprüfung** (V1) in Form der Richtgrößenprüfung wurde mit dem Gesundheitsstrukturgesetz (GSG) 1992/93 unter Horst Seehofer (CSU) als bundeseinheitliches statistisches Verfahren eingeführt. Zuvor existierte eine weniger formalisierte Durchschnittswertprüfung, die nach Fachgruppe verglichen.

Was sich ändert, ist nicht das Grundprinzip (Kostenprüfung + Sanktion), sondern die Position der Verfahren innerhalb einer wachsenden Containerlandschaft.

Was der Solo-Container 1992 außerdem enthielt: Der originale § 106 SGB V (Fassung GRG 1989, geändert durch GSG 1992) war mehr als nur die beiden Prüfverfahren. Er regelte in einem einzigen Paragraphen: die Besetzung und Zuständigkeit der Prüfungsstelle, das Widerspruchsverfahren (Beschwerdeausschuss), die Beratungspflichten, die Sanktionsfolgen und die Kostentragung. Diese funktionalen Elemente sind 2017 auf sechs Paragraphen (§§ 106–106d) und die regionalen Prüfvereinbarungen verteilt worden — bei gleichbleibendem Regelungsgehalt. Die Aufspaltung erhöhte die Regelfläche, nicht die Regelsubstanz.

2026 sind aus dem einen Container fünf ambulante (§§ 106, 106a, 106b, 106c, 106d), zwei stationäre (§§ 275, 275c) plus § 48 BMV-Ä, plus bundesweite Rahmenvorgaben von KBV und GKV-Spitzenverband, plus bis zu 17 regionale Prüfvereinbarungen geworden. Die geschriebene Regelfläche hat sich in 35 Jahren etwa verachtfacht. Der Regelungsgehalt ist im Kern derselbe geblieben — Konzepte wurden aufgespalten, dupliziert, regional variiert und zwischen Normstandorten verschoben, aber der Grundmechanismus (statistische Auffälligkeit oder Kassenantrag → Prüfung → Sanktion) blieb unverändert.




Abbildung 1: Container-Genealogie 1989–2026: Aus einem Paragraphen (§ 106) wurden acht Container. Die große Reform 2015/2017 (GKV-VSG) ist der Wendepunkt. Quelle: eigene Darstellung.

2.2 Der Lahnsteiner Kompromiss 1992

Im Sommer 1992 wechselte das Bundesgesundheitsministerium von Gerda Hasselfeldt (CSU) zu Horst Seehofer (CSU). Mit dem Gesundheitsstrukturgesetz (GSG) von 1992/93 (BT-Drs. 12/3608) wurde § 106 SGB V umfassend reformiert. Der Entwurf war das Ergebnis des so-

nannten *Lahnsteiner Kompromisses* zwischen Seehofer und dem SPD-Sozialpolitiker Rudolf Dreßler. Befürworter waren die Bundesregierung (CDU/CSU/FDP), die SPD-Opposition und alle Krankenkassen-Spitzenverbände (AOK-BV, BKK, VdAK, IKK). Kritiker (BÄK, KBV, Hartmannbund) richteten ihre Kritik primär gegen die Budgetierung und die Arzneimittelbudgets, nicht gegen die Einzelfallprüfung selbst. Die Einzelfallprüfung war damals strukturell unangefochten.

In dieser Reform wurde die Einzelfallprüfung in § 106 Abs. 2 Nr. 2 SGB V als bundeseinheitliche Ergänzungsmethode auf begründeten Antrag einer Krankenkasse oder einer Kassenärztlichen Vereinigung verankert. Sie war zu diesem Zeitpunkt eine Norm unter mehreren in einem einzigen Container.

2.3 GKV-VSG 2015: Die zentrale Wendepunkt-Reform

Der entscheidende Bruch erfolgte 2015 mit dem GKV-Versorgungsstärkungsgesetz (GKV-VSG) unter Hermann Gröhe (CDU). Die zentralen Operationen:

- **Abschaffung der bundesweit einheitlichen Richtgrößenprüfung** (in Kraft 01.01.2017). Die Richtgrößenprüfung setzte vorab definierte Euro-Beträge pro Patient und Quartal fest; Ärzte, die diese überschritten, wurden automatisch geprüft. Begründung der Abschaffung im Gesetzgebungsverfahren: mangelnde Treffsicherheit, Regionalisierung, Niederlassungsattraktivität.
- **Regionalisierung** der ambulanten Wirtschaftlichkeitsprüfung durch neue §§ 106a–c. Die Auffälligkeitsprüfung verbleibt in § 106 SGB V; § 106b regelt die Einzelfallprüfung und verankert in Abs. 2 den Beratungsschutz für V1. Die Einzelfallprüfung wird auf die regionale Ebene der Prüfvereinbarungen ausgelagert.
- **Schutz “Beratung statt Regress”** für die Auffälligkeitsprüfung im Gesetz verankert (§ 106b Abs. 2 SGB V): Bei erstmaliger verbleibender Auffälligkeit wird *Beratung festgesetzt statt eines Regresses*; die Beratung ist damit die Entscheidung im Erstzyklus. Für die Einzelfallprüfung ist dieser Schutz **explizit ausgeschlossen** (§ 106b Abs. 2 S. 4 SGB V).

Die KBV-Stellungnahme zum GKV-VSG 2015 (S. 32-33) warnt explizit, dass die Verlagerung der Einzelfallprüfung in regionale Vereinbarungen “die Gefahr einer Verschärfung der Wirtschaftlichkeitsprüfung birgt”. Das Muster, das die KBV identifizierte: Durch die Regionalisierung bekommen die Krankenkassen mehr Einfluss auf die Ausgestaltung der Prüfvereinbarungen, während die bundesgesetzliche Aufsicht sinkt. Was auf Bundesebene als Entbürokratisierung (Abschaffung der Richtgrößen) präsentiert wurde, wurde auf regionaler Ebene durch eine Ausweitung der Einzelfallprüfung kompensiert.

Das Muster, das die KBV konkret erkannte: (1) Die Regionalisierung entzog die Ausgestaltung der Prüfverfahren dem Bundesgesetzgeber und übergab sie den regionalen Vertragspartnern (KV + Kassen). (2) In regionalen Verhandlungen sind die Krankenkassen strukturell im Vorteil, weil sie als Zahlungspflichtige ein direktes finanzielles Interesse an scharfen Prüfverfahren haben. (3) Was auf Bundesebene als Entbürokratisierung kommuniziert wurde (Abschaffung der Richtgrößen), konnte auf regionaler Ebene durch erweiterte Einzelfallprüfungen kompensiert werden — ohne parlamentarische Kontrolle.

Die Kassenärzteschaft hat dieses Muster erkannt — und politisch verloren. Der prognostizierte Effekt trat ein: In Westfalen-Lippe stiegen die Einzelfallprüfungen im ersten Jahr nach Inkrafttreten um 28 %, in Nordrhein erreichten sie etwa 20.000 Anträge pro Jahr. Verschiedene Erklärungen für diesen Anstieg stehen nebeneinander: Die Kassen argumentieren, dass die regionalen Prüfvereinbarungen gezielter arbeiten als die alten Richtgrößen. Die KVen vermuten, dass die Kassen die Einzelfallprüfung als Ersatz für die abgeschaffte Richtgrößenprüfung nut-

zen. Ob die Zunahme durch verbesserte Antragstechnik (Digitalisierung der Prüfprozesse) oder durch gezieltes Ausnutzen des Beratungsschutz-Ausschlusses getrieben wird, ist empirisch nicht geklärt.

Zum Beratungsschutz (zweistufige Entstehungsgeschichte): Der Beratungsschutz “Beratung statt Regress” wurde nicht in einem Gesetz eingeführt, sondern in zwei Schritten verankert. (i) *GKV-VStG 2012* (§ 106 Abs. 5e a. F.): Beschränkte Beratungsregel für **Richtgrößenprüfungen** — ein erster, enger Schutz innerhalb der alten Auffälligkeitsarchitektur. (ii) *GKV-VSG 2015* (§ 106b Abs. 2 n. F. SGB V): Bundesgesetzlich verbindliche Verallgemeinerung auf die Auffälligkeitsprüfung (V1) insgesamt, nachdem die Richtgrößen parallel abgeschafft wurden. Für die Einzelfallprüfung (V2) wurde der Beratungsschutz mit dem GKV-VSG 2015 **explizit ausgeschlossen** (§ 106b Abs. 2 S. 4). Das heißt: Der Gesetzgeber hat V1 schrittweise geschützt und V2 bewusst ohne den bei V1 gesetzlich vorgesehenen Beratungs-Erstzyklus belassen — das ist kein Übersehen, sondern Design.

2.4 Drei methodisch auffällige Wanderungen

Die Container-Genealogie produziert drei Wanderungen, die methodisch besonders aufschlussreich sind:

- **Die § 106a-Umbenennungsfälle (2017):** Vor 2017 stand in § 106a SGB V die Abrechnungsprüfung. Ab 2017 steht in § 106a die Wirtschaftlichkeitsprüfung ärztlicher Leistungen. Die Abrechnungsprüfung wanderte gleichzeitig in den neuen § 106d. Wer alte Literatur liest, wird systematisch in die Irre geführt. Wer “§ 106a” zitiert, muss seit 2017 dazu sagen, welche Fassung gemeint ist.
- **Die Auslagerungs-Kaskade der Einzelfallprüfung:** BSG-Richterrecht (1959) → Gesetzestext § 106 Abs. 2 Nr. 2 (1993) → bloße Erwähnung in § 106 Abs. 1 S. 2 plus regionale Prüfvereinbarung (2017). Die Substanz ist drei Ebenen abgewandert. Die Sichtbarkeit hat abgenommen, der Anwendungsbereich nicht.
- **Die parallel-gegenläufige Operation Ambulant/Stationär:** 2015 wurde die ambulante Einzelfallprüfung aus dem Gesetz fast herausgeschrieben, 2020 wurde die stationäre Einzelfallprüfung in einen eigenen § 275c verselbständigt. Gegenläufige Logik im selben Gesetzbuch innerhalb von fünf Jahren.

2.5 Strategische Auseinanderreißung: Belege ja, Vorsatz schwer nachweisbar

Die Container-Architektur weist eine strukturell intransparente Regelungsarchitektur auf, deren Entstehungsmuster sich aus dem Gesetzgebungsprozess ergibt:

- **§ 48 BMV-Ä (Sonstiger Schaden)** ist seit Jahrzehnten außerhalb des SGB V kodifiziert — nicht im Gesetz, sondern im Bundesmantelvertrag. Wer “nur” das Gesetz studiert, übersieht das wichtigste verordnungsbezogene Haftungsinstrument. Der Bundesmantelvertrag gilt in der öffentlichen Wahrnehmung nicht als Gesetz.
- **§ 106b Abs. 2 S. 4 SGB V** schließt die Einzelfallprüfung explizit aus dem Schutz “Beratung statt Regress” aus. Eine bewusste asymmetrische Konstruktion: Wer von der Kasse beantragt wird, hat keinen Anspruch auf die bei V1 vorgesehene Beratungsentscheidung (§ 106b Abs. 2 S. 2 SGB V), die dort den Regress im Erstzyklus rechtlich ersetzt.
- Seit 2015 entstehen statt großer Bereinigungen nur noch **Mikro-Patches** (§ 106b Abs. 1a, 1b, 1c — Grippeimpfstoff, Rückruf, Versorgungslücken). Schutzklauseln werden ins SGB V gehoben (Sichtbarmachung), Kontrollwerkzeuge in untergesetzliche Ebenen ausgelagert (Unsichtbarmachung). Niemand korrigiert die Schichtung.

Beobachtung: Die Container-Landschaft bewegt sich seit 2015 nicht in Richtung Vereinfachung, sondern in Richtung weiterer Differenzierung. Welche Folgen das für die praktische Anwendbarkeit hat, lässt sich aus der reinen Containeranalyse nicht ableiten — dafür sind die Befunde aus Teil III (Verhaltensökonomie) und Teil V (institutionelles Schweigen) heranzuziehen.

2.6 Strukturelle Inkonsistenzen im Normgefüge: Top-10

Eine eigene Detailanalyse hat zehn handwerklich identifizierbare Schwachstellen in der heutigen Containerlandschaft dokumentiert. Sieben davon wären mit minimalem gesetzgeberischen Aufwand zu beheben. Sie werden nicht behoben.

#	Inkonsistenz	Fixbar?
1	§ 106a-Umnummerierung 2017 (alte Norm = Abrechnung, neue Norm = Wirtschaftlichkeit) — Pre-2017-Literatur führt in die Irre	Nein, nur über Lesefassungen
2	§ 48 BMV-Ä unsichtbar — der wichtigste existenzvernichtende Regressgrund (BSG B 6 KA 9/24 R, 490.000 EUR) lebt in einem Kollektivvertrag, nicht im SGB V	Ja, Verlinkung oder Aufnahme als § 106e SGB V
3	Beratungs-Asymmetrie § 106b Abs. 2 S. 4 — “Beratung vor Regress” gilt explizit nicht für Einzelfallprüfungen	Ja, einzelziger Halbsatz-Streich
4	Bagatelldgrenzen regional 30–150 EUR — verfassungsrechtlich problematische Ungleichbehandlung	Ja, Mindestgrenze in § 106b SGB V
5	Kein Bauplan für die Einzelfallprüfung — Verweis auf 17 regionale Prüfvereinbarungen	Nein, war 2017 politischer Wille
6	Keine Aufsicht über Prüfungsstellen — keine systematische Vollzugsstatistik	Ja, Veröffentlichungspflicht in § 106c
7	“Unwirtschaftlich” vs. “unzulässig” — keine Legaldefinition; Vollregress vs. Differenzkostenregelung als BSG-Richterrecht	Ja, Liste in § 106b
8	“Wirtschaftlichkeit” in § 12 SGB V undefiniert — Tautologie statt Tatbestand	Schwer, politisch umstritten
9	Sprechstundenbedarf ohne SGB-V-Container — etwa 10.000 Anträge/Jahr allein in KV Nordrhein, Rechtsgrundlage nur untergesetzlich	Ja, neuer Absatz in § 106b
10	BMV-Ä nicht auf gesetz-im-internet.de — strukturelle Sichtbarkeitslücke am amtlichen Rechtsportal	Ja, Verlinkung durch BMJ

Beobachtung: Sieben der zehn Inkonsistenzen sind trivial fixbar — einzelilige Gesetzesänderung, Verlinkung, Halbsatz-Streich. Sie werden seit Jahren nicht behoben. Diese Tatsache ist selbst ein Datenpunkt: *Es scheint keinen Akteur zu geben, der sowohl die Motivation als auch die Befugnis zur Korrektur besitzt — was die Persistenz dieser Schwachstellen erklären würde.*

3 Teil II — Die rechtsdogmatische Lücke: Verdacht ohne Substanz

3.1 Selbstverständnis: Die Einzelfallprüfung ist eine Verdachtsfallprüfung

Die Einzelfallprüfung versteht sich rechtsdogmatisch eindeutig als Verdachtsfallprüfung, nicht als Screening oder Stichprobenverfahren. Drei Belege:

- **§ 106b Abs. 1 SGB V** und die Rahmenvorgaben (KBV / GKV-Spitzenverband, Stand 01.05.2020) verlangen einen “schriftlichen und begründeten Antrag” mit “ausreichendem Verdacht auf Unwirtschaftlichkeit”. Die Krankenkasse muss die konkrete Verordnung, den Schaden und die Vergleichsleistung substantiiert benennen.
- **Die BSG-Rechtsprechung**, insbesondere B 6 KA 21/19 R vom 11.09.2019, sieht die Einzelfallprüfung als gerichteten Kontrollakt über eine konkret bezeichnete Verordnung. Die Prüfungsgremien haben laut BSG keinen Beurteilungsspielraum — eine Verordnung ist entweder zulässig oder unzulässig, ohne Mittelzustand.
- **§ 106b Abs. 2 S. 4 SGB V** schließt “Beratung vor Regress” für Einzelfallprüfungen ausdrücklich aus. Begründung des Gesetzgebers: Der Anlass sei bereits substantiiert; eine pädagogische Beratung sei deshalb entbehrlich.

Das heißt: Jeder Antrag der Krankenkasse muss — per Gesetz — ein substantiierter Verdachtsfall sein. Es darf keine Suchanfrage sein, keine Stichprobe, keine Routineprüfung. Die Beweislast für den Anfangsverdacht liegt bei der Kasse.

Screening versus Verdachtsprüfung — die normative Grenze

Für die folgende Argumentation ist eine begriffliche Präzisierung wichtig. Der Unterschied zwischen einem Screening und einer Verdachtsprüfung ist nicht graduell, sondern normativ:

Kriterium	Screening	Verdachtsprüfung
Zweck	systematisches Aufspüren möglicher Probleme	gerichtete Prüfung eines konkret bezeichneten Falles
Beweislast	nicht erforderlich, breite Filterwirkung erwünscht	substantiiertes Anfangsverdacht zwingend (§ 106b Abs. 1 SGB V)
Zulässige Verwerfungsquote	sehr hoch (das ist der Sinn)	nahe Null bei korrekter Vorprüfung
Sanktion bei Treffer	Empfehlung, Beratung, Korrektur	förmliches Verfahren mit Rechtsfolge
Beispiel	PKW-Verkehrskontrolle	strafrechtlicher Anfangsverdacht

3.2 Die 99,7-%-Verwerfungsrate: Was sie zeigt — und was sie verdeckt

Die KV Hessen wies für die **Auffälligkeitsprüfung (V1)** Arzneimittel 2015 folgende Pipeline aus: 916 Auffälligkeiten → 29 eröffnete Verfahren → 3 durchgesetzte Regresse. Endquote 0,3 %, verifiziert direkt im Deutschen Ärzteblatt (Artikel 113630). Vergleichbare Quoten in Thüringen, Nordrhein und Baden-Württemberg.

Was die V1-Verwerfungsrate zeigt: Für ein statistisches Screening ist eine hohe Verwerfungsrate *erwartbar*. Die Auffälligkeitsprüfung ist ein Suchverfahren: Sie markiert statistische Abweichungen vom Fachgruppendurchschnitt, nicht individuelle Verdächtige. Dass 99,7 % der markierten Fälle nach näherer Prüfung keinen Regress ergeben, ist die normale Funktionsweise eines Filters mit niedriger Spezifität. Aus dieser Perspektive funktioniert V1 wie vorgesehen.

Allerdings ändert das nichts daran, dass alle 916 markierten Ärzte die *Kosten* des Screenings tragen — Angst, Dokumentationsaufwand, Verhaltensänderung —, auch wenn für 913 von ihnen kein Regress folgt. Das Instrument muss nicht versagen, um zu schaden.

Was die V1-Verwerfungsrate verdeckt: Für die **Einzelfallprüfung (V2)** existiert *keine vergleichbare Pipeline-Statistik*. V2-Daten existieren (BMG: ca. 47.000 Verfahren bundesweit 2022; SpiFa Bayern: 13.000 Regresse/Jahr), werden aber nicht als integrierte Durchsetzungsstatistik

mit Verwerfungs- und Vergleichsquoten publiziert. Bekannt sind nur Volumina: Allein in der KV Nordrhein stellen Krankenkassen jährlich ca. 20.000 Einzelfallprüfungsanträge — bei gleichzeitig nur ~2 V1-Regressen pro Jahr.

Die naheliegende Verwunderung — und warum sie in die Irre führt. Auf den ersten Blick scheint die niedrige Gesamtregressquote ($< 1\%$) zu bedeuten, dass auch bei V2 wenig passiert. Das ist ein Fehlschluss. Beide Verfahren verhalten sich *genau so, wie man es von ihrem jeweiligen Design erwarten würde*:

- **V1 (Schwellenwert-Screening nach Auffälligkeiten):** Breites Screening, hoher Dropout → die meisten markierten Ärzte werden entlastet. Erwartbar.
- **V2 (gezieltes Verdachtsverfahren):** Die Kasse identifiziert einen konkreten Formfehler und stellt einen Antrag. Bei einem tatsächlich vorliegenden Formfehler steht das Ergebnis im Wesentlichen fest (normativer Schadensbegriff, BSG B 6 KA 5/09 R): Der Arzt *wird* zahlen. Die Frage ist nur noch *wie viel*.

Warum die Durchsetzung nicht im Gericht sichtbar wird: Beide Seiten haben rationale Gründe, das Gerichtsverfahren zu vermeiden:

- **Der Arzt:** Weiß, dass Gerichte bei festgestelltem Formfehler im Sinne der Kasse entscheiden (normativer Schadensbegriff). Ein Gerichtsverfahren kostet Zeit, Geld und psychische Belastung — ohne realistische Erfolgsaussicht.
- **Die Kasse:** Hat kein Interesse an vielen Gerichtsverfahren, weil diese die Aufmerksamkeit auf die Verfahrenspraxis lenken und unangenehme Fragen aufwerfen könnten (Häufigkeit der Anträge, Verhältnismäßigkeit, Selektionskriterien). Außerdem kann die Kasse V2-Anträge taktisch einsetzen: bei Kleinigkeiten ansetzen und bei Widerstand zurückziehen — ein Disziplinierungsinstrument, das außerhalb des Gerichts wirksamer ist als innerhalb.

Das Ergebnis: Geschätzt 70–80 % der betroffenen Ärzte lassen sich auf einen **Vergleich** ein (typisch 30–50 % des Regressbetrags). Der Vergleich *ist* die Durchsetzung — nur außerhalb des Gerichts. Die V2-Regressdurchsetzungsquote (gemessen am Geldfluss, nicht an Gerichtsurteilen) dürfte daher *erheblich höher* liegen als die V1-Quote. Aber sie wird nirgends publiziert.

Die eigentlichen V2-Probleme liegen nicht in der Durchsetzungsrate (die ist strukturell hoch), sondern in vier Merkmalen des Verfahrensdesigns:

1. **Keine Sanktion bei übersensitiver Antragstellung:** Die Kasse kann beliebig viele V2-Anträge stellen, ohne Konsequenzen für Fehlanträge. Das SG Mainz 2022 (S 3 KA 14/19, 260.000 EUR) ist der einzige dokumentierte Fall, in dem eine Kasse für Rechtsmissbrauch verurteilt wurde.
2. **Keine unabhängige richterliche Prüfung:** Da die Mehrheit der Fälle im Vergleich endet, wird keine richterliche Feststellung zum Einzelfall getroffen. Die Qualität der Kassenanträge wird nie systematisch geprüft.
3. **Kein Beratungsschutz:** § 106b Abs. 2 S. 4 schließt die Rechtsfolge "Beratung statt Regress" bei V2 gesetzlich aus (V1 hätte sie im Erstzyklus). Der Arzt wird direkt sanktioniert.
4. **Disziplinierungswirkung ohne Aktenzeichen:** Schon die Androhung eines V2-Antrags kann Ordnungsverhalten ändern, ohne dass je ein Verfahren stattfindet. Dieser Chilling Effect ist per Definition nicht messbar — er hinterlässt keine Spur im System.

Genau diese Intransparenz adressieren die eingereichten IFG-Anfragen (Anhang C) und das Konzept eines Regress-Transparenzportals (PP-003): Nicht die V1-Verwerfungsrate ist das Problem, sondern die fehlende Messung der V2-Durchsetzungsrealität.

Die praktische Konsequenz in einem Satz: Bei V2b (unzulässige Verordnung) gilt: Wird ein Formfehler festgestellt, muss der Arzt zahlen — unabhängig davon, ob die Behandlung medizinisch korrekt war (normativer Schadensbegriff, BSG B 6 KA 5/09 R; Details in Abschnitt 3.6.5). Das System “zertifiziert” nicht medizinische Qualität, sondern formale Regelkonformität — und sanktioniert deren Fehlen.

3.3 Begriffsklärung: Zwei Prüfdomänen und vier Messebenen

Drei Schichten des Regressbegriffs

Der Begriff “Regress” wird von verschiedenen Akteuren unterschiedlich definiert. Diese Definitionsdivergenz erklärt, warum die öffentlich kommunizierte Quote von “unter 1 %” und die von Ärzten berichtete Erfahrungsrate von 72 % (Ribbat 2023) **beide korrekt** sind — sie messen verschiedene Dinge.

Schicht	Was gezählt wird	Ungefähre Zahl	Quelle
1 (eng)	Nur V1-Regresse, nur rechtskräftig durchgesetzt	<100/Jahr → 0,065 %	Virchowbund 2018
2 (amtlich)	V1 + V2, rechtskräftig durchgesetzt	21 von 21.500 → 0,097 %	KV BaWü 2022
3 (faktisch)	Alle V2-Verfahren mit Zahlung (inkl. Vergleiche, Bagatelle)	ca. 47.000/Jahr → ~30 %	BMG GVSG 2024

Der Faktor zwischen Schicht 1 und Schicht 3 beträgt ca. 470–500×. Wer “Regress” als rechtskräftigen Richtgrößenregress nach Gerichtsurteil definiert (Schicht 1), kommt auf unter 0,1 %. Wer jede V2-Rückforderung ab 30 EUR mitzählt (Schicht 3), kommt auf 13.000 Fälle pro Jahr allein in Bayern (SpiFa 2024). Die Diskrepanz ist kein Wahrnehmungsfehler der Ärzte, sondern ein Messproblem der Statistik. Dieser Befund wird in der Summierungsrechnung (Teil III) und der Kommunikationsasymmetrie-Analyse empirisch untermauert.

Zwei Prüfdomänen — funktional getrennt, nicht graduelle Abstufungen

Das Wirtschaftlichkeitsprüfsystem besteht aus zwei Verfahren, die nicht als unterschiedlich intensive Versionen derselben Logik verstanden werden dürfen. Sie sind funktional inkommensurabel:

Tabelle: Strukturvergleich Auffälligkeitsprüfung (V1) vs. Einzelfallprüfung (V2)

Kategorie	Auffälligkeitsprüfung (V1)		Einzelfallprüfung (V2)
Verfahrensstruktur			
Bezeichnung	Statistische Auffälligkeitsprüfung		Einzelfallprüfung
Auslösetrigger	Kosten-/Mengenabweichung vom Fachgruppendurchschnitt		Konkreter Antrag einer Krankenkasse
Rechtsgrundlage	§ 106 SGB V		§ 106b Abs. 1 SGB V
Auslösende Institution	Prüfungsstelle (KV + Kassen)		Krankenkasse
Charakter	Such- und Filterverfahren		Gezieltes Verdachtsverfahren
Verdachtsqualität	Kein individueller Verdacht (statistisches Signal)		Individueller, substantiierter Verdacht erforderlich
Schutz- und Präventionsstruktur			
Beratung vor Regress	Vorgeschrieben (§ 106b Abs. 2)		Gesetzlich ausgeschlossen (§ 106b Abs. 2 S. 4)
Präventive Maßnahmen	Gegen-	Praxisbesonderheiten, Dokumentation, Anpassung	Doku- KV-Beratung, KK-Vorabanfrage (BSG B 6 KA 27/12 R), antragsfeste Doku
Maßnahmen bei Eintritt	Stellungnahme, ggf. Anpassung		Beratung, Rechtfertigung, Widerspruch, Klage
Risikoprofil			
Häufigkeit (je Patient)	Sehr gering		Sehr gering
Häufigkeit (Hausarzt, ca. 1.200 Pat.)	Gelegentlich		Regelmäßig möglich
Betroffenheit bei Eintritt	Teilweise		100 %
Wahrscheinlichkeit neg. Verfahrensausgang	Niedrig		Hoch
Wahrscheinlichkeit pos. Ausgang	Hoch		Mittel bis niedrig
Folge bei neg. Ausgang	Regressfestsetzung		Regressfestsetzung
Schadenhöhe	Niedrig bis moderat		Moderat bis hoch
Existenzbedrohend	Sehr gering		Niedrig, aber real

Die **Auffälligkeitsprüfung** (V1, statistisches Screeningverfahren) ist ein von der Prüfungsstelle initiiertes Verfahren zur Identifikation wirtschaftlicher Abweichungen im Vergleich zur jeweiligen Fachgruppe. Sie erfolgt ohne individuellen Verdacht. Charakteristisch ist eine bewusst niedrige Trefferquote: Die hohe Sensitivität des Filters ist systemimmanent und gewollt, da das Ergebnis lediglich ein vorläufiges Abweichungssignal darstellt. Die Auffälligkeitsprüfung trifft weder eine Aussage zur medizinischen Angemessenheit noch zur individuellen Verantwortlichkeit.

Die **Einzelfallprüfung** (V2, antragsgebundene Verdachtsprüfung) ist eine fallbezogene Prüfung, die gemäß § 106b Abs. 1 SGB V ausschließlich auf schriftlichen und begründeten Antrag einer Krankenkasse eingeleitet wird. Sie ist von Gesetzes wegen bereits als Ankläger, Richter und Begünstigter in einer Struktur angelegt (§ 106b Abs. 2 S. 4: kein Beratungsschutz; Kasse = Antragstellerin + Empfängerin des Regressbetrags). Wird ein Formfehler bestätigt, folgt unmittelbar eine sanktionsrechtliche Entscheidung — der Bescheid ist praktisch das Urteil (siehe normativer Schadensbegriff, Abschnitt 3.6.5).

Die empirische Konsequenz: Die KV Hessen (916 Auffälligkeiten → 3 Regresse, 0,3 %) demonstriert normales Screening-Verhalten der Auffälligkeitsprüfung (V1) — viel filtern, wenig finden ist für einen breiten Filter korrekt und methodisch unauffällig. Für die Einzelfallprüfung (V2) existieren keine vergleichbaren Veröffentlichungen. Die 99,7 %-Dropout-Rate bezieht sich ausschließlich auf V1.

Warum zwei Verfahren, die Ähnliches zu messen scheinen? V1 und V2 teilen dasselbe Ergebnis (Regressfestsetzung), prüfen aber grundlegend Verschiedenes: V1 fragt “Liegt der Arzt statistisch außerhalb der Norm?” (Fachgruppenschnitt), V2 fragt “Ist *diese konkrete Verordnung* formal angreifbar?” (Einzelfall). Historisch erklärt sich die Koexistenz aus der Container-Genealogie (Teil I): Die Einzelfallprüfung existiert seit 1959 (BSG-Richterrecht), die statistischen Prüfverfahren kamen später als ergänzendes Breitband-Instrument hinzu. Die Abschaffung der Richtgrößen 2017 hat V1 geschwächt, V2 aber unberührt gelassen — beide Verfahren bestehen nebeneinander, weil kein Reformgesetz sie integriert hat.

Vier Messebenen — nicht ein “Regressquote”-Begriff

Der Begriff “Regressquote” wird in der öffentlichen Diskussion und in Teilen dieser Studie für mehrere grundlegend verschiedene Messgrößen verwendet, die nicht miteinander vergleichbar sind:

Begriff	Definition	Was gemessen wird	V1/V2
Prüfquote	Anteil der Ärzt:innen oder Fälle, die in ein formelles Prüfverfahren gezogen werden	Verfahrensbeteiligung	V1: publiziert (regional); V2: k.D.
Regressverfahrenquote	Anteil der geprüften Fälle, bei denen eine Regressforderung gestellt wird	Antragsintensität	V1: ~3 % (KV Hessen); V2: k.D.
Regressdurchsetzungsquote	Anteil der Regressverfahren, bei denen ein Regress rechtskräftig festgesetzt wird	Verfahrenserfolg	V1+V2 zusammen: <1 %; getrennt: k.D.
Regressvolumen	Tatsächlich gezahlte Regressbeträge in Euro	Geldfluss	V1+V2 zusammen; getrennt: k.D.

Die in dieser Studie zitierten Zahlen messen verschiedene Ebenen:

- “Unter 1 % der Ärzte” (verschiedene KV-Statistiken): **Regressdurchsetzungsquote auf Ärztebene, über beide Verfahren (V1+V2) hinweg, ohne Verfahrenstrennung**
- “99,7 % Dropout” (KV Hessen 2015, Auffälligkeitsprüfung): **Pipeline-Verwerfungsrate auf Verfahrensebene**

Diese zwei Zahlen sind kein Widerspruch, sondern komplementäre Messungen verschiedener Ebenen derselben Realität. Bundesweit fehlen alle vier Ebenen als einheitlich veröffentlichte Zahlen — genau das ist die Datenbasis, die PP-003 schließen will.

Zur Regressdurchsetzungsquote bei V2: Für die Einzelfallprüfung existieren keine publizierten Durchsetzungsquoten. Aus der Verfahrensstruktur lässt sich jedoch ableiten, dass sie wesentlich höher liegen muss als bei V1: Fehlt “Beratung vor Regress” (§ 106b Abs. 2 S. 4), gibt es keinen institutionalisierten Abbruchpunkt zwischen Antrag und Bescheid. Der normative Schadensbegriff (Abschnitt 3.6.5) macht den Regress bei festgestelltem Formfehler praktisch

unvermeidlich. Die meisten Verfahren enden nicht durch Freispruch, sondern durch Vergleich — was in der Statistik als “kein Regress” erscheinen kann, obwohl der Arzt 30–50 % des Betrags gezahlt hat.

Eskalationspipeline: Wo welche Regressquote gilt

Beide Prüfverfahren lassen sich als Eskalationstreppe lesen. Die zitierte „unter 1 %“-Endquote ist die Wahrscheinlichkeit, Stufe 9 (rechtskräftiger Regress) zu erreichen, bezogen auf die Gesamtheit der Vertragsärzte. Sie wird amtlich nur **aggregiert für V1 und V2 gemeinsam** veröffentlicht (KV BaWü 2022: 0,097 %); verfahrensgetrennte Durchsetzungsquoten existieren in keiner publizierten Bundesstatistik. Tabellen von unten lesen: Schritt 0 = Verfahrensauslöser, Schritt 9 = höchste Eskalationsstufe (rechtskräftiger Regress).

Struktureller Unterschied: Verfahren 1 ist *probabilistisch* — viele Ärzte erreichen frühe Stufen, sehr wenige gelangen bis Schritt n (das Schutzstufenmodell filtert). Verfahren 2 ist bei **V2b (Unzulässigkeit, insb. Formfehler)** nahezu *deterministisch* — wer Schritt 0 erreicht, durchläuft die Pipeline fast vollständig, weil keine Schutzstufe den Durchlauf unterbricht. Bei **V2a (Unwirtschaftlichkeit bei leitlinienkonformer Verordnung)** bestehen dagegen reale Verteidigungsmöglichkeiten (medizinische Begründung, Kostendifferenzmethode § 106b Abs. 2a SGB V) — hier ist das Verfahren ebenfalls probabilistisch, wenn auch ohne Beratungsschutz. **Betroffenheit beginnt bei Schritt 1, nicht erst beim Geldfluss.**

Verfahren 1: Auffälligkeitsprüfung (§ 106 SGB V)

↑ Eskalation

Schritt / Methode	Sprachform	Verfahrens-Begriff	Reg.	P ges.	P S0
Schritt 8: Regress rechtskräftig — selten	„Der Regress ist durch“	Regress rechtskräftig	1	k.D.* KV BaWü: 0,097 % (V1+V2)	~ 0,3 % KV Hessen: 3/916
Schritt 7: Klage — Sozialgericht	„Ich gehe vor Gericht“	Regress streitig	1	k.D.	k.D.
Schritt 6: Widerspruchsentscheidung	„Entscheidung gefallen“	Regress aufgehoben od. bestätigt	1	k.D.	k.D.
Schritt 5: Widerspruch	„Ich wehre mich“	Regress angefochten	1	k.D.	k.D.
— Folgeschritte 5–8 (■ rot hinterlegt) nur nach Pfad 4b — nicht nach Pfad 4a —					
Schritt 4b : Regressfestsetzung (Zweitzyklus, gedeckelt 25.000 EUR / 2 J.) — Ausnahmefall	„Ich habe einen Regress“	Regress festgesetzt (n. rechtskr.)	1	~0,1 %	~0,3 %
Schritt 4a : Beratung statt Regress (Erstzyklus, bei Erstmaligkeit) — Rechtsfolge, ersetzt den Regress (§ 106b Abs. 2 S. 2 SGB V)	„Ich werde beraten“	Regress im Erstzyklus ausgeschlossen	0	k.D.	< 1 %
— Verzweigung in Schritt 3 (Bewertung): Verneinung → Verfahren endet (>99%); Bejahung → Pfad 4a (■ Erstzyklus) oder Pfad 4b (■ Zweitzyklus, nach 2-Jahres-Karenz; 5-Jahres-Reset auf Zyklus 1) —					
Schritt 3: Bewertung der Wirtschaftlichkeit (Verneinung = Endpunkt für >99%; Bejahung = Übergang zu Pfad 4a/4b)	„Die Prüfung ist durch“	Kein Regress (Regelfall, Verneinung)	0	k.D.	hoch (>99% Verneinung)
Schritt 2: Anhörung + Praxisbesonderheiten — Erklärungsversuch des Arztes (Filterstufe vor Bewertung)	„Ich erkläre mich“	Verfahren läuft	0	k.D.	~100 %
Schritt 1: Prüfverfahren eingeleitet — Screening	„Die prüfen mich“	Prüfverfahren (kein Verdacht)	0	~10–20 % [†]	~100 %
Schritt 0: Trigger: Kosten-/Mengenabweichung erkannt	—	Kein Verfahren	0	~10–20 % [†]	100 %

[*] Quellen und Messmethodik:

(1) **KV BaWü 2022** (0,097 % = ca. 21 / 21.500 Ärzte): KV Baden-Württemberg, Informationsseite Regressgefahr (<https://www.kvbawue.de/praxis/verordnungen/arzneimittel/regressgefahr>); Messmethode: durchgesetzte Arzneimittelregresse/Vertragsärzte gesamt (V1+V2, ohne Verfahrenstrennung).

(2) **KV Hessen 2015** (3/916 = 0,3 % | S0): *Deutsches Ärzteblatt*, Artikel 113630; Messmethode: vollständige Pipeline-Zählung (916 Auffälligkeitsverfahren → 29 geprüft → 3 Regresse; P | S0 = Regressdurchsetzungsrate V1).

Beide Werte: verschiedene Populationen, Verfahren, Jahre — kein Direktvergleich. Die „unter 1 %“-Formel gilt für V1+V2; keine Verfahrenstrennung veröffentlicht.

[†] Bundesweite Prüfquoten nicht veröffentlicht; Schätzung auf Basis regionaler Berichte. Veröffentlichter Datenpunkt:

KV Hessen 2015 (Dt. Ärzteblatt, Art. 113630): 916 ausgelöste Auffälligkeitsverfahren Arzneimittel — Gesamtzahl Vertragsärzte KV Hessen für dieses Jahr nicht separat publiziert (Denominator für absolute Prüfquote damit nicht rekonstruierbar).

Reg. = Regress objektiv eingetreten (0 = nein; 1 = ja, auch wenn noch nicht rechtskräftig).

P ges. = Wahrscheinlichkeit diese Stufe zu erreichen (Bezugsgröße: alle Vertragsärzte).

P | S0 = Wahrscheinlichkeit bezogen auf Population die Schritt 0 erreicht hat. k.D. = keine publizierten Daten verfügbar.

Kernaussage V1: Die Pipeline verzweigt nach Schritt 3 in zwei alternative Endpfade: Pfad **4a** (Erstzyklus, Beratung statt Regress, < 1 %) und Pfad **4b** (Zweitzyklus, Regressfestsetzung, gedeckelt 25.000 EUR, ~ 0,3 %). Pfad 4b setzt voraus, dass nach 2-Jahres-Karenz eine erneute Auffälligkeit eintritt; 5 Jahre Unauffälligkeit setzen auf Pfad 4a zurück. Schritte 5–8 (Widerspruch/Klage/Rechtskraft) sind nur nach 4b relevant. Die rechtskräftige Endquote von ca. 0,097 % (KV BaWü, V1+V2 zusammen) ist das Ergebnis dieser dreistufigen Filterkaskade (Anhörung+Praxisbesonderheiten in Schritt 2, Beratung als Substitut in 4a, Deckelung in 4b), nicht ihr Ausgangspunkt.

Präzisierung der Reihenfolge (Schritt 2 → 3 → 4a/4b). Die Schritte sind *sequenziell zu lesen, mit Verzweigung in Schritt 3*: Wer in Schritt 2 (Anhörung + Praxisbesonderheiten) eine Abweichung erfolgreich erklärt, deren Bewertung in Schritt 3 zur Verneinung der Wirtschaftlichkeitsverletzung führt, scheidet aus dem Verfahren aus — weder Beratung (Pfad 4a) noch Regressfestsetzung (Pfad 4b) kommt für ihn in Betracht. Die Beratung tritt nur dann ein, wenn die Prüfungsstelle in Schritt 3 zu der Erkenntnis gelangt: „Es liegt eine Unwirtschaftlichkeit vor“, und die Auffälligkeit erstmalig im Prüfzyklus auftritt (Pfad 4a). Tritt sie wiederholt nach Karenz auf, geht es direkt zur Regressfestsetzung in Pfad 4b. Die Beratung ist damit das Erstmaligkeits-Privileg eines Arztes, dessen Wirtschaftlichkeitsverletzung bejaht wurde, der aber zum ersten Mal in einem Prüfzyklus auffällig geworden ist (BSG 22.10.2014, B 6 KA 3/14 R — Grundsatzentscheidung „Beratung vor Regress“ zur Vorgängernorm § 106 Abs. 5e SGB V; BSG 11.12.2019, B 6 KA 23/18 R — direkte Bestätigung zu § 106b Abs. 2 SGB V: „individuelle Beratung vor Regressfestsetzung gilt bei statistischen Erstauffälligkeiten, *nicht* bei Einzelfallprüfungen“; GPE Baden-Württemberg, Verfahrensbeschreibung). Das ist dogmatisch wichtig, weil es die häufige Fehillesart entkräftet, die Beratung sei eine sanktionsfreie „Vorstufe“ — sie ist tatsächlich Regress-Substitut. Aggregierte Stufendurchlauf-Quoten (Anhörung → Bewertung-Verneinung → Bewertung-Bejahung → Beratung) werden von keiner KV publiziert (offener Recherche-punkt R1).

Verfahren 2: Einzelfallprüfung (§ 106b Abs. 1 SGB V)

↑ Eskalation

Schritt / Methode	Sprachform	Verfahrens-Begriff	Reg.	P S0	Dropout-Anmerkung
Schritt 9: Regress rechtskräftig	„Regress ist durch“	Regress rechtskräftig	1	k.D., Schritt 5	V2a>V2b vor Gericht (R2)
Schritt 8: Klage — Sozialgericht	„Ich gehe vor Gericht“	Regress streitig	1	k.D., Minderheit	—
Schritt 7: Widerspruchsent-scheidung	„Entscheidung gefallen“	Regress aufgehoben oder bestätigt	1	k.D.	—
Schritt 6: Widerspruch	„Ich wehre mich“	Regress angefochten	1	k.D.	70–80 % Vergleichs-Ausstieg vor diesem Schritt (R3)
Schritt 5: Regress-festsetzung	„Ich habe einen Regress“	Regress fest-gesetzt (n. rechtskr.)	1	~95 % [*]	—
— Hier wäre systematisch die „Beratung statt Regress“ anzusiedeln (analog Pfad 4a in V1) — gesetzlich ausgeschlossen (§ 106b Abs. 2 S. 3 Hs. 2 SGB V) —					
Schritt 4: Bewertung — Verdacht bestätigt/verneint	„Die entscheiden“	Regress möglich / entfällt	0/1	~100 %	—
Schritt 3: Formale Prüfung	„Die prüfen meine Unterlagen“	Regressverfahren aktiv	0	~100 %	—
Schritt 2: Unterlagenanforderung	„Ich muss mich rechtfertigen“	Regressverfahren aktiv	0	~100 %	—
Schritt 1: Prüf-verfahren eingeleitet	„Die prüfen mich gezielt“	Regressverfahren eingeleitet	0	~100 %	[[‡]]
Schritt 0: Konkreter Kassenantrag (Trigger)	—	Kein Verfahren	0	100 % (Def.)	[[‡]]

[*] KV Nordrhein gegenüber dem Deutschen Ärzteblatt: ca. 95 % der Einzelfallprüfungen führen zu einem Regress (Vergleich rechnet rechentechnisch als Regress; daher ST-001-Schätzung 70–80 % Vergleich konsistent im 95 %-Korridor).

[[‡]] KV Nordrhein: geschätzt ca. 20.000 Einzelfallprüfungs-Anträge / Jahr bei ca. 13.500 Praxen (konservative Bandbreite: 15.000–25.000; Quelle: interne KV-Berichte 2016–2018, zitiert in der Berichterstattung zur GKV-VSG-Umsetzung; **extern nicht verifizierbar**, keine veröffentlichte Jahresstatistik der KV Nordrhein; Verfahrensabschlussquoten nicht publiziert. Die Größenordnung bleibt Gegenstand der IFG-Anfrage an die KV Nordrhein (Anhang C) und des offenen Recherchepunkts R3).

Reg. = Regress objektiv eingetreten (0 = nein; 0/1 = verfahrensabhängig; 1 = ja).

P | S0 = bedingte Wahrscheinlichkeit, dass ein V2-Antrag (Schritt 0) diese Stufe erreicht. **Dropout-Anmerkung** = qualitative Hinweise auf Verfahrensausstiege (Vergleich, V2a/V2b-Differenz). Quantitative Werte sind k.D. (R2–R4). k.D. = keine publizierten Daten.

Kernaussage V2 (eingeschränkt): Die Pipeline ist **strukturell so angelegt**, dass bei Auslösung eine hohe Übergangswahrscheinlichkeit zum Regress anzunehmen ist (kein Beratungsschutz, normativer Schadensbegriff, kein Ermessensspielraum bei Formfehlern). Empirisch belastbare Transitionswahrscheinlichkeiten sind wegen der Datenlücke nicht verfügbar (Einwand 4, Abschnitt 9, räumt dies explizit ein; „deterministisch“ ist daher eine Struktur-Beschreibung, kein gemessener Transitionswert). **Wichtige Qualifikation (Einwand 5):** Die Kernaussage gilt nicht

uneingeschränkt für alle V2-Verfahren. Geschätzt **60–65 % der V2-Verfahren** (Kategorie B reine Formfehler sowie verfahrensfremde Angriffsvektoren wie der Stempel-Regress) sind in diesem Sinne dysfunktional; die restlichen 35–40 % (Kategorie A: evidenzbasierte Formregeln, z.B. AM-RL-Anlagen, G-BA-Beschlüsse, Biosimilar-Pflicht) codieren medizinische Evidenz, wenn auch über den punitiven statt edukativen Kanal (Einwand 5 bringt diesen Befund in die Hauptthese ein). **Rechtskräftig vs. faktisch:** Das Bild “fast jeder Arzt, der bis zum Gericht zieht, bekommt einen Regress” trifft auf **V2b** (Formfehler/unzulässige Verordnungen) zu — die Erfolgsaussichten vor Gericht liegen dort wegen des normativen Schadensbegriffs nahe Null. Das Gericht zu erreichen ist aber die Minderheit: geschätzt 70–80 % der V2-Betroffenen vergleichen sich vor Rechtskraft (typisch 30–50 % des Regressbetrags; Schätzung, empirisch nicht publiziert, siehe offene Recherchepunkte R2/R3). Bei **V2a** (unwirtschaftliche, aber leitlinienkonforme Verordnungen) bestehen echte Verteidigungsmöglichkeiten: Der Arzt kann die medizinische Begründung vorbringen, und die Kostendifferenzmethode (§ 106b Abs. 2a SGB V, BSG 2024) begrenzt den Regress auf die Differenz zum wirtschaftlichen Niveau. Die quantitative Verteilung V2a/V2b sowie die Widerspruchs-Erfolgsquoten sind aktuell nicht belastbar publiziert (offener Recherchepunkt).

Offene Recherchepunkte (Datenlücken, die diese Studie nicht schließen kann)

Diese Studie arbeitet, wo nötig, mit Schätzungen und hypothesengeleiteter Argumentation. Die folgenden Punkte sind empirisch nicht belastbar abgedeckt und müssen in künftigen Versionen gefüllt werden (ggf. über IFG-Anfragen oder KV-Auswertungen):

- **R1 — V1-Dropout-Quoten je Schutzstufe:** Wie viele statistisch auffällige Ärzte fallen in Stufe 1 (Anhörung/Praxisbesonderheiten), Stufe 2 (Beratung) bzw. Stufe 3 (gedeckelter Folgereggress) aus dem Verfahren? Nur die Endquote (0,097 %) ist bekannt.
- **R2 — V2-Widerspruchs-Erfolgsquote:** Wie oft gewinnen Ärzte im Beschwerdeausschuss bzw. vor dem Sozialgericht? Unterschied V2a vs. V2b?
- **R3 — V2-Vergleichsquoten rechtskräftig vs. faktisch:** Der in dieser Studie verwendete Wert “70–80 % vergleichen vor Rechtskraft” beruht auf Praxisberichten, nicht auf publizierten Statistiken. *Teilweise belastbare Annäherung gefunden:* KV Nordrhein gibt gegenüber dem *Deutschen Ärzteblatt* an, dass “ca. 95 % der Einzelfallprüfungen zu einem Regress führen” (publizierter Aggregat-Wert für V2-Anträge der KV Nordrhein 2017–2019; Vergleich zählt rechentechnisch als Regress, sodass ST-001-Schätzung 70–80 % Vergleich konsistent in den 95 %-Korridor passt). Die exakte Vergleichsquote (Regress-mit-Vergleich vs. Regress-rechtskräftig) bleibt nicht publiziert.
- **R4 — Quantitative Aufteilung V2a/V2b:** Anteil, durchschnittliche Regresssumme und Widerspruchs-Erfolgsquote je Untertyp.

3.4 Termination without Determination: Die unsichtbare Ökonomie der Vergleiche

Die 99,7 %-Verwerfungsrate der Auffälligkeitsprüfung (V1, KV Hessen) ist aussagekräftiger als bisher dargestellt — aber in eine unerwartete Richtung. Die bisherige Analyse hat gefragt: *Warum scheitern so viele Verfahren?* Die entscheidende Folgefrage lautet: *Wie enden sie — und welche epistemische Qualität haben diese Enden?*

Regressverfahren können auf mindestens fünf Wegen enden, die sich in ihrer epistemischen Qualität fundamental unterscheiden:

Beendigungsweg	Rechtlicher Weg	Feststellung der Berechtigung?
Prüfungsstelle lehnt Antrag ab	Ablehnungsbescheid	Ja — durch Prüfungsstelle
Informeller Vergleich / Zahlung	§§ 53–62 SGB X, Kassenrücknahme	Nein — kein Bescheid, kein Urteil
Kasse zieht Antrag zurück	Einstellung ohne Sachentscheidung	Nein
Verjährung	Fristablauf	Nein
Gerichtliches Urteil	Urteil, bestandskräftig	Ja — höchste epistemische Qualität

Nur zwei der fünf Wege produzieren eine inhaltliche Feststellung. Da fast alle Verfahren vor Erreichen des Gerichts enden, bleibt die Systemqualität dauerhaft ungemessen.

Das erzeugt ein **strukturelles Anreizproblem**: Kassen, die einen unbegründeten Antrag gestellt haben, können ihn vor Gericht zurückziehen, ohne dass die Unbegründetheit je festgestellt wird. Ärzte, die aus Angst vor Aufwand oder Reputationsschaden einer Vergleichszahlung zustimmen, “anerkennen” damit keine Schuld — aber das System wertet die Zahlung faktisch als Bestätigung. Die Verwerfungsquote misst damit nicht die Qualität der Anträge, sondern die **Gegenwehrstärke der Betroffenen**.

Das Muster ist strukturell identisch mit dem deutschen Abmahnwesen: Viele Anträge, die meisten zahlen aus Angst vor Kosten und Aufwand, kaum einer klagt. Die Yield kommt nicht aus gerichtlichen Erfolgen, sondern aus der Asymmetrie von Angstkosten und Abwehrkosten. Das Gericht wäre der einzige Ort, an dem unabhängig festgestellt werden könnte, ob ein Verfahren berechtigt war. Weil fast kein Verfahren je ein Gericht erreicht, bleibt der Qualitätssensor dauerhaft ohne Messwerte.

3.5 Die Asymmetrie zwischen Auffälligkeits- und Einzelfallprüfung

Die beiden Prüfverfahren widersprechen sich strukturell:

Prüfungsart	Initiator	Beratung vor Regress	Schutz
Auffälligkeitsprüfung	Prüfungsstelle (neutral)	Ja (§ 106b Abs. 2)	Gehoben
Einzelfallprüfung	Krankenkasse (Antragstellerin)	Nein (§ 106b Abs. 2 S. 4)	Abgesenkt

Während die Auffälligkeitsprüfung über die Jahre Schutzschichten dazubekommen hat (erste Beratungsregelung für Richtgrößenprüfungen mit GKV-VStG 2012, § 106 Abs. 5e a. F.; Praxisbesonderheiten 2011; bundesgesetzlich verankerter Beratungsschutz “Beratung statt Regress” erst mit GKV-VSG 2015 in § 106b Abs. 2 n. F.; Richtgrößen abgeschafft 2015/2017), blieb die Einzelfallprüfung explizit ohne diesen Schutz. Aus Sicht des Anwendungsbereichs ist sie damit das verbleibende Verfahren mit den geringsten Schutzklauseln.

Ob das eine bewusste Schutzlücke oder eine zufällige Reformresidue ist, lässt sich aus den Gesetzgebungsmaterialien nicht eindeutig klären. Die KBV-Stellungnahme zum GKV-VSG 2015 hat die Verlagerung als “Gefahr einer Verschärfung” kritisiert (siehe oben), wurde aber im Verfahren nicht gefolgt. Methodisch ist daher festzuhalten: Das Muster ist vorhanden, der Vorsatz nicht beweisbar.

3.5.1 Ausschlussfristen: Wie weit zurück geprüft werden darf

Ein weiterer Asymmetrie-Aspekt betrifft die zeitliche Reichweite der Prüfverfahren. Die Fristen wurden mehrfach reformiert. Wichtig: Es handelt sich um **Ausschlussfristen** (wirken von Amts wegen, das Recht erlischt automatisch), nicht um Verjährungsfristen (müssten vom Arzt einredeweise geltend gemacht werden). Für Ärzte ist das die günstigere Variante.

	V1 Auffälligkeitsprüfung	V2 Einzelfallprüfung
Aktuelles Recht (ab TSVG 11.05.2019 / GVWG 20.07.2021)		
Festsetzungsfrist	2 Jahre ab Jahresende bzw. Honorarbescheid	18 Mon. Antragsfrist + 12 Mon. Festsetzung = 2,5 Jahre
Rechtsgrundlage	§ 106 Abs. 3 S. 3 SGB V	§ 106 Abs. 3 S. 4–5 SGB V
Altes Recht (vor 11.05.2019 — gilt für Altfälle!)		
Ausschlussfrist	4 Jahre (BSG-Richterrecht)	4 Jahre (BSG-Richterrecht)
Rechtsgrundlage	BSG 6 RKA 40/94 (20.09.1995)	BSG B 6 KA 13/18 R (11.09.2019)

Hintergrund: Die vierjährige Ausschlussfrist wurde 1995 vom BSG richterrechtlich entwickelt (6 RKA 40/94), in Anlehnung an § 45 SGB I und andere sozialrechtliche Vier-Jahres-Fristen. Der Gesetzgeber hat sie mit dem TSVG (2019) und GVWG (2021) auf 2–2,5 Jahre verkürzt. Begründung im Gesetzgebungsverfahren: „Zeiträume von mehr als zwei Jahren zwischen dem geprüften Verordnungszeitraum und dem Abschluss der Prüfungen [sind] für die Betroffenen unzumutbar.“

Praktische Einschränkung: Die Ausschlussfrist begrenzt nur, *bis wann ein Erstbescheid ergehen muss*. Wurde das Verfahren innerhalb der Frist eingeleitet, gibt es **keine zeitliche Obergrenze** für den weiteren Instanzenzug. Das BSG hat Verfahren entschieden, die 8–11 Jahre nach dem Verordnungszeitraum bei ihm ankamen (z. B. B 6 KA 6/21 R, 2022: Verordnungen aus 2011). Für den betroffenen Arzt kann die Belastung durch ein laufendes Verfahren also weit über die Ausschlussfrist hinausreichen.

3.6 Der Zertifikatsfehler: Was das System vorgibt zu messen — und was es tatsächlich misst

3.6.1 Zwei inkommensurable Messdomänen

Beide Prüfverfahren produzieren Ergebnisse, die **überwiegend nicht messen, was § 12 SGB V als Schutzziel benennt**. Sie messen Proxys — aus verschiedenen Domänen, mit verschiedenen Methoden und fundamental verschiedener epistemischer Qualität. *Einschränkung:* Ein Teil der V2-Prüfungen (geschätzt ~35 %, Kategorie A) codiert durchaus medizinische Evidenz als Formregeln — AM-RL-Anlagen, G-BA-Nutzenbewertungen und Biosimilar-Pflichten sind inhaltlich evidenzbasiert, auch wenn sie formal geprüft werden (vgl. Abschnitt 3.7).

Begriffserklärung „Zertifikat“: In der folgenden Tabelle bezeichnet **Zertifikat** eine belastbare, inhaltliche Aussage über die medizinische Angemessenheit einer Versorgungsleistung im Sinne des § 12 Abs. 1 SGB V. Ein Zertifikat liegt nur vor, wenn das Prüfergebn tatsächlich misst, ob die Versorgung „ausreichend, zweckmäßig und wirtschaftlich“ war — nicht lediglich, ob eine formale oder statistische Auffälligkeit vorliegt.

Instanz	Selbstanspruch	Tatsächlich gemessen / Zertifikat?
Auffälligkeitsprüfung (§ 106 SGB V)	Wirtschaftliche Versorgung (Screening)	Kosten-/Mengenabweichung vom Fachgruppendurchschnitt → statistisch-ökonomisches Abweichungssignal (kein medizin. Zertifikat)
Einzelfallprüfung	Medizinische Unwirtschaftlichkeit im Einzelfall	Formale / dokumentarische Angreifbarkeit → formales Sanktionsresultat (kein medizin. Zertifikat)
Praxisbesonderheiten	Korrektur legitimer Abweichung	Verfahrensabhängige Anerkennung; anmeldepflichtig, regional intransparent → Validität exogen (kein Zertifikat)
Ärztliche Dokumentation	Medizinische Begründung	Selbstbeschreibung unter systemischem Druck → Dokumentation (kein Zertifikat)
Medizinischer Dienst (MD)	Leistungs- / Abrechnungsprüfung	Regel- und zweckgebundene Anspruchsbewertung (kein Qualitätszertifikat)
Amtsärztliche Gutachten	Status- / Verwaltungsfragen	Zustandsbewertung (Dienstfähigkeit etc.) (kein Versorgungszertifikat)
Forschung / Register / QS (IQTIG etc.)	Qualitätsverbesserung	Aggregierte Qualitätssignale; nicht individualisierbar, nicht sanktionslogisch (kein Zertifikat)
Schlichtungsstellen (Ärztekammern)	Behandlungsstandard	Patientenbezogene medizinische Angemessenheit → medizinisches Zertifikat (selten, ex post, systemisch entkoppelt)
Zivilrechtliche Arzthaftung	Behandlungsfehler	Medizinischer Standard + Kausalität → starkes medizinisches Zertifikat (ex post, reaktiv)
Kein Verfahren	§ 12 SGB V: bedarfsgerechte, zweckmäßige Versorgung	wird im Regress- und Prüfsystem systematisch nicht gemessen

Medizinische Angemessenheit — das Schutzziel des § 12 Abs. 1 SGB V (“Die Leistungen müssen ausreichend, zweckmäßig und wirtschaftlich sein; sie dürfen das Maß des Notwendigen nicht überschreiten.”) — wird im deutschen Vertragsarztrecht nur außerhalb des Regress- und Prüfsystems zertifiziert: in Schlichtungsverfahren der Ärztekammern und in zivilrechtlichen Arzthaftungsprozessen. Diese Verfahren sind reaktiv, selten, ex post und systemisch vollständig vom Wirtschaftlichkeitsprüfsystem entkoppelt.

Abbildungen 2 und 3 zeigen beide Prüfprozesse im Detail. An keiner Stufe beider Verfahren entsteht eine medizinisch verwertbare Aussage. Auch der vollständige Rechtsweg (Widerspruch, Klage) korrigiert ausschließlich formale Entscheidungen — er ersetzt keine medizinische Bewertung der Versorgung.




Abbildung 2: Pipeline A: Auffälligkeitsprüfung (statistisches Screening), zweizyklisch dargestellt. Im Erstzyklus ersetzt die Beratung den Regress rechtsverbindlich (§ 106b Abs. 2 S. 2 SGB V); sie ist nicht Vorstufe eines Regresses, sondern der normative Endpunkt. Erst in Zyklus 2 (nach ≥ 2 J. Karenz und erneuter Auffälligkeit) kann ein gedeckelter Regress (25.000 EUR / 2 J.) festgesetzt werden; 5 J. Unauffälligkeit setzen zurück. An keiner Stufe entsteht ein medizinisches Zertifikat. Die Anhörung mit Praxisbesonderheiten ist der einzige Punkt, an dem der Arzt die Messvalidität aktiv beeinflussen kann.




Abbildung 3: Pipeline B: Einzelfallprüfung (Verdachtsprüfung). Auch der vollständige Rechtsweg (Widerspruch → Klage) erzeugt kein medizinisches Zertifikat — er korrigiert ausschließlich formale Entscheidungen.

3.6.2 Warum so wenige Verfahren vor Gericht landen

An keiner Stelle des Prüfprozesses — weder bei der Auffälligkeitsprüfung noch bei der Einzelfallprüfung — entsteht eine medizinisch verwertbare Aussage über die Versorgungsqualität. Auch der Beschwerdeausschuss prüft nur die Rechtmäßigkeit des Bescheids, nicht die medizinische Angemessenheit der Behandlung. Erst das Sozialgericht wäre die erste unabhängige Instanz. Doch fast alle Verfahren enden vorher — durch Vergleich, Rücknahme oder Verjährung.

Warum? Die Antwort unterscheidet sich fundamental nach Verfahren:

Bei V1 (Auffälligkeitsprüfung): Die meisten Verfahren enden bereits bei Schritt 4 (Screeningabschluss) — der Arzt erklärt die Abweichung, die Prüfungsstelle akzeptiert. Eine Klage wäre widersinnig, weil das Verfahren erfolgreich für den Arzt endet.

Bei V2 (Einzelfallprüfung): Das Ergebnis steht nach Verfahrenseinleitung im Wesentlichen fest (normativer Schadensbegriff, siehe Abschnitt 3.6.5). Drei Mechanismen entwerten den Rechtsweg für den Arzt: (1) Das Gericht würdigt bei Formfehlern die medizinische Korrektheit der Behandlung nicht — selbst exzellente Medizin schützt nicht vor dem Regress. (2) Kein Beratungsschutz (§ 106b Abs. 2 S. 4): Es gibt keinen pädagogischen Zwischenschritt, der das Verfahren noch abwenden könnte. (3) Der normative Schadensbegriff definiert den Schaden als ab Verordnung eingetreten — die nachträgliche Heilung des Formfehlers ist prozessual ausgeschlossen.

Die Kasse ihrerseits bevorzugt einen Vergleich (30–50 % des Betrags, sofort, ohne öffentliche Aufmerksamkeit) gegenüber einem Prozess (100 % des Betrags, aber mit Risiko, Aufwand und Sichtbarkeit). Beide Seiten haben rationale Gründe, das Gericht zu meiden. Die wenigen Fälle, die Gericht erreichen, sind nicht repräsentativ — sie sind die Spitze einer Selektion, bei der beide Seiten schwache Fälle vorher aussortiert haben.

Machtungleichgewicht: Für die Kasse ist ein unbegründeter Antrag praktisch folgenlos: § 106b SGB V enthält keine Sanktionen für unbegründete Anträge, keine Kostentragungspflicht bei Falsch-Positiv und keine Mengenbegrenzung. Die Prüfungskosten werden paritätisch umgelegt (§ 106 Abs. 4 SGB V). Für den Arzt ist jeder Antrag existenziell belastend. Dieses asymmetrische Risikoprofil begründet ein strukturelles Missbrauchspotenzial: Die Kasse kann es sich leisten, breit Anträge zu stellen und auf Vergleiche zu setzen, ohne ein Gerichtsverfahren zu riskieren. Die einzige dokumentierte Ausnahme: Das Sozialgericht Mainz wies 2022 einen Regress von 260.000 EUR als *rechtsmissbräuchlich* zurück (SG Mainz, S 3 KA 14/19, 07.12.2022; fehlende Gegenzeichnung bei Chemotherapie-Verordnungen, medizinisch korrekt, kein persönlicher Vorteil des Arztes) — ein Einzelfall, keine gesetzliche Schranke.

3.6.3 Der doppelte Zertifikatsfehler — und der größere dahinter

Wichtige Differenzierung vorweg — drei Ebenen:

- **V1** (Auffälligkeitsprüfung): sequenzielles dreistufiges Schutzstufenmodell (Details siehe Kasten unten). Der Zertifikatsfehler wirkt nur als Screening-Last, nicht als Sanktion.
- **V2a** (Unwirtschaftlichkeit bei leitlinienkonformer Verordnung): medizinische Verteidigung und Kostendifferenzmethode (§ 106b Abs. 2a) sind möglich — der Zertifikatsfehler wirkt abgemildert.
- **V2b** (Unzulässigkeit): hier gilt er in voller Schärfe, aber *binnendifferenziert*:
 - (i) *Reine Formfehler* (fehlende Unterschrift/Stempel, fehlende ICD, falsches Aut-idem-Kreuz): Formkonformität ist *kein* Proxy für medizinische Qualität — voller Zertifikatsfehler.

- (ii) *Inhaltliche Unzulässigkeit* (AM-RL-Verstoß, Off-Label ohne Begründung, AMNOG-Ausschluss): Die “Form” codiert hier bereits medizinische Evidenz (G-BA-Nutzenbewertung, AM-RL-Kriterien) — die Regel *ist* Evidenz in formaler Verkleidung. Der Zertifikatsfehler ist hier schwächer, weil die Formregel medizinische Qualität mittelbar misst. Die Kommunikation bleibt punitiv statt edukativ (Strafsignal statt Lernsignal; siehe CORE4-7, Doppelfunktionsbefund).

Übergeordneter Befund: Der doppelte Zertifikatsfehler betrifft, *was* gemessen wird. Der **größere Zertifikatsfehler** betrifft, *in welche Richtung* gemessen wird: Das System prüft ausschließlich “zu viel verordnet”, nie “zu wenig versorgt”. Darauf kommen wir im Unterabschnitt „*Der übergeordnete Zertifikatsfehler: die Einbahnprüfung*“ weiter unten zurück.

Die folgende Analyse fokussiert zunächst auf die *strukturelle Anlage* beider Verfahren — die inneren Schutzlücken konzentrieren sich auf V2b.

Das V1-Schutzstufenmodell im Detail (§ 106b Abs. 2 SGB V)

Das V1-Modell ist *nicht* eine Liste paralleler Entlastungen, sondern eine *sequenzielle Kaskade*, die Schritt für Schritt filtert. Erst am Ende dieser Kaskade bleiben die ca. 0,097 % rechtskräftig durchgesetzten Regresse übrig:

1. **Anhörung + Praxisbesonderheiten:** Erklärt der Arzt seine Kostenabweichung plausibel (atypische Patientenstruktur, fachliche Spezialisierung, besondere Therapien), endet das Verfahren vor jeder Sanktion. Rechtsgrundlage der Anhörung im Prüfverfahren ist **§ 24 SGB X** (allgemeine sozialrechtliche Anhörungspflicht vor belastendem Verwaltungsakt), konkretisiert durch die Rahmenvorgaben (KBV/GKV-Spitzenverband, Stand 01.05.2020). Regionale Empirie zeigt: der Großteil der markierten Fälle verlässt die Pipeline hier.
2. **Beratung statt Regress:** Bei erstmaliger verbleibender Auffälligkeit *ist* die Beratung die Rechtsfolge des Verfahrens — nicht eine pädagogische Vorstufe. Sie schließt einen Regress im Erstzyklus rechtlich aus (§ 106b Abs. 2 S. 2 SGB V; vom BSG als Regelungsentscheidung mit Verwaltungsaktqualität eingestuft, B 6 KA 21/15 R und B 6 KA 1/17 R).
3. **Karenzzeit + 25.000-EUR-Deckel + 5-Jahres-Reset:** Erst bei *wiederholter* Auffälligkeit nach Ablauf einer 2-Jahres-Karenzzeit darf überhaupt ein Regress festgesetzt werden. In den ersten 2 Jahren nach der Beratung ist er auf 25.000 EUR gedeckelt (gesetzliche Grundlage der Regressbegrenzung: § 106b Abs. 2 S. 3 SGB V). **Der 5-Jahres-Reset selbst** (Rückkehr zu Stufe 2 nach 5 Jahren Unauffälligkeit) ist allerdings *nicht* unmittelbar in § 106b Abs. 2 S. 3 geregelt, sondern in den **Rahmenvorgaben § 6** der KBV/GKV-Spitzenverbands-Vereinbarung (Stand 01.05.2020) als Konkretisierung der Karenzsystematik normiert.

Kernaussage: *Der Schutz greift, fast niemand kommt am Ende an.* Die ca. 0,097 %-Endquote ist das *Ergebnis* dieser Filterkaskade, nicht ihr Ausgangspunkt. Das Modell existiert nur für V1. Für V2 ist “Beratung statt Regress” gesetzlich ausgeschlossen (§ 106b Abs. 2 S. 4 SGB V).

Erster Zertifikatsfehler: Die Auffälligkeitsprüfung misst Kostenabweichung, nicht medizinische Qualität. Der hohe Dropout ist für ein Screening-Verfahren technisch korrekt — ein breiter Filter mit niedriger Spezifität ist funktional erwartet. Das ändert nichts daran, dass alle 916 markierten Ärzte die Kosten des Screenings tragen (Angst, Aufwand, Verhaltensänderung), auch wenn für 913 von ihnen kein Regress folgt. Das Instrument muss nicht versagen, um zu schaden.

Zweiter Zertifikatsfehler: Die Einzelfallprüfung beansprucht, medizinische Unwirtschaftlichkeit im Einzelfall zu prüfen (§ 106b Abs. 1 SGB V). Sie misst faktisch überwiegend formale und dokumentarische Kriterien. Die implizite Annahme, Formfehler könnten als Proxy für medizinische Fehlversorgung dienen, ist epistemisch nicht haltbar:

- Formfehler können bei exzellenter Medizin auftreten.
- Medizinische Fehlversorgung kann bei formgerechter Dokumentation vollständig unsichtbar bleiben.
- Formkonformität ist kein Proxy für medizinische Qualität.

Das Einzelfallprüfverfahren misst nicht medizinische Fehler, sondern formale Angreifbarkeit — und behandelt diese fälschlich als medizinische Evidenz. Dieser Befund gilt **uneingeschränkt für V2b (i) — reine Formfehler**: Hier ist die Form kein Proxy für Medizin, der Zertifikatsfehler voll. Bei **V2b (ii) — inhaltlicher Unzulässigkeit** (AM-RL-Verstoß, Off-Label ohne Begründung) ist der Befund abgeschwächt: Die Formregel codiert G-BA-Nutzenbewertung oder AM-RL-Kriterien; das System misst medizinische Qualität *mittelbar* über die Regel — aber punitiv statt edukativ (siehe CORE4-7: Doppelfunktion). Bei **V2a** (unwirtschaftliche, leitlinienkonforme Verordnungen) kann der Arzt die Therapieentscheidung medizinisch begründen; die Kostendifferenzmethode begrenzt den Regress. Dieses Proxy-Versagen ist kein Einzelfall, sondern eine bekannte systemische Pathologie: *Goodhart's Law* ("When a measure becomes a target, it ceases to be a good measure") und *Campbell's Law* ("Je stärker ein quantitativer Indikator für soziale Entscheidungsfindung genutzt wird, desto mehr ist er Korruptionsdruck ausgesetzt") beschreiben exakt diesen Mechanismus. Die Prüfquote wird zum Ziel, die Formkonformität zum Messobjekt — und beide verlieren dadurch ihre diagnostische Aussagekraft über die tatsächliche Versorgungsqualität.

Der größere Zertifikatsfehler: die Einbahnprüfung. Die ersten beiden Zertifikatsfehler betreffen den *Messinhalt* (Kostenabweichung statt Medizin; Formkonformität statt Medizin). Der größere liegt in der *Richtung*: Das gesamte Regresssystem prüft ausschließlich "**zu viel verordnet**" — nie "**zu wenig versorgt**". Damit verschiebt das System den Schaden vom Arzt zum Patienten: Der Arzt ist bei Handeln dem Regressrisiko ausgesetzt; der Patient trägt bei ärztlicher Zurückhaltung die Unterversorgung. Und selbst wenn der Arzt in die andere Richtung ausweicht (Facharzt-Überweisung, Zusatzdiagnostik als Absicherung), trägt der Patient auch diese Überversorgung — *medizinisch* (iatrogene Risiken, Overdiagnosis) und *finanziell/zeitlich* (Zuzahlungen, Fahrtwege, Arbeits- und Urlaubszeit; siehe Glossar-Eintrag *Überversorgung*).

- Wurde zu viel verordnet → Regress möglich.
- Wurde zu wenig verordnet → keine Konsequenz im Prüfsystem.
- Wurden Patienten aus Regressangst auf Spezialisten abgeschoben → keine Konsequenz.
- Wurde eine Therapie aus Budgetängsten verzögert oder unterlassen → keine Konsequenz.

Diese Richtungs-Asymmetrie ist in ihrer Tragweite größer als V1 und V2 zusammen: Denn während die ersten beiden Zertifikatsfehler *falsche Sanktionen* produzieren können (Formfehler-Regress bei medizinisch korrekter Verordnung), produziert der Richtungsfehler *systematische Unterversorgung* ohne institutionalisierten Korrekturmechanismus.

Präzisierung: Was genau dem Versorgungsauftrag des § 70 SGB V fehlt. Es wäre zu schlicht, zu sagen, es gäbe "kein Messinstrument" für § 70. Aggregierte Messungen existieren durchaus: die Bedarfsplanung der KVen (räumliche Erreichbarkeit), der Zi-Versorgungsatlas [1] (regionale Versorgungsindikatoren), ACSC-Hospitalisierungen (Ambulatory Care Sensitive Conditions; Sundmacher et al. 2015, [2]), die Qualitätssicherung nach § 135a/§ 136 SGB V. Die Präzisierung lautet daher: Dem Versorgungsauftrag des § 70 fehlt **kein Mess-, sondern ein Sanktions- bzw. Korrekturinstrument auf Praxisebene**, das die Asymmetrie zur Wirtschaftlichkeitsprüfung aufheben würde. Aggregate werden gemessen, aber nicht mit operativen Korrekturschritten gegen den Einzelleistungserbringer verbunden. Der MD prüft Abrechnungs-, nicht Therapieangemessenheit; der G-BA arbeitet mit aggregierten Indikatoren ohne ambulante Einzelfall-Anbindung; Arzthaftung setzt erst bei manifestem Schaden ein. Ergebnis: Ein Arzt, der

aus Angst weniger tut, wird nie geprüft. Ein Arzt, der leitliniengerecht behandelt, riskiert Regress. **Das System belohnt Unterlassung und bestraft Handeln** — und das ist kein Messfehler innerhalb eines Verfahrens, sondern die grundsätzliche Richtungswahl des Gesamtsystems (vgl. Abschnitt 10.7: Vorschlag einer Versorgungsprüfung als symmetrisches Korrekturinstrument; sowie Abschn. 4.4.7 für die Diskussion eines positiven Rückkopplungssignals nach Vorbild des britischen QOF — “nachweislich gute Medizin höhere Vergütung” — als institutionelles Gegengewicht zur einseitig negativen Sanktionsstruktur).

Kanonischer Befund:

Das Regresssystem weist einen doppelten Zertifikatsfehler im *Messinhalt* auf und einen übergeordneten Zertifikatsfehler in der *Messrichtung*. Der gesetzliche Auftrag der Wirtschaftlichkeitsprüfung (§§ 106 ff. SGB V) ist die Ausgabenkontrolle, nicht die Qualitätszertifizierung — und diesen Auftrag erfüllt das System. Der Fehlschluss liegt in der öffentlichen und politischen Interpretation: Die niedrige Regressquote wird als Beleg für ein “funktionierendes System” kommuniziert, wobei “funktionierend” implizit medizinische Versorgungsqualität meint. Tatsächlich misst die Auffälligkeitsprüfung Kostenabweichungen, die Einzelfallprüfung formale bzw. zulassungsrechtliche Angreifbarkeit — und das gesamte System nur in eine Richtung: Überversorgung. Medizinische Angemessenheit im Sinne des § 12 SGB V und der Versorgungsauftrag des § 70 SGB V werden systematisch nur außerhalb des Regresssystems zertifiziert. Der größere Zertifikatsfehler ist damit nicht, dass falsch gemessen wird, sondern dass Unterversorgung gar nicht gemessen wird.

Einschränkungen: V1 berücksichtigt medizinische Besonderheiten im dreistufigen, sequenziellen Schutzstufenmodell (Details im Kasten oben). V2a lässt medizinische Verteidigung und Kostendifferenzmethode zu. Der Befund gilt in voller Schärfe für V2b (i) (reine Formfehler); bei V2b (ii) (inhaltliche Unzulässigkeit, AM-RL-Verstoß) ist er abgeschwächt, weil die Formregel G-BA-Evidenz codiert — das Problem bleibt die punitive Kommunikation statt eines Lernsignals (CORE4-7). Der übergeordnete Richtungs-Zertifikatsfehler gilt für *alle* Verfahren gleichermaßen.

Hinweis zur Gegenposition: Ob der Zertifikatsfehler ein konstruiertes Kriterium ist — ob also die Studie dem System ein Qualitätsversprechen unterstellt, das es nie gegeben hat —, wird in Abschnitt 9 (Einwand 2) eingehend diskutiert. Der Einwand ist dogmatisch zutreffend und wird dort eingeräumt.

Die naheliegende Frage: Warum gibt es keine Versorgungsprüfung? Wenn das Wirtschaftlichkeitsprüfsystem medizinische Versorgungsqualität nicht misst — warum existiert kein paralleles System, das genau das tut? Die Antwort ist mehrstufig: (1) Die stationäre Qualitätssicherung (IQTIG, § 136 SGB V) arbeitet mit aggregierten Indikatoren und ist nicht auf den ambulanten Bereich übertragbar. (2) Der Medizinische Dienst (MD) prüft Leistungs- und Abrechnungsangemessenheit, aber nicht die therapeutische Entscheidung selbst. (3) Eine individuelle Versorgungsprüfung wäre methodisch anspruchsvoll: Sie müsste den Behandlungsstandard zum Zeitpunkt der Verordnung ex post bewerten — das leisten nur die Schlichtungsstellen der Ärztekammern (selten, reaktiv, freiwillig) und die Zivilgerichte (Arzthaftung). Keines dieser Instrumente ist systemisch an das Regressverfahren angeschlossen. Die Regelungslücke ist keine technische Unmöglichkeit, sondern ein Ergebnis historisch getrennter Verwaltungskulturen: Die Wirtschaftlichkeitsprüfung gehört zur Selbstverwaltung (KV + Kassen), die Qualitätssicherung zum G-BA, die Haftung zum Zivilrecht.

3.6.4 Formfehler als strukturelle Strategie

Aus dem Zertifikatsfehler der Einzelfallprüfung ergibt sich ein struktureller Strategievorteil für die antragstellende Seite. Formfehler sind ein besonders effizientes Angriffsziel:

- **Billig zu prüfen:** Kein medizinisches Gutachten nötig, keine Fachexpertise erforderlich.
- **Eindeutig:** Unterschrift fehlt oder Stempel statt Unterschrift — kein Ermessensspielraum.
- **Angstwirksam:** Jeder Arzt kann potentiell Formfehler produzieren; jeder Arzt ist exponiert.
- **Nicht medizinisch streitbar:** Kein Gegengutachten kann die formale Angreifbarkeit aufheben, unabhängig davon wie gut die Medizin war.

Das erzeugt eine inverse Selektionslogik: Das System selektiert **gegen Dokumentationsschwäche, nicht gegen Versorgungsdefizite**. Ein Arzt, der systematisch schlechte Medizin macht aber sauber dokumentiert, ist im System vollständig unsichtbar. Ein Arzt, der exzellente Medizin macht aber Formfehler produziert, ist maximal exponiert.

3.6.5 Der normative Schadensbegriff: Warum Formfehler ab Verfahrenseinleitung nicht mehr heilbar sind

Der normative Schadensbegriff des BSG (B 6 KA 5/09 R, 05.05.2010) verbindet den Zertifikatsfehler mit der Determinismus-Eigenschaft der Einzelfallprüfung. Seine Logik:

1. **Vor Verfahrenseinleitung:** Formfehler können korrigiert werden (fehlende Unterschrift nachtragen, Angaben ergänzen). Kein Schaden.
2. **Entstehung und Konkretisierung des Schadens:** Der *Schaden* der Kasse tritt **normativ bereits mit der unzulässigen (formfehlerhaften) Verordnung ein** — er wird durch die spätere Bezahlung durch die Kasse nur *konkretisiert*, nicht erst erzeugt. Ob das Medikament medizinisch indiziert war, ist für die Schadensbemessung **irrelevant**. “Ersparte Aufwendungen” werden im normativen Modell nicht gegengerechnet. Diese Präzisierung ist dogmatisch bedeutsam: Die frühere Formulierung “Schaden tritt mit Bezahlung ein” verkürzt den Gehalt des BSG-Urteils. Entscheidend ist, dass der Rechtsverstoß (unzulässige Verordnung) den Schaden auslöst; die Zahlung macht ihn liquid.
3. **Gerichtliche Prüfung:** Das Sozialgericht prüft ausschließlich: Lag der Formfehler zum Zeitpunkt der Verordnung vor? Ja oder Nein.
4. **Ergebnis:** Ab Schritt 2 steht das Verfahrensergebnis im Wesentlichen fest.

Das BSG hat dies mit Urteil vom 27. August 2025 (B 6 KA 9/24 R) bei rund 490.000 EUR Stempel-Regress bestätigt: Der Arzt argumentierte, alle Verordnungen seien medizinisch indiziert. Das Gericht erklärte dieses Argument für irrelevant. 2024 schloss das BSG die Differenzkostenregelung (§ 106b Abs. 2a) für “unzulässige” Verordnungen (= Formfehler) ausdrücklich aus (B 6 KA 5/23 R; B 6 KA 10/23 R).

Strukturelle Konsequenz: Der normative Schadensbegriff erzeugt für die Einzelfallprüfung eine Anreizstruktur, die einem Vergleichssystem ähnelt: Geschätzt 70–80 % der betroffenen Ärzte schließen Vergleiche (typisch 30–50 % des Regressbetrags; Schätzung aus Praxisberichten von Regressberatern und ärztlichen Fachverbänden, keine publizierte Studie), weil die Erfolgsaussichten vor Gericht bei formalen Fehlern nahe Null liegen. Ärzte, die dennoch den Rechtsweg beschreiten, tun dies häufig in der Erwartung, das Gericht würde die medizinische Korrektheit der Behandlung würdigen. Diese Erwartung wird durch den normativen Schadensbegriff systematisch enttäuscht.

Ausnahmen: In seltenen Fällen haben Gerichte trotz Formfehler zugunsten des Arztes entschieden: Das Sozialgericht Mainz wies 2022 einen Regress von 260.000 EUR als *rechtsmiss-*

bräuchlich zurück (S 3 KA 14/19, 07.12.2022; Treu und Glauben, § 242 BGB analog — kein realer Schaden, kein persönlicher Vorteil des Arztes). Das LSG Baden-Württemberg entschied 2025 (L 5 KA 1505/23), dass eine Einzelfallprüfung nicht für Verordnungen durchgeführt werden darf, die bereits in einer Richtgrößenprüfung unbeanstandet geblieben sind (Doppelprüfungsverbot). Diese Ausnahmen sind jedoch nicht verallgemeinerbar und belegen gerade durch ihre Seltenheit, wie wenig Schutz der Rechtsweg typischerweise bietet.

3.6.6 Praxisbesonderheiten: Der Validitäts-Reparaturmechanismus und seine Grenzen

Die Auffälligkeitsprüfung enthält einen eingebauten Mechanismus zur Verbesserung ihrer medizinischen Validität: **Praxisbesonderheiten**. Ein Arzt, dessen Kostenprofil statistisch auffällig ist, kann geltend machen, dass seine Patientenstruktur die Abweichung erklärt (höherer Anteil schwer kranker Patienten, spezielles Fachgebiet etc.). In der Praxis scheitert dieser Korrekturmechanismus an drei strukturellen Hürden:

1. **Anmeldepflicht:** Praxisbesonderheiten müssen aktiv geltend gemacht werden — sie werden nicht von Amts wegen berücksichtigt.
2. **Regionale Intransparenz:** Anerkennungskriterien variieren erheblich zwischen KVen, ohne bundesweit einheitliche Maßstäbe.
3. **Restriktive Anerkennung:** In der Praxis werden Praxisbesonderheiten eng ausgelegt; der Nachweis ist aufwendig und unsicher.

Die Validität des statistischen Signals hängt damit nicht vom Messinstrument ab, sondern davon, ob der Arzt aktiv und erfolgreich interveniert. Wer das nicht tut — aus Unkenntnis, Aufwandscheu oder aus Angst, durch Widerspruch zusätzliche Aufmerksamkeit auf sich zu ziehen — erhält ein epistemisch minderwertigeres Verfahrensergebnis. Das ist ein weiterer Mechanismus der Regressangst, der bisher wenig diskutiert wird: nicht die Angst vor dem Regress selbst, sondern die Angst davor, durch Gegenwehr zusätzliche Sichtbarkeit zu erzeugen.

3.6.7 Das System kennt seinen Fehler: Vier informelle Ausgleichsmechanismen

Das Wirtschaftlichkeitsprüfsystem hat — trotz seiner beschriebenen Messdefizite — informelle Korrekturkanäle entwickelt. Ihre Existenz ist analytisch bedeutsam: Sie zeigen, dass das System selbst weiß, dass seine formalen Messinstrumente unvollständig sind, und sich Ausgleichswege geschaffen hat, ohne diese institutionell zu integrieren.

Zeitpunkt	Typ	Instrument	Rechtsgrundlage
Vor Verordnung	fachlich-epistemisch	KV-pharmakologische Beratung (z. B. KVBW, Kooperation Univ.-Kliniken)	KV-intern
Vor Verordnung	administrativ-faktisch	Ärztliche Anfrage zur Verordnungsfähigkeit an Krankenkasse	BSG B 6 KA 27/12 R
Nach Auffälligkeit	statistisch-validierend	Praxisbesonderheiten	§ 106 Abs. 5a SGB V
Nach Regresseinleitung	prozessual-schützend	Beratung vor Regress	§ 106b Abs. 2 SGB V

Alle vier Instrumente teilen eine strukturelle Schwäche: Sie sind freiwillig, unverbindlich, regional heterogen und in keiner Bundesstatistik erfasst. Niemand weiß, wie oft sie genutzt werden — genau das ist die Datenlücke, die ein Transparenzportal (PP-003) schließen würde.

Analytischer Kernsatz: Die Existenz dieser informellen Ausgleichsmechanismen belegt, dass

der Zertifikatsfehler nicht nur theoretisch bekannt ist, sondern praktisch kompensiert wird — aber bislang ausschließlich individuell, nicht systemisch. Wer Zugang zu diesen Wegen hat und sie kennt, ist strukturell besser geschützt. Wer sie nicht kennt, trägt das volle systemische Risiko.

Einschränkung bei Instrument 2 (KK-Anfrage): Eine positive Stellungnahme der Krankenkasse bindet die Kasse als *Antragstellerin* in einer Einzelfallprüfung — sie kann nicht selbst Regress beantragen und zuvor die Verordnungsfähigkeit bestätigt haben (*venire contra factum proprium*). Sie bindet jedoch nicht die Prüfungsstelle bei einer von Amts wegen initiierten Auffälligkeitsprüfung. Der Schutz ist stark gegen KK-initiierte Einzelfallregresse — kein Schutz gegen Prüfungsstellen-initiierte Auffälligkeitsprüfungen.

Analytische Pointe: Die KK-Stellungnahme ist strukturell das Instrument, das einem medizinischen Zertifikat am nächsten kommt — eine inhaltliche Bewertung der Verordnungsfähigkeit vor dem Schadenseintritt. Dass sie existiert, aber freiwillig, informell und nicht flächendeckend ist, zeigt die Lücke im System: Der Ansatz für eine präventive Qualitätsbewertung ist vorhanden, aber nicht institutionalisiert. Ein systemisch verankertes Pendant — etwa eine verbindliche Vorabklärung bei kostenintensiven oder off-label-Verordnungen — könnte den Zertifikatsfehler partiell schließen.

3.7 Evidenz in formaler Verkleidung: Die Doppelfunktion des Prüfsystems

Die bisherige Analyse behandelte “Formalität” als einheitlich medizinisch irrelevant. Das war zu pauschal. Eine genauere Betrachtung der AOK-BaWü-Prüfthemen 2025 und der AM-RL-Struktur zeigt **zwei Ebenen der Formalität**:

		Ebene 1: Echte Formalität	Ebene 2: Codierte Evidenz
Was	geprüft wird	Stempel statt Unterschrift, fehlende ICD-Kodierung, Aut-idem-Kreuz	AM-RL Anlage III, Biosimilar-Pflicht, Off-Label-Verbot, Mengengrenzen
Medizinischer	Gehalt	Keiner — die Medizin stimmt, nur die Dokumentation nicht	Hoch — G-BA hat Gleichwertigkeit/Evidenz bewertet und in Formregel übersetzt
Zertifikatsfehler		Gilt in voller Schärfe	Gilt <i>nicht</i> — die “Form” ist die Evidenz

Die Doppelfunktion: Schätzt man die Verteilung der V2-Prüfanlässe anhand der AOK-BaWü-Prüfthemenliste 2025 und der SpiFa-Bayern-Daten, ergibt sich ein Dreiteilungsbild:

Kategorie	Anteil	Charakter	Beispiele
A: Rationale Evidenzsteuerung	~35 %	Medizinischer Inhalt als Formregel codiert	Biosimilar-Pflicht, Off-Label-Kontrolle (GLP-1-RA), Opioide Mengengrenzen, RSV-Prophylaxe Altersgrenzen
B: Reine Formalkontrolle (V2b)	~40 %	Kein medizinischer Inhalt	Stempel statt Unterschrift, fehlende ICD-Kodierung, Dokumentationslücken
C: Bürokratie-Overhead	~25 %	Kleinstbeträge <300 EUR	Bagatellrückforderungen, Kodierungsfehler

Zwei parallele Evidenzkanäle: Das Gesundheitssystem verfügt über zwei Steuerungsmechanismen für medizinische Evidenz — einen edukativen und einen punitiven:

	Fortbildungspflicht (CME, § 95d SGB V)	Einzelfallprüfung (V2)
Timing	Vor dem Fehler (präventiv)	Nach dem Fehler (punitiv)
Signal	“Biosimilar ist gleichwertig” (Lernsignal)	“Sie haben kein Biosimilar verordnet, zahlen Sie” (Strafsignal)
Wahl des Arztes	Arzt wählt Fortbildungsthemen selbst	Kasse wählt Prüfgegenstand
Sanktion	10–25 % Honorarkürzung (indirekt)	Voller Regressbetrag (direkt)
Pflicht	250 CME-Punkte / 5 Jahre	Keine — nur reaktiv

Konsequenz für die zentrale These: Der Zertifikatsfehler gilt in voller Schärfe nur für Ebene 1 (echte Formalität, Kategorie B ~40 % + Kategorie C ~25 % Bagatelle = zusammen ~65 % der Prüfungen). Bei Ebene 2 (~35 %, Kategorie A) steckt die medizinische Qualität *implizit* in der Formregel — der G-BA hat die Evidenz bewertet und in eine Vorschrift übersetzt. Das System *enthält* medizinische Evidenz, *kommuniziert* sie aber nicht als Evidenz, sondern als Strafe. Auch bei Kategorie A (rationale Steuerung) fehlt der Beratungsschutz (§ 106b Abs. 2 S. 4): Der Arzt erhält *kein* Lernsignal vor dem Regress, sondern *nur* ein Strafsignal danach. Das ist wie Verkehrserziehung ausschließlich durch Bußgelder ohne Fahrschule. Die Forderung dieser Studie bleibt daher bestehen — aber sie verschiebt sich: Nicht Abschaffung der Evidenzsteuerung, sondern Ergänzung des punitiven Kanals um einen edukativen (vgl. Einwand 5 in Abschnitt 9).

3.8 Die operative Synthese: Drei Scanner, keine Qualitätsprüfung

Fasst man die bisherigen Befunde zusammen — Zertifikatsfehler, normativer Schadensbegriff, Formfehler-Strategie, informelle Ausgleichsmechanismen —, ergibt sich ein Gesamtbild, das über die einzelnen Befunde hinausgeht. Das deutsche Wirtschaftlichkeitsprüfsystem betreibt drei Screening-Mechanismen. Keiner davon prüft medizinische Versorgungsqualität:

Scanner	Was er sucht	Was er nicht prüft	Rechtsgrundlage
Auffälligkeitsprüfung (V1)	Statistische Abweichung vom Fachgruppenschnitt (Kostenvolumen)	Ob die Versorgung medizinisch angemessen war	§ 106 SGB V
Einzelfallprüfung (V2a)	Prüft Wirtschaftlichkeit einzelner Verordnungen (medizinische Begründung möglich)	Ob die Therapieentscheidung medizinisch richtig war	§ 106b SGB V
Einzelfallprüfung (V2b)	Scannt formale Korrektheit (Unterschrift, Kodierung, Indikation). Prüft nicht Therapiequalität.	Ob die Therapieentscheidung medizinisch richtig war	§ 106b SGB V
Retaxprüfung	Formale Korrektheit der Apothekenabrechnung	Ob der Patient das richtige Medikament bekommen hat	§ 129 SGB V

Keines dieser Verfahren prüft, ob der Patient ausreichend versorgt wurde (§ 12 SGB V), ob eine Unterlassung stattfand, ob die Therapieentscheidung leitliniengemäß war, oder ob der Arzt aus Angst *weniger* verordnet hat als medizinisch geboten. Der Versorgungsauftrag des § 70 SGB V — “eine bedarfsgerechte und gleichmäßige [...] Versorgung der Versicherten zu

gewährleisten“ — hat kein eigenes Messinstrument im Prüfsystem. Das gilt gleichermaßen für die Qualitätsverpflichtung aus § 135a SGB V, die Leistungserbringer explizit auf “den jeweiligen Stand der wissenschaftlichen Erkenntnisse” festlegt und die gesetzliche Verankerung der vom Sachverständigenrat entfalteten Trias (Übersorgung, Unterversorgung, Fehlversorgung; SVR 2000/2001 Band III) bildet: Geprüft wird faktisch nur die erste Kategorie.

3.8.1 Das System als Formfehler-Erkennung

Die operative Realität der Einzelfallprüfung legt eine Interpretation nahe, die über die bisherige Diskussion hinausgeht: Die Kassen suchen nicht primär nach medizinischer Unwirtschaftlichkeit, sondern nach **Formfehlern**. Der Formfehler *ist* der Verdacht. Das System ist dabei extrem effizient in dem, was es operativ tut: Formfehler finden und regressieren. Nur eben nicht in dem, wofür es normativ da sein soll.

Die Kausalkette:

1. Kasse erhält Verordnungsdaten (§ 300 SGB V, Apothekenrechenzentren).
2. Prüfsoftware gleicht Verordnungen ab (PZN↔ICD, Formcheck, Dosierung).
3. Flag: Formfehler identifiziert (fehlende Unterschrift, falscher Code etc.).
4. Sachbearbeiter sichtet Flag, bestätigt: “begründeter Verdacht”.
5. Formaler Antrag an Prüfungsstelle (§ 106b Abs. 1).
6. Normativer Schadensbegriff greift (BSG B 6 KA 5/09 R).
7. Formfehler ab Verfahrenseinleitung nicht mehr heilbar.
8. Gericht prüft: Formfehler ja/nein. Medizinische Indikation irrelevant.
9. 70–80 % der Ärzte schließen Vergleich (30–50 % des Betrags).
10. Regress fließt an die Krankenkasse zurück.

Unter Lesart C erklärt sich die hohe Verwerfungsquote anders: Die 97 % Einstellungen sind Fälle *ohne* verwertbaren Formfehler. Die 3 % mit Regress sind Fälle *mit* Formfehler. Das System optimiert auf Einhaltung formaler Kriterien — wie ein Rechtschreibprüfprogramm. Es tut genau das, wofür es operativ gebaut ist.

Methodische Einschränkung: Dies ist eine Arbeitshypothese, keine bewiesene Tatsache. Die Frage, ob Kassen tatsächlich automatisiert nach Formfehlern screenen, ist empirisch nicht abschließend geklärt (siehe Abschnitt 3.8.4). Die technischen Voraussetzungen dafür sind vorhanden; die operative Nutzung ist plausibel, aber nicht durch öffentliche Quellen belegt.

3.8.2 Hypothese: Digitalisierung als Treiber der Einzelfallprüfungszunahme

Die Zunahme der Einzelfallprüfungsanträge nach 2017 (Westfalen-Lippe +28 %, Nordrhein geschätzt 15.000–25.000/Jahr, extern nicht verifiziert) fällt zeitlich mit der zunehmenden Digitalisierung der Kassenverwaltung zusammen. Dies legt eine testbare Hypothese nahe: *Je stärker eine Krankenkasse digitalisiert ist, desto mehr Einzelfallprüfungsanträge stellt sie* — weil automatisierte Prüfsoftware die Identifikation von Formfehler-Kandidaten erleichtert und die Grenzkosten eines Antrags gegen Null senkt.

Operationalisierung (Vorschlag):

1. **Digitalisierungsgrad der Kassen:** Proxy über E-Rezept-Adoptionsrate, ePA-Nutzungsquote oder IT-Ausgaben pro Versichertem (KJ1-Statistik des BAS).
2. **Einzelfallprüfungsvolumen pro Kasse:** Daten aus IFG-Anfragen oder KV-Statistiken, sofern verfügbar.

3. **Korrelationsanalyse:** Korreliert der Digitalisierungsgrad mit dem Antragsvolumen? Kontrollvariablen: Kassengröße, regionale Prüfvereinbarung, Versichertenstruktur.

Diese Analyse konnte im Rahmen der vorliegenden Studie nicht durchgeführt werden (fehlende Daten zu kassenspezifischen Antragsvolumina). Sie ist als Forschungsauftrag für die Zeit nach Eingang der IFG-Antworten vorgemerkt.

3.8.3 Informationsasymmetrie: Der Prüfkatalog als Einbahnstraße

Zur operativen Synthese gehört ein Befund über Informationszugänge, der bisher nicht systematisch dargestellt wurde:

Akteur	Zugang zum Prüfkatalog	Echtzeit-Prüfung	Prüfsoftware
Krankenkasse	Eigener Katalog (mit Anbietern wie scanacs entwickelt)	Ja (automatisiert)	Ja
Apotheke	Prüfmodul im Warenwirtschaftssystem (scanacs, ABDA-Datenbank)	Ja (vor Abgabe)	Ja
Arzt	Nur allgemeine Verordnungshinweise der KV	Nein	Nein

Der Verordnende — der Arzt — ist der einzige Akteur im System, der die konkreten operativen Prüfkriterien nicht kennt, obwohl er derjenige ist, der die Verordnung ausstellt und für Formfehler haftet. Apotheken und Krankenkassen verfügen über Echtzeit-Prüfsoftware, die Verordnungen vor Abgabe bzw. nach Einreichung automatisiert gegen Prüfkataloge abgleicht. Ärzte haben keinen Zugang zu diesen Katalogen.

Das Bestimmtheitsgebot (Art. 20 Abs. 3 GG) verlangt, dass der Normadressat wissen kann, welches Verhalten von ihm erwartet wird. Die Prüfvereinbarungen nach § 106b Abs. 6 SGB V sind öffentlich — die operativen Prüfkataloge, nach denen konkret gescannt wird, sind es nicht. Ob diese Diskrepanz rechtsstaatlich problematisch ist, ist ungeklärt.

3.8.4 Die offene Rechtsfrage: Verdacht oder Screening?

§ 106b Abs. 1 SGB V definiert die Einzelfallprüfung als antragsgebundenes Verdachtsverfahren. Das setzt voraus, dass der Verdacht **zufällig** entsteht — ein Sachbearbeiter stößt bei der regulären Arbeit auf eine auffällige Verordnung und formuliert daraus einen begründeten Antrag.

Systematisches, flächendeckendes, automatisiertes Screening aller Verordnungen mit dem Ziel, Formfehler-Kandidaten zu identifizieren, sieht das Gesetz nicht vor. Ein solches Vorgehen wäre funktional eine Auffälligkeitsprüfung (V1) — eingekleidet als Einzelfallprüfung (V2).

Merkmal	Zufälliger Verdacht (gesetzeskonform)	Systematisches Screening (fragwürdig)
Auslöser	Sachbearbeiter bemerkt Auffälligkeit bei Routinearbeit	Software scannt alle Verordnungen
Umfang	Einzelne Fälle	Flächendeckend, automatisiert
Verdachtsqualität	Konkret, fallbezogen, menschlich bewertet	Maschinell generiert, menschlich nur bestätigt
Analogie	Polizist beobachtet zufällig Verstoß	Flächendeckende Videoüberwachung

Ob Kassen tatsächlich systematisch screenen, ist nicht belegt. Belegt ist, dass die technischen

Mittel dafür existieren (Prüfsoftware, PZN↔ICD-Abgleich, § 300 SGB V-Datenlieferungen) und dass das Volumen der Einzelfallprüfungsanträge in einigen KV-Regionen in Größenordnungen liegt, die mit zufälligen Verdachtsmomenten schwer erklärbar sind (KV Nordrhein: ca. 20.000 Anträge/Jahr). Die Frage, ob ein automatisiert identifizierter Formfehler-Kandidat einen “begründeten Antrag” im Sinne des § 106b Abs. 1 begründen kann — oder ob die Automatisierung des Screening-Schritts die Verfahrensgrenze zwischen V1 und V2 verwischt —, ist rechtlich ungeklärt.

Verfassungsrechtliche Einordnung: Das BVerfG hat 2023 im “Hessendata”-Urteil (1 BvR 1547/19) entschieden, dass jede automatisierte Datenanalyse ein **eigenständiger Eingriff** in das Recht auf informationelle Selbstbestimmung ist und strengen Verhältnismäßigkeitsanforderungen unterliegt. Die Übertragbarkeit auf die GKV-Prüfpraxis ist argumentativ gut vertretbar: Wenn die Polizei nicht unbegrenzt automatisiert Daten scannen darf, kann eine Krankenkasse nicht ohne weiteres sämtliche Verordnungsdaten automatisiert durchrastern, um daraus Regressanträge zu generieren. Eine gerichtliche Klärung dieser Frage existiert bisher nicht — es handelt sich um eine echte Regelungslücke.

Forschungsbedarf: Eine IFG-Anfrage an die Krankenkassen, ob und in welchem Umfang automatisierte Software zur Identifikation von Einzelfallprüfungs-Kandidaten eingesetzt wird, könnte diesen Befund empirisch untermauern oder widerlegen. Die operativen Prüfkataloge selbst müssten nach §§ 1, 2, 70 SGB V dogmatisch offenkundig sein — ein BSG-Urteil hierzu existiert jedoch nicht.

3.9 Der innere Konflikt: Drei Codes auf einer Operationseinheit

Die Asymmetrie zwischen den Prüfverfahren ist nur eine äußere Schicht des Problems. Die innere Schicht liegt eine Ebene tiefer: in der Konstruktion des Wirtschaftlichkeitsgebots selbst.

3.9.1 § 12 SGB V als Doppelanforderung

§ 12 Abs. 1 SGB V verlangt: “Die Leistungen müssen *ausreichend, zweckmäßig und wirtschaftlich* sein; sie dürfen das Maß des Notwendigen nicht überschreiten.” Die Norm kombiniert in einem einzigen Satz vier qualitative Anforderungen ohne Vorrangregel:

- “ausreichend” (Versorgungsanspruch des Patienten, §§ 27, 31 SGB V)
- “zweckmäßig” (Indikationsangemessenheit, leitliniengemäß, § 92 SGB V)
- “wirtschaftlich” (Kostenoptimum, sanktioniert durch § 106b SGB V)
- “nicht das Maß des Notwendigen überschreitend”

Solange es um eine *Leistungsdefinition* geht, ist die Kombination tragbar — sie beschreibt einen Ziel-Korridor. Sobald sie zur *Sanktionsnorm* wird (über § 106b SGB V mit existenzbedrohenden Regressbeträgen), wird sie zum Problem: Der Arzt soll sämtliche Anforderungen simultan erfüllen — und trägt die Verantwortung wenn sie nicht alle gleichzeitig erfüllbar sind.

3.9.2 Drei Funktionssystem-Codes auf einer ärztlichen Verordnung

Wer das systemtheoretisch betrachtet (in der Tradition Niklas Luhmanns), erkennt: Auf der Operationseinheit “ärztliche Verordnung” treffen drei Funktionssystem-Codes zusammen, die nicht miteinander kompatibel sind:

Code	Funktionssystem	Anforderung an die Verordnung
krank / gesund	Medizin	medizinisch indiziert, leitlinien-gemäß
Zahlung / Nichtzahlung	Wirtschaft (GKV)	wirtschaftlich, kostenoptimiert
Recht / Unrecht	Recht (Sozialrecht)	substantiierungsfähig, formfehlerfrei, dokumentiert

Die drei Codes sind in modernen Gesellschaften normalerweise systemtheoretisch entkoppelt: Der Arzt entscheidet medizinisch, das Wirtschaftssystem kalkuliert separat, das Rechtssystem urteilt auf einer dritten Ebene. Im deutschen Vertragsarztrecht treffen alle drei Codes auf demselben Objekt zusammen — und auf derselben Person. Der Arzt muss *simultan* medizinisch, ökonomisch und juristisch korrekt handeln. Ist eine der drei Anforderungen mit den anderen nicht vereinbar, trägt er das Risiko allein.

In Luhmanns Sprache: Was hier vorliegt, ist eine Kollision funktional differenzierter Codes auf einer Operationseinheit, ohne dass die Differenzierung selbst an der Operationseinheit aufgehoben wäre. Das ist mit den Mitteln moderner Gesellschaftsstrukturen nicht auflösbar — es muss durch institutionelle Konstruktion umgangen werden. Im deutschen Fall geschieht das nicht; die Konstruktion belastet stattdessen den einzelnen Arzt.

3.9.3 Das KBV-Statement von 2016

Die KBV hat den Doppelbind öffentlich benannt. Regina Feldmann (damals KBV-Vorstand) im Jahr 2016:

“Der Arzt soll verantwortlich sein für die Therapie, für Dosierung und Wirkstoffauswahl. Aber nicht für den Preis.”

Das ist genau die Forderung nach Code-Trennung: Medizinischer Code beim Arzt, ökonomischer Code beim System. Sie wurde von der Gesundheitspolitik nicht aufgegriffen.

3.9.4 Der BVerfG-Notausgang von 2005

Das Bundesverfassungsgericht hat den Konflikt erkannt — aber nur für einen schmalen Anwendungsfall. Im sogenannten *Nikolaus-Beschluss* (Az. 1 BvR 347/98 vom 06.12.2005) entschied der Erste Senat: Bei **lebensbedrohlichen oder regelmäßig tödlichen Erkrankungen** und Fehlen einer alternativen Behandlung besteht ein Anspruch auf nicht regulär erstattete Behandlung — auch dann, wenn das Wirtschaftlichkeitsgebot dagegen sprechen würde. Diese Rechtsprechung wurde 2012 in § 2 Abs. 1a SGB V kodifiziert.

Die Normalversorgung blieb davon unberührt. Wer chronisch krank ist, ohne lebensbedrohlich zu sein — Diabetiker, Schmerzpatienten, MS-Erkrankte, viele andere —, fällt nicht unter den Notausgang. Für sie greift weiterhin der volle Doppelbind, und der Arzt trägt das Risiko.

Sämtliche Reformen seit 1989 betrafen das *Verfahren* der Prüfung (§ 106 → § 106b, Beratung vor Regress, Bagatellgrenzen, Differenzkostenregelung 2024) — **nicht die Grundnorm § 12 SGB V**. Der innere Code-Konflikt blieb unangetastet.

3.10 Der theoretische Rahmen: Managerialismus und Audit Society

Die bisherigen Beobachtungen lassen sich in zwei etablierte Theorielinien der Sozial- und Verwaltungswissenschaft einbetten, die in der deutschen gesundheitspolitischen Diskussion

erstaunlich wenig rezipiert sind. Beide liefern keine neuen Fakten, aber einen Rahmen, in dem die Einzelbefunde aufhören, als “deutsche Eigentümlichkeit” zu erscheinen.

3.10.1 Freidson: Die “dritte Logik” und ihre Erosion

Der amerikanische Medizinsoziologe Eliot Freidson (1923–2005) hat in drei Standardwerken — *Profession of Medicine* (1970), *Professional Dominance* (1970) und *Professionalism: The Third Logic* (Polity, Cambridge 2001) — das Konzept der professionellen Dominanz entwickelt. Seine Kernthese: Echte Professionen unterscheiden sich von gewöhnlichen Berufen durch drei Merkmale — hohes Maß an Autonomie, Selbstregulierung, und das Monopol auf die Definition der eigenen Arbeitsinhalte. Diese Autonomie sei gesellschaftlich legitimiert, weil Professionen über ein esoterisches Fachwissen verfügen, das Laien (auch staatliche Administratoren) nicht adäquat beurteilen können.

Freidson benennt drei konkurrierende Logiken der Arbeitsorganisation:

- der **freie Markt** (Consumerism), der über Preissignale steuert,
- die **bürokratische Kontrolle** (Managerialismus), die über formale Regeln und Rechenschaftspflichten steuert, und
- der **Professionalismus** — die “dritte Logik” — der über ethische Bindung und kollegiale Qualitätskontrolle steuert.

Die zentrale historische These Freidsons: In westlichen Gesundheitssystemen wird der Professionalismus seit den 1980er-Jahren systematisch durch den Managerialismus ersetzt. Das *fundamentale Misstrauen* des Managerialismus lässt ärztliche Entscheidungen nicht mehr per se als gemeinwohlorientiert gelten; sie müssen externen, quantifizierbaren Leistungsindikatoren unterworfen werden.

Die in Teil II beschriebene rechtsdogmatische Lücke ist aus dieser Sicht keine Verirrung des deutschen Sozialrechts, sondern eine konsequente Anwendung des managerialen Prinzips: Der Arzt muss seine Entscheidungen formal auditierbar machen, sonst gilt seine Entscheidung vor dem System nicht. Die Drei-Code-Kollision des § 12 SGB V ist der deutsche Ausdruck eines globalen Paradigmenwechsels in der Steuerung von Gesundheitssystemen.

3.10.2 Power: Die “Audit Society” und ihre Rituale der Verifikation

Der britische Soziologe und Wirtschaftswissenschaftler Michael Power, Professor of Accounting an der London School of Economics, hat 1997 in *The Audit Society: Rituals of Verification* (Oxford University Press) eine weitere, präzise zugeschnittene Theorieline vorgelegt. Powers Kernthese: Die massive Ausweitung von Prüfungs-, Zertifizierungs- und Rechenschaftspflichten seit den 1990er-Jahren führt nicht notwendig zu mehr Qualität, Effizienz oder Sicherheit — sondern zu einer *Illusion von Kontrolle*. In einer “Audit Society” richten Organisationen ihre Aufmerksamkeit und ihre Ressourcen weg vom eigentlichen Kernzweck hin zur Produktion formal prüfbarer Dokumente und Prozesse (des sogenannten “audit trail”).

Drei Thesen Powers sind für den deutschen Fall direkt anwendbar:

- **Rituale der Verifikation:** Audits dienen primär der Legitimationsbeschaffung von Akteuren, nicht der Qualitätssicherung. Ihre Form ist wichtiger als ihr Inhalt.
- **Performativität:** Audits sind keine neutralen Messinstrumente, sie verändern das Verhalten der Geprüften aktiv — sie schaffen die Realität, die sie zu messen vorgeben.
- **Entkopplung von Prozess und Ergebnis:** Was auditierbar ist, wird wichtig. Was nicht auditierbar ist, verliert an Gewicht — unabhängig von seinem tatsächlichen medizinischen

Wert.

Der in Teil II dokumentierte 491.000-EUR-Formalregress wegen eines Namensstempels (BSG B 6 KA 9/24 R) ist aus dieser Sicht kein bizarres Fehlurteil, sondern das paradigmatische Endstadium der Audit Society: Der tatsächliche medizinische Schaden ist null, aber in der Logik der "Auditability" kollabiert der institutionelle Wert der Handlung vollständig, wenn das Ritual der handschriftlichen Unterschrift fehlt. Und die in Teil III dokumentierte Defensivmedizin ist nicht bloß eine affektive Reaktion auf ein "Angstsystem" — sie ist die zutiefst logische, strukturell erzwungene Adaption an eine Prüfgesellschaft, die Vertrauen in professionelle Expertise durch den Zwang zur dokumentierten Auditierbarkeit ersetzt hat.

3.10.3 Noordegraaf: Das Paradox des konnektiven Professionalismus

Mirko Noordegraaf (2015, 2020) hat Freidsons defensive Konzeption des Professionalismus weiterentwickelt. Er unterscheidet *protective professionalism* (Verteidigung beruflicher Exklusivität und Autonomie gegen externe Eingriffe) von *connective professionalism* (kooperative Integration von Stakeholder-Anforderungen — wie Transparenz, Effizienz, Kostendruck — in die eigene professionelle Praxis). Noordegraafs These: In modernen, komplexen Dienstleistungssystemen ist der rein defensive Modus nicht mehr tragfähig; Professionen müssen hybride Identitäten entwickeln.

Für das deutsche Wirtschaftlichkeitsprüfsystem ergibt sich daraus ein **theoretisches Paradox**: Konnektiver Professionalismus setzt voraus, dass das institutionelle Gegenüber Kooperationsanreize bietet. Ein System, das — wie die Regelkreisanalyse (Abschnitt 3.8) zeigt — ausschließlich Minus-Signale sendet und Formfehler deterministisch sanktioniert, entzieht dem Arzt systematisch die Möglichkeit zur vertrauensvollen Konnektivität. Die empirische Frage, ob und wie hybride Professionalität aufrechterhalten werden kann, wenn der Versuch zur Kooperation von der regulierenden Instanz durch formalistische Bestrafung beantwortet wird, ist eine offene Forschungslücke.

3.10.4 Foucault: Die Wirtschaftlichkeitsprüfung als Panoptikum

Die Verhaltenswirkung des Prüfsystems lässt sich mit Michel Foucaults Panoptismus-Konzept (*Surveiller et punir*, 1975, dt. *Überwachen und Strafen*) präzise beschreiben. Foucaults Kernthese: Ein Überwachungssystem entfaltet seine größte Disziplinierungswirkung nicht durch tatsächliche Bestrafung, sondern durch die *permanente Möglichkeit* der Beobachtung. Der Überwachte muss nicht tatsächlich beobachtet werden — er muss nur glauben, dass er beobachtet werden *könnte*.

Das deutsche Wirtschaftlichkeitsprüfsystem erfüllt die drei Kernmerkmale des Panoptikums:

1. **Asymmetrische Sichtbarkeit:** Der Arzt weiß nicht, ob und wann seine Verordnungen geprüft werden. Die Kasse sieht seine Daten in Echtzeit (Verordnungsdaten-Informationssystem VODATI, KV-Abrechnungsdaten). Der Arzt sieht die Antragsstrategien der Kasse nicht.
2. **Internalisierung der Kontrolle:** 72 % der Hausärzte (Ribbat 2023) ändern ihr Ordnungsverhalten *präventiv* — nicht weil sie geprüft werden, sondern weil sie geprüft werden *könnten*. Die Disziplinierung wirkt ohne Ausübung.
3. **Ökonomie der Macht:** Die öffentlich sichtbare V1-Regressquote (<1 %) ist kein Systemversagen, sondern maximale Effizienz: Das Screening allein erzeugt flächendeckende Verhaltensänderung, ohne viele Regresse durchsetzen zu müssen. Bei V2 ist die tatsächliche Durchsetzungsrate höher (Vergleiche), aber unsichtbar — der Disziplinierungseffekt wirkt auf beiden Ebenen.

Die Panoptikum-Perspektive ergänzt Power (Audit-Rituale als Ersatz für Vertrauen) und Freidson (Managerialismus verdrängt Professionalismus) um die Machtdimension: Das Prüfsystem ist nicht nur ein schlechtes Messinstrument — es ist ein hochwirksames Disziplinierungsinstrument, das gerade *weil* es nicht präzise misst, seine größte Wirkung entfaltet. Präzise Messung würde die meisten Ärzte entlasten. Diffuse Überwachung diszipliniert alle.

Freidson, Power und Foucault erklären, warum das System so aussieht und so wirkt, wie es wirkt. Sie erklären noch nicht, wie Ärzte darauf reagieren. Das ist die Frage von Teil III — und dort wird eine weitere Theorielinie nötig, die den Arzt nicht als passives Opfer, sondern als rationalen Akteur unter unauflösbaren Zwangslagen versteht: Michael Lipskys “Street-Level Bureaucracy”.

4 Teil III — Die Verhaltensökonomie: Was Ärzte tatsächlich tun

4.1 Ribbat 2023 — die derzeit umfangreichste deutsche Befragung

Die Frage, wie sich die Regressangst auf das ärztliche Verhalten auswirkt, ist nicht im Bereich der Anekdoten anzusiedeln. Sie ist empirisch beantwortet — in einer bundesweiten Studie, die merkwürdigerweise kaum jemand kennt:

Ribbat L, Linde K, Schneider A, Riedl B (2023): Effects of the Risk of Recourse Claims on the Work of General Practitioners and Orthopedists — A Nationwide Survey. Gesundheitswesen 85(2): 111-118. DOI: 10.1055/a-1594-2527, PMID: 34587633.

Methodik: Bundesweite Zufallsstichprobe von je 1000 Hausärztinnen und 1000 Orthopäd:innen. Rücklauf 41 % / 39 % (n=770). Vierseitiger Fragebogen. Lehrstuhl für Allgemeinmedizin TU München.

Verifizierte Hauptergebnisse (alle Werte V1+V2 zusammen, keine Verfahrenstrennung in der Studie):

- **47 % Hausärzte / 55 % Orthopäden:** Regressgefahr beschäftigt im Praxisalltag “stark oder sehr stark”.
- **37 % / 47 %:** ärztliches Handeln “stark beeinflusst”.
- **51 % Hausärzte / 25 % Orthopäden:** überweisen “zumindest gelegentlich trotz Indikation” zu Spezialisten.
- **72 % / 78 %:** emotionale Belastung durch Regresse “stark oder sehr stark”.

Konfidenzintervalle (95 %, Wilson-Score-Approximation). Die Stichprobengrößen je Fachgruppe liegen bei rund 410 (Hausärzte, 41 % Rücklauf) und 390 (Orthopäden, 39 % Rücklauf). Daraus ergeben sich für die vier Kernpunktschätzer Binomial-Konfidenzintervalle:

Kennzahl		Gruppe	n (ca.)	Punktschätzer	95 %-CI
Regressgefahr stark	“stark/sehr stark”	Hausärzte	410	47 %	42,2–51,9 %
Regressgefahr stark	“stark/sehr stark”	Orthopäden	390	55 %	50,0–59,9 %
Überweisung trotz Kompetenz		Hausärzte	410	51 %	46,2–55,8 %
Emotionale Belastung “stark/sehr stark”		Hausärzte	410	72 %	67,5–76,1 %
Verhaltensänderung samt, kombiniert)*	(Ge-	Gesamt	770	85 %	82,3–87,3 %

* Der 85 %-Wert bezieht sich auf die zusammengefasste Quote berichteten Ordnungsverzichts über beide Fachgruppen; Bezugsgröße $n \approx 770$ (kombinierte Nettostichprobe).

Die Konfidenzintervalle sind für die statistische Präzision aussagekräftig; sie decken nicht die systematischen Verzerrungen ab (Non-Response-Bias, Selbstbericht vs. objektives Verhalten), die im nachfolgenden Bias-Abschnitt diskutiert werden.

Interpretation: Knapp die Hälfte der Hausärzte ändert ihr Ordnungsverhalten aus Regressangst, mehr als die Hälfte schiebt Patienten weiter, die sie selbst behandeln könnten. Direkte deutsche Evidenz, keine Hochrechnung nötig. Die Konfidenzintervalle zeigen, dass die Größenordnungen robust sind — auch die untere Schranke der 95 %-CIs bleibt für alle Kernindikatoren oberhalb von 40 % (Hausärzte) bzw. 25 % (Orthopäden, für Überweisungsverhalten), was die substanzielle statistische Präzision bestätigt.

Bias-Diskussion (klassische Survey-Verzerrungen). Die statistische Präzision (Konfidenzintervalle oben) sagt nichts über systematische Verzerrungen. Vier klassische Bias-Quellen verdienen bei Ribbat 2023 besondere Aufmerksamkeit:

- **Non-Response-Bias.** Mit 41 % (Hausärzte) und 39 % (Orthopäden) liegt der Rücklauf im guten Mittelfeld deutscher Praxissurveys, aber klar *unter* den 60–70 %, die als weitgehend bias-frei gelten. Nicht-Antwortende könnten systematisch anders sein: entweder weniger regressbetroffen (“wen es nicht betrifft, der füllt den Fragebogen nicht aus”; Überschätzung der 72 %-Erfahrungsrate) oder stärker regressbetroffen (“wer gerade in einem Verfahren steckt, hat keine Zeit”; Unterschätzung der Belastungswerte). Ohne Non-Respondent-Follow-up ist die Richtung nicht bestimmbar. Für eine künftige Replikation wäre ein zweistufiges Design (Postkarten-Kurzbefragung der Non-Responder zu 2–3 Kernfragen) methodisch sinnvoll.
- **Response-Bias (soziale Erwünschtheit).** Die Frage “Haben Sie aus Regressangst weniger verordnet?” hat zwei mögliche Verzerrungsrichtungen: Unterberichterung (Arzt will nicht zugeben, Patienten aus Angst nicht optimal behandelt zu haben) oder Überberichterung (Arzt nutzt die Umfrage, um politischen Druck auf die Regressreform zu erhöhen). Beide Effekte können parallel wirken. Anonyme Selbstauskunft mildert das Problem nur teilweise.
- **Recall-Bias.** “Regress erlebt” umfasst bei Ribbat den gesamten Berufsverlauf (Lebenszeitprävalenz), nicht eine definierte Referenzperiode. Ältere Ärzte haben strukturell mehr Zeit, Regresse zu erleben; die 72 %-Zahl ist deshalb altersabhängig und nicht direkt als Jahresinzidenz lesbar. Die Poisson-Hochrechnung in der Summierungsrechnung (Teil III, $\lambda \in [0,30; 1,48]$) trägt dem Rechnung, indem sie Jahresrate und Lebenszeitraten systematisch trennt.
- **Publikations-Bias.** Ribbat 2023 ist die einzige große deutsche Befragungsstudie zu diesem Thema. Eine einzelne Studie kann eine Publikations-Bias-Einschätzung noch nicht leisten (Funnel-Plots etc. setzen Replikationen voraus). Der Befund dieser Studie — “die mediale Resonanz auf Ribbat ist auffallend niedrig” (siehe “Datum am Rande” unten) — spricht eher gegen einen Publikations-Bias in der *Rezeption*. Ob vergleichbare negative Studien unveröffentlicht geblieben sind (“File drawer problem”), ist ohne externe Register-Analyse nicht beantwortbar.

Konsequenz für die Interpretation. Die Richtung des Gesamtbefunds (substanzielle Verhaltensverzerrung durch Regressangst) ist robust gegen die diskutierten Bias-Quellen — die absolute Höhe der 47 %- und 72 %-Werte ist es nicht notwendigerweise. Für die Hauptargumentation dieser Studie ist das

ausreichend: Es geht um die Existenz und Struktur des Mechanismus, nicht um Präzisionspunktschätzer für politische Feinstuerung. Für Letzteres bräuchte es eine methodisch stärker abgesicherte Replikation (siehe Einwand 1 im Gegenpositions-Kapitel, Abschnitt 9).

Hinweis zur Gegenposition: Die methodischen Grenzen dieser Befunde — insbesondere die Frage, ob selbstberichtetes Verhalten auf tatsächliche Unterversorgung schließen lässt — werden in Abschnitt 9 (Einwand 1) diskutiert. Zur Operationalisierung und Falsifizierbarkeit siehe den folgenden Abschnitt.

Datum am Rande — die fehlende Resonanz: Eine eigene Recherche zur Medienresonanz dieser Studie zeigt: Sie wurde von keinem deutschen Fachmedium prominent aufgegriffen — weder vom Deutschen Ärzteblatt noch von der Ärzte Zeitung, weder von Medical Tribune noch von Coliquio. Auch in den Publikumsmedien (Zeit, Spiegel, FAZ) ist keine Berichterstattung nachweisbar. Bundestagsdebatten zitieren sie nicht. Die Verbände (KBV, NAV-Virchow, Hartmannbund) beklagen "Regressangst" chronologisch, stützen sich dabei aber auf eigene Verbandsumfragen und nennen Ribbat nicht als Goldstandard-Beleg. Es liegt kein Boykott vor und keine Verschwörung — es ist das "normale Schicksal" einer versorgungswissenschaftlichen Studie ohne PR-Maschine. Genau diese Stille ist methodisch der zweite Befund: Die deutsche Versorgungsforschung produziert Befunde, die in der gesundheitspolitischen Debatte nicht ankommen. Das ist nicht das Versagen der Forschung, sondern eine Eigenschaft der Aufmerksamkeitsökonomie des deutschen Gesundheitssystems.

4.2 Ribbat-Operationalisierung: Von der Befragung zum Verhaltensmechanismus

Einzelstudien-Risiko. Ribbat et al. (2023) ist die einzige große deutsche Befragungsstudie, die spezifisch die Auswirkungen der Regressangst auf das ärztliche Ordnungsverhalten misst. Eine unabhängige Replikation steht aus. Diese Studie zitiert Ribbat als den *besten verfügbaren Datenpunkt*, nicht als abschließenden Beweis. Die methodische Einschränkung — dass Ribbat *subjektive Wahrnehmung und selbstberichtetes Verhalten* misst, nicht objektive Versorgungsergebnisse — wird in Abschnitt 9 (Einwand 1) eingehend diskutiert.

Mapping zum Theorierahmen. Die Ribbat-Befunde lassen sich auf zwei *tragende* Theorierahmen dieser Studie abbilden: die **Spieltheorie** (Teil III, Nash-Gleichgewicht bei asymmetrischer Information) und Michael Lipskys **Street-Level Bureaucracy** (Coping-Strategien unter unauflösbaren Zwangslagen). Die weiteren Theorielinien (Freidson, Power, Foucault, Herd/Moynihan) tragen zur *Einordnung* des Systems bei (Teil II), werden hier aber bewusst nicht als erklärende Mechanismen für den konkreten Verhaltensmechanismus herangezogen, sondern als interpretatorischer Hintergrund (siehe Marginalien-Spalte):

Ribbat-Befund	Tragende Theorie	Vorhergesagter Mechanismus	Hintergrund (Marginalie)
72 % haben Regress erlebt	Spieltheorie (Teil III)	Hohes P_{erfahren} → überhöhtes $P_{\text{perceived}}$ → defensives Nash-Gleichgewicht	—
51 % überweisen trotz Kompetenz	Lipsky (SLB)	Weiterverweisung als Risikoverlagerung ("Outsourcing" / Referral)	Foucault (Panoptikum): Selbstverlagerung unter diffuser Beobachtung
85 % berichten Verordnungsverzicht	Lipsky (SLB)	Rationierung als klassische Frontline-Coping-Strategie unter Ressourcendruck	Herd/Moynihan: Administrative Burden verstärkt Rationierungsbereitschaft
47 % tägliche Beschäftigung	Spieltheorie + Lipsky	Antizipation verschiebt den Handlungshorizont in Richtung Risikovermeidung (Prospect-Theory-Verlustaversion, [3])	Foucault (Panoptikum): internalisierte Überwachung ohne aktive Prüfung

Dieses reduzierte Mapping zeigt: Die vier zentralen Ribbat-Befunde lassen sich parsimonisch aus zwei Theorien erklären (Spieltheorie + Lipsky). Freidson/Power/Foucault/Herd-Moynihan bleiben für die Systemeinordnung relevant, aber nicht als Erklärungsinstanzen für den individuellen Verhaltensmechanismus — sie beschreiben Systemeigenschaften, nicht Coping-Entscheidungen.

Falsifikationsbedingungen — pro tragende Theorie:

- **Spieltheorie (Nash-Gleichgewicht defensiv):** Falsifiziert, wenn (a) Prüfintensität (Antragshäufigkeit der Kassen je KV-Region) und Verordnungsvolumen (DDD pro Kopf) *nicht* negativ korrelieren, oder (b) eine Meta-Analyse der europäischen Regress-Systeme zeigt, dass die Verordnungsbereitschaft in nicht-punitiven Systemen (Beratung-statt-Regress-Regime) *nicht* signifikant höher ausfällt. Datenlage derzeit lückenhaft; IFG-Anfragen (Anhang C) zielen auf genau diese Korrelation.
- **Lipsky (Street-Level Bureaucracy):** Falsifiziert, wenn eine Replikation von Ribbat mit strengem Design (representative, non-response-korrigiert) *weniger als 20 %* berichteten Verhaltensseffekt zeigt, oder wenn eine qualitative Längsschnittstudie zeigt, dass die dokumentierten Coping-Mechanismen (Referral, Rationing, Limiting Engagement) *nicht* regress-induziert, sondern aus anderen Gründen (Zeitknappheit, Patientendruck, Überdiagnostikkultur) entstehen.

Die weiteren Theorielinien (Foucault, Herd/Moynihan, Freidson, Power) werden in dieser Studie als *Systemeinordnung* und nicht als eigenständige Erklärungshypothesen geführt; ihre Falsifikation ist nicht Gegenstand der Ribbat-Operationalisierung. Sie tragen zur Deutung des institutionellen Rahmens bei, nicht zum konkreten Mechanismus, der die Ribbat-Prozentsätze erzeugt.

4.3 Die internationale Bestätigung: 75,8 % Defensivmedizin global

Die Ribbat-Befunde stehen nicht allein. Eine globale Meta-Analyse (Zheng et al. 2023, Int J Qual Health Care, PMID: 38060672) beziffert die globale Prävalenz von Defensivmedizin auf 75,8 %. Die deutsche Spezialstudie Goetz et al. 2024 (BMC Primary Care, DOI: 10.1186/s12875-024-02267-x) zeigt: 27 % der deutschen Hausärzte mit "starker Rechtsangst", 54 % wöchentliche unnötige Labortests, 38 % Selbstschutz als Motiv.

Die Wirkmechanik ist also weder selten noch deutsch. Sie ist global, sie ist bekannt — und sie ist im deutschen Fall durch ein spezifisches Sanktionssystem verschärft, das in dieser Form nur Deutschland und die Schweiz kennen (siehe Teil VI).

4.4 Spieltheoretische Modellierung

Wer das Regress-System spieltheoretisch betrachtet, findet drei interessante Strukturen: ein dominantes Spiel mit asymmetrischer Information, ein Nash-Gleichgewicht das alle Beteiligten schlechter stellt, und ein Gefangenendilemma in der Ärzteschaft. Die folgenden Abschnitte skizzieren die Grundstruktur; eine formale Durchmodellierung mit Auszahlungsmatrizen, Sensitivitätsanalysen und verfahrensspezifischen Parametern ist als eigenständige Folgeanalyse vorgesehen.

4.4.1 Das Verordnungsspiel: Bayessches Spiel mit asymmetrischer Information

Das zentrale Spiel wird zwischen Arzt und Krankenkasse millionenfach pro Quartal gespielt. Es ist ein **Bayessches Spiel**, weil beide Seiten unter Unsicherheit über die Wahrscheinlichkeit eines Regresses entscheiden müssen — und weil diese Wahrscheinlichkeit *asymmetrisch verteilt* ist: Die Kasse kennt ihre eigenen Antragsstrategien, die internen Erfolgsquoten und teilweise die vertraulichen Erstattungsbeiträge. Der Arzt kennt nichts davon. Er schätzt das Regressrisiko über Anekdoten, Medienberichte und Berufsbiografie.

Grundgesamtheiten: Die Risikobetrachtung hängt fundamental von der gewählten Bezugsgröße ab. Bei V2 (Einzelfallprüfung) ist die Wahrscheinlichkeit, dass *eine bestimmte Verordnung* geprüft wird, verschwindend gering (ca. 800 Mio. GKV-Verordnungen pro Jahr, tausende V2-Anträge). Für den einzelnen Arzt mit durchschnittlich ca. 1.380 Patienten pro Quartal (KBV Gesundheitsdaten) und mehreren tausend Verordnungen pro Jahr summiert sich das Risiko:

Die Summierungsrechnung (KV Nordrhein als Beispiel):

Kenngroße	Wert
Praxen in KV Nordrhein	ca. 13.500
Vertragsärzte	ca. 22.500 (~1,67 pro Praxis)
V2-Anträge pro Jahr	ca. 20.000 (davon ~10.000 Sprechstundenbedarf)
V2-Anträge pro Arzt und Jahr	~0,9 (bei Gleichverteilung [†])
V2-Durchsetzungsquote	~95 % führen zu Regresszahlung (Dt. Ärzteblatt 2020)
→ Zahlungsvorgänge pro Arzt/Jahr	~0,85 (bei Gleichverteilung [†])
Jährliche Betroffenheitsquote	~57 % der Ärzte mit mind. 1 Zahlungsvorgang ^{††}
→ In 3 Jahren kumuliert	→ ~92 % mindestens einmal betroffen
Ribbat 2023: 72 % Regresserfahrung Rechnerisch plausibel	

[†] Annahme: Die 20.000 V2-Anträge verteilen sich gleichmäßig auf alle 22.500 Ärzte. Die tatsächliche Verteilung ist nicht publiziert — genau das ist Teil der diagnostizierten Intransparenz. Bei Konzentration auf bestimmte Fachgruppen oder Praxen wäre die individuelle Betroffenheitsquote für diese höher, für andere niedriger.

^{††} Poisson-Modell mit $\lambda = 0,85$ (regionale Rechnung KV Nordrhein): $P(k=0) = e^{-0,85} \approx 0,43$; $P(k \geq 1) = 0,57$ pro Jahr; über 3 Jahre $1 - e^{-2,55} \approx 0,92$. **Bandbreiten-Hinweis:** Die λ -Schätzung ist unsicher. Alternative Anker: BMG-Bundesrechnung (47.000 Verfahren / 155.000 Ärzte) ergibt $\lambda \approx 0,30$ und damit 26 % pro Jahr bzw. 59 % in 3 Jahren; die KV-Nordrhein-Antragsquote (20.000 / 13.500) ergibt $\lambda \approx 1,48$ und damit 77 % bzw. 99 %. Die drei Anker messen *verschiedene Ereignistypen* (BMG-Rate: abgeschlossene Verfahren bundesweit; KV-Nordrhein-Zahlungsquote: abgeschlossene Zahlungsvorgänge; KV-Nordrhein-Antragsquote: gestellte V2-Anträge, darunter auch im Vergleichswege erledigte Fälle). Für eine ehrliche Gesamtaussage wird in der Studie die Bandbreite **60–99 % in drei Jahren** verwendet — 60 % für den engen Zahlungsbegriff, 99 % für den weiten Antragsbegriff. Die Punktschätzung 92 % (mittleres Szenario) ist nicht belastbar. Eine formale Drei-Ereignistyp-Tabelle mit getrennten λ für Antrag, Vergleich und rechtskräftige Zahlung steht aus (Recherchepunkt R3).

Kleines Risiko pro Verordnung, großes Risiko pro Arzt. Unter der regionalen KV-Nordrhein-Annahme ($\lambda=0,85$) ergibt sich rechnerisch: ~57 % der Ärzte pro Jahr mit mindestens einem Zahlungsvorgang (Regress oder Vergleich), ~92 % über drei Jahre. Unter der konservativeren BMG-Bundesannahme ($\lambda=0,30$) sinkt der Wert auf ~59 % in drei Jahren; unter der Antragsquoten-Annahme ($\lambda=1,48$) steigt

er auf ~99 %. **Ehrliche Aussage: eine deutliche Mehrheit der Ärzte (60–99 %, je nach gezähltem Ereignistyp) ist über drei Jahre betroffen** — der exakte Wert ist empirisch nicht publiziert (offener Recherchepunkt R3). Die „unter 1 %“-Zahl misst etwas anderes: rechtskräftig durchgesetzte V1+V2-Regresse. Die V2-Vergleichsrealität taucht in keiner öffentlichen Statistik auf.

Zwei Kumulationsarten — sie wirken zusammen. Die Summierungsrechnung trennt zwei unabhängige Dimensionen der Risikoakkumulation, die in der öffentlichen Debatte oft zu einer einzigen verschmolzen werden. Beide wirken beim selben Arzt, aber aus unterschiedlichen Richtungen.

1. **Betroffenheits-Kumulation (Lostopf-Effekt).** Jede einzelne Verordnung hat ein sehr kleines Prüfisiko. Ein Arzt gibt aber mehrere tausend Verordnungen pro Jahr heraus — er greift also tausendfach in den „Lostopf“. Bei genügend vielen Griffen wird die Wahrscheinlichkeit, *mindestens einmal* getroffen zu werden, sehr hoch. Das ist der Poisson-Effekt der obigen Tabelle: 57–99 % in drei Jahren, je nach gezähltem Ereignistyp. Diese Kumulation misst, *ob* der Arzt über die Berufslaufbahn in ein Verfahren gerät.
2. **Finanzielle Kumulation (Rückforderungs-Zeitraum).** Wenn ein V2-Verfahren ausgelöst wird, prüft die Kasse typischerweise *nicht eine einzelne* Verordnung, sondern den gesamten Rückforderungszeitraum: meist 12–18 Monate, bei Dauerverordnungen auch länger (Festsetzungsfrist 2 Jahre V1, 18 Monate Antragsfrist + 12 Monate Festsetzung = 2,5 Jahre V2; siehe Abschnitt 3.5.1). Ein vermeintlicher „Bagatell“-Regress mit Median 100–200 EUR pro Verordnung wird bei 1–4 wiederholten Verordnungen pro Quartal und 6 Quartalen Rückforderungszeitraum rasch zu einem vier- bis fünfstelligen Betrag: Dauer-Verordnung eines 500-EUR-AM-RL-Ausschluss-Medikaments × 6 Quartale × 4 Fälle = 12.000 EUR; ein Stempel-Fehler über 18 Monate Praxislaufzeit kann fünfstellig werden (Extremfall: Stempel-Regress BSG 27.08.2025, rund 490.000 EUR). Diese Kumulation misst, *wie viel* der Arzt zahlt, *sobald* er in ein Verfahren gerät.

Warum beide gemeinsam relevant sind. Für die Risikoangst ist nicht nur eine der beiden Dimensionen ausschlaggebend, sondern ihr Produkt: die hohe Wahrscheinlichkeit, überhaupt in ein Verfahren zu geraten (Lostopf), multipliziert mit der hohen Einzelforderung, wenn es passiert (Rückforderungszeitraum). Die öffentliche Debatte betont meist nur die Wahrscheinlichkeit („unter 1 %“), der Arzt spürt vor allem die Höhe („wenn es mich trifft, dann richtig“). Beide Zahlen sind *einzelnen* missverständlich, *gemeinsam* erklären sie die disproportionale Defensivmedizin.

Die Kommunikationsasymmetrie: Beide Seiten sagen die Wahrheit — über verschiedene Messgrößen. Die „unter 1 %“-Zahl (Virchowbund: 0,065 %, basierend auf <100 rechtskräftigen Regressen bundesweit 2018 bei 155.000 Vertragsärzten) misst *ausschließlich V1-Regresse* — der Virchowbund selbst sagt, statistische Auffälligkeitsprüfungen „spielen kaum noch eine Rolle“. Die KV BaWü-Zahl (0,097 %) misst V1+V2, aber nur *rechtskräftig durchgesetzte* Regresse. In beiden Fällen fehlen die **V2-Vergleiche** — geschätzt 70–80 % der betroffenen Ärzte zahlen, ohne dass ein „Regress“ in der Statistik erscheint.

Der Arzt misst seine *Berufslaufbahn*: Wie oft war ich in 20 Jahren mit einem V2-Verfahren konfrontiert? Bei ~0,9 Anträgen pro Arzt und Jahr (KV Nordrhein) und 95 % Durchsetzungsquote: mehrfach. Es ist kein Widerspruch — es ist eine systematische Perspektivdivergenz, bei der die beruhigende Zahl immer die öffentlich kommunizierte ist und die belastende Zahl in keiner Statistik auftaucht.

Bundesweit: 2022 gab es ca. 47.000 Wirtschaftlichkeitsprüfungen bei niedergelassenen Ärzten (BMG GVSG-Referentenentwurf 2024). Bei ca. 155.000 Vertragsärzten entspricht das einer Rate von ca. 30 % pro Jahr — wobei der Großteil Kleinbetragsprüfungen betrifft. **Regionale Bestätigung:** Der SpiFa meldet für Bayern 13.332 festgesetzte Regresse (2024) bei ~24.000 Vertragsärzten — Durchschnittsbetrag 334 EUR, ~70 % davon Bagatellregresse unter 300 EUR (SpiFa 2024).¹ Die bayerische Rate (max. 55 %

¹Der arithmetische **Mittelwert** von 334 EUR ist für die Verteilung nur eingeschränkt aussagekräftig. Da ~70 % der Regresse unterhalb von 300 EUR liegen und einzelne hohe Regresse (vier- bis fünfstellig) den Mittelwert nach oben ziehen, ist die Verteilung *rechtsschief* und lässt sich plausibel als Lognormal-Verteilung modellieren. Der **Median** dürfte deutlich unter dem Mittelwert liegen — plausible Schätzung: 100–200 EUR (auf Basis der 70 %-unter-300-EUR-Angabe und der SpiFa-Beschreibung der Bagatell Dominanz). Für die Lastbewertung ist der Median aussagekräftiger als der Mittelwert (typische Belastung eines typischen Regresses); für die Systemlast insgesamt bleibt der Mittelwert relevant (Summenvolumen). Beide Lageparameter sollten getrennt gelesen werden; eine präzisere Angabe würde Verteilungs-Rohdaten des SpiFa voraussetzen (Freigabe ausstehend).

bei Einzelzählung, ~28 % bei Zwei-pro-Arzt-Bündelung) konvergiert mit dem Bundesschnitt und dem Poisson-Modell.

Die empirisch belegbaren Werte:

- **Offizielle Regressdurchsetzungsquote** ($P_{\text{offiziell}}$, V1+V2 zusammen): unter 1 %, je nach KV-Bezirk 0,065–0,8 %
- **Tatsächliche Regresserfahrung** (P_{erfahren} , Ribbat 2023): **72 % der Hausärzte** haben mindestens einmal einen Regress erlebt (V1+V2 zusammen; keine Verfahrenstrennung)
- **Wahrgenommenes Risiko** ($P_{\text{perceived}}$): rund 15 % (KBV-Berufsmonitoring zeigt 50 % der Studierenden mit Niederlassungsangst)

Die Diskrepanz liegt nicht zwischen Wahrnehmung und Realität, sondern zwischen offizieller Statistik und tatsächlicher Erfahrung. Der frühere Wahrnehmungsfaktor von ca. 50:1 ($P_{\text{perceived}} / P_{\text{offiziell}}$) suggerierte, Ärzte überschätzten ihr Risiko dramatisch. Ribbats 72 % zeigen: Die ärztliche Wahrnehmung ist näher an der Realität als die offizielle Statistik. Die Erklärung: Die offizielle "unter 1 %"-Zahl misst nur *rechtskräftig durchgesetzte* Regresse (Schritt 9), nicht die Gesamtheit der Verfahren, Anhörungen, Vergleiche und psychischen Belastungen. Beide Größen — die offizielle Quote und die Ribbat-Erfahrungsraten — sind V1+V2 zusammen; eine verfahrensgetrennte Messung existiert nicht. Die Angst ist berechtigt — sie bezieht sich auf die Verfahrenserfahrung, nicht auf den Geldfluss.

Mit der Verlustaversionskonstanten von Kahneman/Tversky ($\lambda \approx 2,25$) ergibt sich zusätzlich ein verstärkter gefühlter Erwartungswert. Der Arzt entscheidet nicht unter falschen Annahmen, sondern unter Berücksichtigung einer Verfahrensrealität, die in der offiziellen Statistik systematisch untererfasst ist.

4.4.2 Defensive Unter-Verordnung als Nash-Gleichgewicht

Bei $P_{\text{perceived}} \approx 0,15$ wird "nicht verordnen" für den Arzt zur dominanten Strategie. Bei $P_{\text{real}} \approx 0,003$ wäre "verordnen" dominant. Die Schwelle, an der die Strategie kippt, ist mathematisch berechenbar — und sie liegt deutlich unter der wahrgenommenen Risikoschwelle.

Das Ergebnis ist ein **Pareto-suboptimales Nash-Gleichgewicht**:

- Arzt verliert (ethischer Stress, defensive Mehrarbeit, dokumentationslastige Prozesse)
- Patient verliert (Unterversorgung, vermeidbare Folgeschäden)
- Krankenkasse gewinnt nichts (das nicht verordnete Medikament wird ohnehin nicht verordnet, sie zahlt nichts ein, aber sie zahlt später die Hospitalisierung)
- System verliert die in Teil IV bezifferten Folgekosten

Niemand will dieses Gleichgewicht. Alle spielen es individuell rational.

4.4.3 Das Solidaritäts-Gefangenendilemma

Das zweite zentrale Spiel ist nicht das Verordnungsspiel selbst, sondern das Spiel *daneben*: das Solidaritäts-Spiel innerhalb der Ärzteschaft. Zwei Ärzte könnten gemeinsam öffentlich für leitliniengerechte Verordnung kämpfen, koordinierte Beschwerden einreichen, gemeinsam Pressearbeit machen. Jeder einzelne hat aber den Anreiz, still zu bleiben und sich selbst zu schützen.

- Wer öffentlich kämpft, wird zur Zielscheibe künftiger Prüfverfahren
- Wer schweigt, profitiert vom Erfolg anderer (Trittbrettfahrer in der Solidaritäts-Allmende)

Das Ergebnis: Berufsverbände sind politisch schwach, individuelle Erfahrungen bleiben anekdotisch, statt aggregiert zu werden. Genau diese Aggregation wäre die Bedingung für eine kollektive Verteidigungsfront — und sie findet aus rationalen individuellen Gründen nicht statt.

4.4.4 Multi-Principal-Agent-Problem

Auf einer dritten Ebene liegt eine klassische Principal-Agent-Konfiguration mit drei überlagerten Schichten:

- Schicht 1: **Patient** → **Arzt** — der Patient erwartet Versorgung

- Schicht 2: **Krankenkasse** → **Arzt** — die Kasse erwartet wirtschaftliches Verordnen
- Schicht 3: **Versicherter** → **Krankenkasse** — der Versicherte erwartet, dass die Kasse seine Versorgung organisiert

Das systemische Problem: **Schicht 2 dominiert das Verhalten des Arztes, Schicht 3 ist faktisch inaktiv.** Der Versicherte hat keinen direkten Einfluss darauf, wie aggressiv „seine“ Kasse Regresse beantragt. Der Patient erlebt nur die Konsequenz (Unterversorgung), nicht die Ursache (Antragsdruck der Kasse). Die Kette ist gebrochen.

4.4.5 Die spieltheoretisch wirksamste Intervention

Der mathematische Befund liefert eine klare Empfehlung: **Reduktion der asymmetrischen Information ist die wirkungsmächtigste Einzelintervention.** Sobald Ärzte ihr reales Regressrisiko statt ihres empfundenen Risikos kalibrieren können, verschiebt sich das Verordnungsspiel automatisch vom defensiven zum kooperativen Gleichgewicht. Das ist eine echte Pareto-Verbesserung: Patient gewinnt, Arzt gewinnt, System gewinnt; die Kasse verliert nur ihre Abschreckungs-Rente, nicht ihre tatsächlichen Regress-Einnahmen.

Information schlägt Reform — weil Reform der Information folgt, nicht umgekehrt.

Genau auf diese Funktion zielt das Regress-Transparenzportal in PP-003. **Eine verfahrensgetrennte Erhebung (V1 vs. V2) wäre dabei das wirksamste Korrektiv für das bisherige Narrativ:** Sollte PP-003 zeigen, dass die V2-Regressdurchsetzungsquote deutlich über der offiziellen V1+V2-Mischquote liegt, würde das die Risikokalibrierung der Ärzte rückwirkend als realistischer erweisen — und die Dringlichkeit gesetzlicher Korrekturen erhöhen. Die fehlende Verfahrenstrennung in den offiziellen Statistiken ist daher nicht nur ein methodisches Problem, sondern ein politisches: Sie verhindert die Identifikation des asymmetrischeren Verfahrens (V2) als eigenständiges Regulierungsproblem.

4.4.6 Regelkreisanalyse: Nur Minus-Signale

Aus steuerungstechnischer Perspektive weist das Prüfsystem einen fundamentalen Konstruktionsfehler auf: Es enthält ausschließlich negative Rückkopplungssignale (Sanktionen bei Verstößen), aber keine positiven (Belohnung oder Bestätigung bei korrektem Verhalten).

Signaltyp	Beispiel im Regresssystem	Beispiel in einem balancierten System
Minus-Signal (Sanktion)	Regress, Auffälligkeitsmeldung, Vergleichszahlung	Konventionalstrafe
Plus-Signal (Bestätigung)	<i>existiert nicht</i>	Prämie für leitliniengerechte Versorgung, positives Prüfergebnis
Null-Signal (neutral)	Keine Prüfung = kein Feedback	Keine Prüfung = kein Feedback

Ein Regelkreis, der nur Minus-Signale sendet, erzeugt systemtheoretisch vorhersagbar ein Übervorsichtiges Gleichgewicht: Das System bestraft Abweichung, belohnt aber Konformität nicht. Der Arzt erhält nie die Rückmeldung „Ihre Verordnungspraxis ist medizinisch angemessen“ — er erfährt nur „Sie wurden nicht bestraft“. Die Abwesenheit von Bestrafung ist kein positives Signal. Sie ist ein Null-Signal, das der Arzt nicht von Glück unterscheiden kann.

4.4.7 Asymmetrische Sanktionsstruktur ohne Gegengratifikation

Die bisherige Analyse fokussiert auf einen Sanktionskanal — den wirtschaftsbezogenen Regress der Krankenkassen. Dieser Fokus greift zu kurz. Der niedergelassene Arzt steht strukturell unter einem **bidi-rektionalen Sanktionsdruck**, dem auf der positiven Seite *kein* institutionelles Äquivalent gegenübersteht. Diese Konfiguration ist der eigentliche Kern der institutionellen Schieflage.

Sanktionskanal A — wirtschaftliche Übernutzung (Kassenrichtung). Wird eine Verordnung als unwirtschaftlich eingestuft, droht Regress (§ 106, § 106b SGB V), bei Formfehlern Einzelfallregress (§ 48

BMV-Ä), in schweren Fällen Disziplinarverfahren durch die KV (§ 81 Abs. 5 SGB V), bei wiederholten Verstößen Zulassungsentzug (§ 95 Abs. 6 SGB V). Diese Sanktionen greifen, wenn der Arzt *zu viel, zu teuer oder außerhalb der Indikation* verordnet.

Sanktionskanal B — medizinische Unterversorgung (Patientenrichtung). Unterlässt der Arzt eine medizinisch indizierte Leistung oder verzögert sie, greifen zivilrechtliche Ansprüche aus dem Behandlungsvertrag (§§ 630a ff., 280 Abs. 1, 823 BGB), gegebenenfalls strafrechtliche Haftung (§§ 223, 229 StGB), Verfahren vor den Gutachterkommissionen und Schlichtungsstellen der Ärztekammern sowie berufsrechtliche Maßnahmen bis hin zum Approbationsentzug (§ 5 BÄO). Bundesweit bearbeiten die Gutachterkommissionen und Schlichtungsstellen jährlich rund 12.000 Arzthaftungsverfahren, mit einer Bestätigungsquote kausaler Behandlungsfehler von etwa 24–25 % [4]. Parallel begutachtet der Medizinische Dienst jährlich rund 14.000 Fälle [5]. Diese Sanktionen greifen, wenn der Arzt *zu wenig, zu spät oder zu zurückhaltend* verordnet.

Der Arzt steht damit zwischen zwei rechtlich bewehrten Fehlerkonten: Das eine führt die Kasse, das andere der Patient. Beide Konten kennen nur Minusbuchungen. Es gibt kein institutionelles Konto, auf dem leitliniengerechte, maßvolle, evidenzbasierte Versorgung *positiv* gutgeschrieben würde.

Die fehlende Gegengratifikation. Das deutsche Vertragsarztsystem kennt keinen formalisierten Belohnungsmechanismus für evidenzbasiertes Ordnungsverhalten. Es existiert keine öffentliche Anerkennung, keine Prämie, kein Unauffälligkeitssertifikat, keine formale Bestätigung für langjährig regelkonformes Verhalten. Auch fachliche Empfehlungsinitiativen wie die DGIM-Kampagne „Klug entscheiden“ [6] oder die DEGAM-S2e-Leitlinie zu Überversorgung [7] liefern ausschließlich normative Empfehlungen — ohne institutionelle Rückkopplung an Honorar, Prüfstatus oder öffentliche Anerkennung. Das gilt analog für die internationale *Choosing-Wisely*-Initiative und vergleichbare Low-Value-Care-Programme: Systematische Reviews zeigen, dass Dissemination und Empfehlungen allein — ohne strukturelle Verankerung in Vergütung, Audit oder Workflow — Ordnungsverhalten nicht messbar verändern [8, 9].

Der internationale Vergleich illustriert den Kontrast mit einem positiven Rückkopplungssystem. Der britische *Quality and Outcomes Framework* (QOF), seit 2004 im NHS etabliert, honoriert leitliniengerechte Versorgung mit rund 25 % des Praxishonorars [10, 11]. Systematische Reviews belegen moderate Verbesserungen in Diabetes- und SMI-Care, dokumentieren aber auch *unintended consequences* (Gaming, Exklusionen, Fokusverengung) [12, 13]. Die methodische Debatte — unter anderem formalisiert im McGuire-Pauly-Modell der Multi-Payer-Agentur [14] — ist in dieser Studie nicht zu entscheiden. Entscheidend ist die *strukturelle* Differenz: Ein positives Rückkopplungssignal existiert, es wird evaluiert, es wird diskutiert. Das deutsche System kennt diese Diskussion auf operativer Ebene nicht, weil der Mechanismus gar nicht existiert.

Konsequenz für das Anreizfeld. Die Kombination aus bidirektionalem Sanktionsdruck und einseitig negativer Rückkopplung erzeugt eine Anreizstruktur, in der der Arzt rational zwei Ziele simultan verfolgt: (1) Minimierung der Regressexposition, (2) Minimierung der Haftungsexposition. Beide Ziele lassen sich nur über Risikoreduktion erreichen — entweder durch Überweisung, Vermeidung oder übervorsichtige Dokumentation. Der *dritte* rationale Modus — maximale medizinische Qualität als eigenständiges Ziel — bleibt ökonomisch unbelohnt. Zu den Besten zu gehören bringt dem Arzt im deutschen System keinen institutionellen Gewinn, der über die Abwesenheit von Sanktion hinausginge. Der rationale Arzt minimiert Exposition; er maximiert nicht Qualität.

Das erklärt, warum die in Teil III dokumentierten Verhaltensanpassungen (Quartalsende-Verschiebung, Überweisung statt Behandlung, Ordnungsverzicht) in einem anreiztheoretisch konsistenten Bild stehen: Sie sind nicht Ausdruck mangelnder Professionalität, sondern die erwartbare Antwort auf ein Anreizfeld, das Fehler teuer, Exzellenz aber unbelohnt lässt. Der Lösungsraum in Teil VII greift diesen Befund auf (Rang 4 des KNV-Katalogs: positive Rückkopplung als struktureller Hebel).

4.5 Der Modellarzt

Aus den verfügbaren empirischen Daten lässt sich ein konkretes Profil des regress-ängstlichen Modellarzts ableiten. Es ist keine Konstruktion, sondern die Verdichtung der dokumentierten Befunde.

4.5.1 Profil

Mittleres Lebensalter (ca. 50 Jahre), Hausarzt in westdeutscher Mittelstadt, seit etwa 18 Jahren in Einzelpraxis, eine MFA, rund 1.100 Scheine pro Quartal, hoher Anteil multimorbider Patienten. Hat bereits ein bis drei Auffälligkeitsmeldungen der KV erlebt.

Wichtig: Die statistisch belegten Prädiktoren der Regressangst sind *nicht* Alter, Berufserfahrung oder Praxisstruktur (Goetz et al. 2024 zeigen explizit: nicht signifikant). Prädiktiv sind:

- Wunsch nach rechtlicher Selbstabsicherung ($\beta = 0,338$)
- Antizipierte Klagewahrscheinlichkeit ($\beta = 0,250$)
- Geschlecht (Frauen ängstlicher, $\beta = -0,158$)

Die Angst ist also strukturell, nicht biografisch. Sie entsteht aus dem Spielfeld, nicht aus den Spielern. Strukturell exponiert sind neben Hausärzten besonders Onkologen, Diabetologen, Schmerzmediziner und Neurologen.

4.5.2 Die dokumentierten Verhaltensanpassungen

Was tut der Modellarzt anders? Die folgenden Verhaltensweisen sind alle empirisch belegt:

- **Quartalsende-Verschiebung** teurer Verordnungen (Himmel/Schneider 2017, HCHE Research Paper No. 2017/14, TK-Daten: bis 14 % weniger Termine, +19 Prozentpunkte Notdienstbelastung)
- **Überweisung statt Behandlung** (Ribbat 2023: 51 % der Hausärzte schieben weiter, obwohl sie selbst behandeln könnten)
- **Verordnungsverzicht** im Lauf der Karriere (Ribbat 2023: 85 % der Hausärzte haben mindestens einmal aus Regressangst eine Verordnung unterlassen)
- **Defensive Diagnostik** (Goetz 2024: 54 % wöchentlich unnötige Labortests)
- **Off-Label-Vermeidung** trotz medizinischer Indikation
- **Heilmittel-Drosselung** (Reha-Verzögerung)
- **Patientenselektion** gegen multimorbide Patienten
- **Verlagerung in den stationären Sektor** (treibt die deutsche ACSC-Hospitalisierungsrate)
- **Niederlassungsverzicht** (KBV-Berufsmonitoring: 50 % der Studierenden nennen Regress als Hindernis)

4.5.3 Hochrechnung auf die Makro-Ebene

Bei **155.678 Vertragsärzten** (KBV 2025, ohne Psychotherapeuten), 40 % betroffenen Ärzten (Mittelwert aus Ribbat-Befragungswerten für Hausärzte und Orthopäden), 20 unterlassenen Verordnungen pro Arzt und Jahr und konservativen Folgeannahmen ergibt sich ein direkt zurechenbares Schadensvolumen von etwa **200 Mio. EUR/Jahr** aus den Verhaltensanpassungen allein.

Rechnet man den plausiblen Regressangst-Anteil an den vermeidbaren ACSC-Folgekosten (7-8 Mrd. EUR/Jahr WldO/Zi) und Non-Adhärenz-Folgekosten (10-19 Mrd. EUR DIMDI HTA 65) mit konservativen 5 % dazu, liegt die Gesamtspanne bei **0,9-1,7 Mrd. EUR/Jahr**.

Unter diesen Szenario-Annahmen (mittleres Modell) wären ca. **6.230 vermeidbare Hospitalisierungen** und ca. **125 Todesfälle pro Jahr** anteilig mit Regressangst-induzierter Unterversorgung assoziiert. **Wichtige Einschränkung:** Diese Zahlen sind ein illustratives Gedankenexperiment auf Basis der Szenario-Annahmen, kein kausalanalytisch abgesicherter Befund. Die tatsächliche Mortalitätslast ist ohne eine eigenständige epidemiologische Studie nicht bestimmbar.

Der gesamtsystemische Rahmen liegt bei rund 15.000–20.000 vermeidbaren Todesfällen pro Jahr in Deutschland (Schätzungen aus verschiedenen Quellen, u. a. Sepsis-Memorandum der Leopoldina/Fachgesellschaften; Quelle für v1.0 zu präzisieren), von denen nur ein Teil regress-kausal ist. Die hier vorgenommene Hochrechnung ist absichtlich konservativ.

4.5.4 Methodische Einschränkungen und Sensitivitätsanalyse

Die Hochrechnung beruht auf Szenario-Annahmen, nicht auf empirisch gemessenen Parametern. Insbesondere die Attributionsrate (Anteil regress-kausal an Folgekosten) und die Frequenz unterlassener Verordnungen sind Modell-Annahmen — keine der derzeit verfügbaren Studien misst diese Größen direkt. Die Spanne der Szenarien soll die Größenordnung des möglichen Schadens illustrieren, nicht einen Punktschätzer liefern. Drei Schlüsselparameter bestimmen die Bandbreite:

Parameter	Konservativ	Mittel	Pessimistisch
Anteil betroffener Ärzte (Ribbat 2023)	27 % (Goetz: starke Rechtsangst)	40 % (Mittelwert HA/Ortho)	75,8 % (Zheng global)
Unterlassene Verordnungen pro Arzt/Jahr	5	20	50
Anteil regress-kausal an Folgekosten	2 %	5 %	15 %
Direkt zurechenbar	ca. 25 Mio. EUR	ca. 200 Mio. EUR	ca. 1,4 Mrd. EUR
Plus anteilige Folgekosten	ca. 0,4 Mrd. EUR	ca. 0,9 Mrd. EUR	ca. 4,2 Mrd. EUR
Vermeidbare Hospitalisierungen/Jahr	~2.500	~6.230	~23.600
Vermeidbare Todesfälle/Jahr	~50	~125	~472

Lesehinweis: Die Bandbreite zeigt, dass selbst unter sehr konservativen Annahmen erhebliche Schadensvolumen plausibel sind. Im mittleren Szenario liegen die direkten plus anteiligen Kosten bei rund **1,1 Mrd. EUR/Jahr** (200 Mio. direkt + 0,9 Mrd. anteilig). Der in Teil IV eingeführte Wert von 7–17 Mrd. EUR ist der *Systemrahmen* der assoziierten ACSC- und Non-Adhärenz-Folgekosten vor Attribution — der Nenner, aus dem durch Multiplikation mit der Attributionsrate die Regress-Folgekosten berechnet werden.

Die Modellrechnung ersetzt keine kausalanalytische Studie. Sie zeigt nur, dass die Größenordnung des Schadens unter plausiblen Annahmen die Größenordnung der Einnahmen um ein Vielfaches übertrifft.

Eine systematische Prüfung durch eine zuständige Stelle (BRH, SVR, IGES, Versorgungsforschungsinstitute) hat bisher nicht stattgefunden. Auch das ist ein Befund.

4.6 Der Arzt als Street-Level Bureaucrat

Die bisherigen Teile dieser Studie haben das Verhalten der Ärzte primär über verhaltensökonomische Kategorien erklärt: Verlustaversion nach Kahneman/Tversky, asymmetrische Information, Nash-Gleichgewicht. Diese Erklärung ist mathematisch elegant, aber sie reicht nicht aus. Sie beschreibt, *warum* der einzelne Arzt eine bestimmte Entscheidung trifft, nicht *was für einen Akteur er dabei ist*. Eine präzisere Einordnung liefert die Verwaltungswissenschaft, namentlich Michael Lipskys Theorie der Street-Level Bureaucracy.

4.6.1 Lipskys Grundmodell

In seinem Standardwerk *Street-Level Bureaucracy: Dilemmas of the Individual in Public Services* (Russell Sage Foundation, 1980; erweiterte Neuauflage 2010) definiert Lipsky die sogenannten **Street-Level Bureaucrats** (SLB) als Akteure an der äußersten Frontlinie staatlicher oder quasi-staatlicher Leistungserbringung: Lehrer, Polizisten, Sozialarbeiter, Sachbearbeiter — und im öffentlich finanzierten Gesundheitssystem auch Ärzte. Sie teilen drei Merkmale:

- **Direkter Kontakt** zu den Bürgern/Patienten
- **Erheblicher Ermessensspielraum** in der Einzelfallentscheidung
- **Unauflösbare Zwangslagen** durch widersprüchliche oder überbordende politische und juristische Vorgaben bei begrenzten Ressourcen

Das fundamentale Dilemma der SLB ist, dass die Nachfrage nach ihren Leistungen systematisch die verfügbaren Ressourcen übersteigt und sie gleichzeitig mit inkonsistenten Vorgaben konfrontiert sind. Sie können die formalen Anforderungen ihres Systems prinzipiell nicht alle gleichzeitig erfüllen — also entwickeln sie zwangsläufig **Coping-Mechanismen**.

Der deutsche Vertragsarzt passt präzise in dieses Modell: § 12 SGB V verlangt, dass ärztliche Leistungen *ausreichend, zweckmäßig und wirtschaftlich* sein müssen, das *Maß des Notwendigen nicht überschreiten* dürfen, und gleichzeitig leitliniengerecht zu erfolgen haben. Diese Anforderungen sind in der täglichen Praxis nicht simultan erfüllbar (siehe Drei-Code-Kollision in Teil II). Der Arzt muss diesen Widerspruch im Minuten-Takt operationalisieren, während im Hintergrund das Risiko der Regressierung besteht.

4.6.2 Lipskys Coping-Typologie, angewandt auf den Modellarzt

Die von Lipsky identifizierten Coping-Strategien mappen erstaunlich präzise auf die bereits dokumentierten Verhaltensanpassungen des Modellarzts (siehe voriger Unterabschnitt):

Coping-Mechanismus (Lipsky)	Manifestation im SGB V-Kontext	Empirischer Beleg
Rationing (implizite Rationierung)	Zurückhaltung teurer, aber indizierter Medikamente; Off-Label-Vermeidung trotz medizinischer Rechtfertigung	Ribbat 2023, 85 % unterlassene Verordnungen
Referral / Outsourcing (Abwälzen)	51 % der Hausärzte überweisen an Spezialisten, obwohl sie selbst behandeln könnten	Ribbat 2023
Creaming / Cherry-Picking (Selektion)	Vermeidung multimorbider Patienten, die das Budget überdurchschnittlich belasten	Verhaltensmuster im Modellarztprofil
Routinization (Standardisierung)	Strikte Adhärenz an Leitlinien, Vermeidung individualisierter Therapiepfade	Goetz 2024, defensive Laborroutine
Limiting Engagement (Rückzug)	Quartalsende-Verschiebung, reduzierte Patientenbindung, Niederlassungsverzicht	HCHE-Kifmann, KBV-Berufsmonitoring

Diese Mapping-Tabelle ist der analytisch zentrale Punkt dieses Teils. Die Defensivmedizin des deutschen Vertragsarzts ist damit nicht mehr eine affektive Randerscheinung oder ein bedauerlicher „Betriebsunfall“ des Systems, der sich durch Aufklärung beheben ließe. **Sie ist der klassische, lehrbuchmäßige Bewältigungsmechanismus einer Frontlinien-Rolle in einem Ressourcen- und Widerspruchskonflikt.**

4.6.3 Die politisch-analytische Konsequenz

Wer Lipsky anwendet, kommt zu einer politisch unbequemen Schlussfolgerung, die über die Diagnose „Angstsystem“ deutlich hinausgeht: Der Vertragsarzt ist nicht nur ein passives Opfer der GKV-Bürokratie. Er ist vielmehr *das ausführende Organ einer impliziten, politisch nicht kodifizierten Ressourcensteuerung*. Indem er durch defensive Unterversorgung, Referral-Kaskaden und Routinization das System entlastet, übernimmt er eine Rationierungsfunktion, die der Gesetzgeber selbst nicht offen kodifizieren würde — und die in dieser Form auch nie offen beschlossen wurde.

Das ist die präzisere Formulierung der in Teil IV entwickelten Folgekosten-These: Der Arzt „zahlt“ nicht nur mit seiner Zeit, seiner Versicherungsprämie und seinem Stresslevel für das System. Er zahlt mit seiner Berufsethik, indem er gezwungen wird, Entscheidungen zu treffen, deren Rationierungswirkung das System produziert, aber deren moralische Last allein bei ihm liegt. Das ist die eigentliche Pointe der Lipsky-Analyse: *Staatliche Ressourcenknappheit wird an der Street-Level nicht nur umgesetzt — sie wird dort auf den Schultern einzelner Frontlinien-Akteure abgeladen.*

5 Teil IV — Die Folgekosten: Wenn das System mehr schadet als es spart

5.1 Die direkten Patientenschäden

Die Verhaltensänderungen aus Teil III führen zu konkreten Patientenschäden. Die wichtigsten dokumentierten Wirkmechanismen:

- **Quartalsende-Effekt:** Die HCHE-Kifmann-Studie (Hamburg Center for Health Economics, TK-Daten 2013/14) dokumentiert bis zu 14 % weniger Termine am Quartalsende und einen Anstieg der Notdienst-Belastung um 19 Prozentpunkte.
- **Überweisungskaskade:** 51 % der Hausärzte überweisen trotz Indikation an Spezialisten (Ribbat 2023). Dies erzeugt Wartezeiten, Mehrkosten und Versorgungsverzögerungen, ohne dass das Risiko gesamtsystemisch gemindert wird.
- **Off-Label-Vermeidung in der Onkologie:** Bis zu 60 % der Krebspatienten in der Regelversorgung werden off-label behandelt, weil die Wissenschaft schneller ist als die Zulassung. Trotz BSG-Rechtsprechung zur Zulässigkeit unter bestimmten Bedingungen regressierten Krankenkassen Onkologen für Standardtherapien (DGHO-Stellungnahme 2006, 2024).
- **GLP-1 bei Diabetes mit Leberzirrhose:** Dokumentierter Fall, in dem ein Patient nach Aussetzung der leitliniengerechten Tirzepatid-Therapie auf Insulin umgestellt wurde — ein Medikament, das die Grunderkrankung verschlimmert.
- **Vermeidbare Hospitalisierungen:** OECD Health at a Glance 2025 dokumentiert für Deutschland 810 vermeidbare Hospitalisierungen pro 100.000 Einwohner gegenüber einem OECD-Mittel von 473 (+70 %).

5.2 Die volkswirtschaftliche Hochrechnung

Die direkten und indirekten Folgekosten der regress-induzierten Unterversorgung lassen sich konservativ und verifizierbar abschätzen:

Kostenbestandteil	Wert (Bandbreite)	Quelle
Vermeidbare stationäre Aufnahmen	7-8 Mrd. EUR/Jahr	WIdO Krankenhaus-Report 2016, Zi 2021
Non-Adhärenz / Therapieabbrüche	10-19 Mrd. EUR/Jahr	DIMDI HTA 65, ABDA
Vermeidbare Todesfälle (Versorgungsdefizite)	ca. 20.000/Jahr	Monitor Versorgungsforschung 02/2025
US-Defensivmedizin (proportional auf DE)	6-25 Mrd. EUR/Jahr	Mello et al. 2010 (Health Affairs), eigene Hochrechnung

Systemrahmen der assoziierten Folgekosten (Nenner, vor Attribution): 7–17 Mrd. EUR pro Jahr (ACSC-Hospitalisierungen + Non-Adhärenz-Kosten; Quelle: WIdO/Zi, DIMDI HTA 65). Dies ist der Nenner der Zurechnungsrechnung — nicht die regressangst-attributierte Schätzung selbst. Das Dreistufenmodell: *Systemrahmen* (7–17 Mrd.) × *Attributionsrate* (5 %–15 %) = *Regress-Folgekosten* (0,9–4,2 Mrd./Jahr). Im mittleren Szenario (5 %, inkl. direkter Verhaltenskosten) ergibt sich **0,9–1,7 Mrd. EUR/Jahr** (siehe Sensitivitätsanalyse oben).

5.3 Die Verhältnisrechnung: Schaden zu Einnahme

Wieviel nimmt das System ein, wieviel kostet es?

Position	Wert/Jahr	Quelle
Durchgesetzte Regresse (konservativ)	ca. 5 Mio. EUR	KV-Statistiken, Hochrechnung
Durchgesetzte Regresse (großzügig)	niedrige zweistellige Mio. EUR	GKV-SV 2022 (MD-stat.)
Bürokratiekosten ambulant (gesamt)	4,33 Mrd. EUR	Statistisches Bundesamt
Regress-Folgekosten (5 % attribuiert, eigene Hochrechnung)*	0,9–1,7 Mrd. EUR	eigene Hochrechnung

* *Szenario-Annahme, keine kausale Messung.* Der Kausalschluss “Prüfdruck → Unterversorgung → Folgekosten” ist nicht empirisch geschlossen. Die Zahl ist ein illustratives Modell auf Basis einer unbewiesenen Attributionsannahme (5 %).

Szenario-Verhältnis Schaden zu Einnahme (unter den genannten Modellannahmen): ca. 100:1 bis 1.000:1. Unter diesen Annahmen wäre selbst die großzügigste Schätzung der durchgesetzten Regresse um zwei bis drei Größenordnungen kleiner als der modellierte Schaden.

Methodische Einschränkung: Diese Verhältnisrechnung beruht auf Hochrechnungen mit offenen Annahmen. Die Bandbreite ist absichtlich weit, weil keine deutsche Punktschätzung der durch Regressangst kausal induzierten Folgekosten existiert. Auch die konservativste Schätzung deutet jedoch darauf hin, dass die durchgesetzten Regresse die Folgekosten nicht aufwiegen. Eine systematische Prüfung dieses Verhältnisses durch eine zuständige Stelle (BRH, SVR, IGES) hat bisher nicht stattgefunden — siehe Teil V.

Unvollständiger Nenner: Die Verhältnisrechnung setzt den modellierten Schaden ins Verhältnis zu den *durchgesetzten Regressen* (5–50 Mio. EUR). Das unterschlägt den potenziellen Nutzen des Systems: die Abschreckungswirkung, d. h. Mehrausgaben, die durch die bloße Existenz des Prüfsystems vermieden werden. Diese Abschreckungswirkung ist real (Einwand 3, Abschnitt 9), aber nicht quantifiziert. Eine vollständige Kosten-Nutzen-Analyse müsste die verhinderten Mehrausgaben im Nenner berücksichtigen. Da diese Größe nicht verfügbar ist, bildet die 100:1-Zahl den *worst case* für das System ab, nicht den Erwartungswert.

Vergleichsfolie zu akzeptierten gesundheitsökonomischen Modellrechnungen: Die hier verwendete Methodik entspricht dem Standard gesundheitsökonomischer Hochrechnungen mit transparenten Annahmen. Vergleichbare Studien:

- Mello et al. (Health Affairs 2010, “National Costs of the Medical Liability System”) schätzen die US-Defensivmedizin-Kosten auf 45,6 Mrd. USD/Jahr — mit Bandbreite und expliziten Sensitivitätsannahmen
- Effertz et al. (European J of Health Economics 2016) berechnen die volkswirtschaftlichen Kosten der Adipositas in Deutschland mit ähnlicher Methodik
- DIMDI HTA-Bericht 65 zur Non-Adhärenz arbeitet mit Bandbreiten zwischen 10 und 19 Mrd. EUR/Jahr

Die hier verwendete konservative Hochrechnung ist methodisch nicht ambitionierter als diese etablierten Modelle und liegt in ihren Bandbreiten in einer vergleichbaren Größenordnung. Die Modellrechnung ist also weder spekulativ noch überambitioniert — sie wendet etablierte Methodik auf einen bisher nicht rechtsförmig untersuchten Gegenstand an.

5.4 Vergleich mit anderen großen Kostentreibern

Zum Vergleich mit anderen großen gesellschaftlichen Kostentreibern (Systemrahmen ACSC + Non-Adhärenz = 7–17 Mrd.; attribuierte Regress-Folgekosten konservativ = 0,9–1,7 Mrd.; * = Szenario-Annahme):

Schadensquelle	Volkswirtschaftliche Kosten/Jahr (DE)
Rauchen	ca. 79 Mrd. EUR
Adipositas	ca. 63 Mrd. EUR
Alkohol	ca. 57 Mrd. EUR
Non-Adhärenz	10-19 Mrd. EUR
Systemrahmen Regress-assoziiert (ACSC + Non-Adh., vor Attr.)	7–17 Mrd. EUR
Davon attributierbar (5 %, konservativ)*	0,9–1,7 Mrd. EUR
Krankenhauskeime	4-12 Mrd. EUR
Bürokratie ambulant	2,4-4,33 Mrd. EUR

Drei Vergleichsanker (Systemrahmen 7–17 Mrd.; attributierte Regress-Folgekosten konservativ 0,9–1,7 Mrd.):

- Das Schaden-zu-Einnahme-Verhältnis ist selbst im konservativen Attributionsszenario (1,1 Mrd.) noch schlechter als bei Alkohol (Verhältnis Schaden zu Steuer: 18:1) — und produziert keinen “Konsumnutzen”.
- Der Systemrahmen der regress-assoziierten Folgekosten (7–17 Mrd.) ist 17- bis 42-fach größer als das KBV-Bürokratie-Einsparpotenzial (400 Mio. EUR/Jahr). Die KV administriert das System, das ihre eigenen Mitglieder so massiv belastet. Selbst die konservative Attributionsschätzung (0,9–1,7 Mrd.) ist noch 2- bis 4-fach größer als das Einsparpotenzial.
- Der Systemrahmen ist größenordnungsmäßig vergleichbar mit den Kosten aller Krankenhauskeime Deutschlands zusammen (4–12 Mrd.) — bei einem Bruchteil der politischen, medialen und wissenschaftlichen Aufmerksamkeit. Für Krankenhauskeime existieren das RKI-KRINKO, Hygieneverordnungen und Awareness-Kampagnen. Für Regress: Schweigen.

5.5 Administrative Burden als “Policymaking by Other Means”

Die Größenordnungen aus dem vorigen Unterabschnitt — 4,33 Mrd. EUR jährliche Bürokratiekosten im ambulanten Sektor, ca. 61 Arbeitstage pro Vertragsarzt und Jahr allein für Verwaltung, rund 16.000 terminale ICD-10-Codes — werden in der deutschen Debatte üblicherweise als Ineffizienz, schlechtes Gesetzeshandwerk oder als “wuchernde Bürokratie” interpretiert. Diese Lesart greift zu kurz. Die US-amerikanische Policy-Forschung liefert seit einigen Jahren einen wesentlich schärferen analytischen Rahmen: die Theorie der **Administrative Burden**.

5.5.1 Herd & Moynihan: Bürokratie als Politikgestaltung

In ihrem Standardwerk *Administrative Burden: Policymaking by Other Means* (Russell Sage Foundation, New York 2018 — ausgezeichnet unter anderem mit dem Louis Brownlow Book Award 2019 und dem Herbert Simon Best Book Award 2022) definieren Pamela Herd und Donald P. Moynihan “Administrative Burden” *explizit nicht* als zufälliges Nebenprodukt träger oder inkompetenter Verwaltung. Sie ist in ihrer Lesart “**Policymaking by Other Means**” — Politikgestaltung mit anderen Mitteln. Wenn Regierungen oder Kostenträger Leistungen nicht offen, politisch kostspielig und gesetzlich legitimiert kürzen wollen oder können, erhöhen sie strategisch die administrativen Hürden, um die Inanspruchnahme implizit zu senken.

Herd und Moynihan zerlegen administrative Lasten in drei trennscharfe, empirisch messbare Kategorien:

Kosten-Kategorie	Definition	Übertragung auf Wirtschaftlichkeitsprüfung
Learning Costs (Lernkosten)	Kognitiver und zeitlicher Aufwand, um die anwendbaren Regeln überhaupt zu erfassen	Bis zu 17 regionale Prüfvereinbarungen, geheime Erstattungsbeträge, "Container-Landschaft" des § 106b SGB V, unklare Auslegung der Substantiierungsschwelle
Compliance Costs (Befolgungskosten)	Zeit und monetäre Ressourcen für formale, gerichtsfeste Dokumentation und Kodierung	61 Arbeitstage/Jahr pro Arzt, 4,33 Mrd. EUR Bürokratiekosten ambulant, "ICD für den Gutachter, nicht für den Patienten"
Psychological Costs (Psychologische Kosten)	Stress, Autonomieverlust, Frustration durch die Navigation des Systems	Ribbat 2023: 72–78 % "stark emotional belastet" durch Regresse; Goetz 2024: 27 % "starke Rechtsangst"; defensive Medizin als Folge

5.5.2 Die analytische Konsequenz: Die Bürokratie funktioniert wie vorgesehen

Wer die Herd/Moynihan-Brille aufsetzt, liest die in Teil II dokumentierten Befunde **diametral entgegengesetzt** zur naheliegenden Lesart "Systemversagen". Dabei wirken V1 und V2 als komplementäre Burden-Instrumente:

- **V1 (Auffälligkeitsprüfung):** Erzeugt primär *Learning Costs* und *Compliance Costs*. Die 99,7 %-Verwerfungsquote (KV Hessen 2015) bedeutet: 913 Ärzte tragen die administrativen und psychologischen Kosten des Screenings, ohne dass ein Regress folgt. Aus Burden-Perspektive ist genau das die Funktion — die Kosten des Verfahrens selbst, nicht sein Ergebnis, steuern das Verhalten.
- **V2 (Einzelfallprüfung):** Erzeugt primär *Psychological Costs* durch die Kombination aus fehlender Beratungsschutzstufe, normativem Schadensbegriff und hoher Durchsetzungswahrscheinlichkeit. Hier ist nicht die Breite des Filters, sondern die Unausweichlichkeit der Sanktion das Steuerungsinstrument.

Aus Sicht der Administrative-Burden-Theorie ist die Kombination beider Verfahren *kein dysfunktionales Bürokratie-Versagen*. Es wirkt wie ein hochwirksam kalibriertes Steuerungsinstrument: V1 erzeugt breite Unsicherheit, V2 erzeugt gezielte existenzielle Angst. Zusammen bringen sie Ärzte dazu, auf rechtlich und medizinisch legitime Verordnungen *freiwillig* zu verzichten. Diese Wirkung ist der "Chilling Effect".

Die Pointe von Herd und Moynihan ist, dass dieser Effekt nicht als Nebenwirkung einer Politik einzuordnen ist, sondern als ihr **intendiertes Ergebnis unter politisch "gesichtswahrenden" Bedingungen**: Niemand muss offen beschließen, dass Diabetiker keine GLP-1-Agonisten bekommen sollen. Es reicht, die Hürde so hoch zu legen, dass der rationale Arzt den "Eintrittspreis" in Form von Dokumentationsaufwand, rechtlichem Risiko und emotionaler Belastung nicht mehr zahlt. Das Ergebnis ist eine Rationierung, die politisch nie beschlossen wurde, aber faktisch eintritt.

Methodische Vorsicht: Wie bei der Niskanen-Analyse in Teil V (siehe dort die Vorbemerkung "Anreize sind nicht gleich Intentionen") gilt auch hier: Die These der bewussten Instrumentalisierung ist theoretisch schlüssig, aber historisch schwer zu beweisen. Es lässt sich nicht zeigen, dass *jemand* die deutsche Wirtschaftlichkeitsprüfung mit dem expliziten Ziel entworfen hat, Ärzte zu defensivem Verordnen zu bewegen. Was sich zeigen lässt, ist, dass das System im Ergebnis genau diese Wirkung erzielt — und dass diese Wirkung mit den öffentlich formulierten Zielen ("Wirtschaftlichkeit", "Beitragssatzstabilität") gut vereinbar ist. Die Absicht liegt nicht im Gesetzestext, sie liegt in der Akzeptanz des beobachtbaren Effekts durch die Systemarchitekten.

Das führt zur nächsten Frage: Wer profitiert eigentlich davon, dass niemand dieses System stört? Diese Frage behandelt Teil V.

6 Teil V — Das institutionelle Schweigen

6.1 Der GKV-Spitzenverband 2024: Verteidigung ohne Belege

Im Argumentationspapier vom 26.04.2024 (im Kontext der KHVVG-Anhörung) verteidigt der GKV-Spitzenverband die Einzelfallprüfung als "effizient" und "überlegen". Die Recherche zeigt: **Es wird keine einzige empirische Effizienz-Studie vorgelegt.** Keine IQWiG-Untersuchung, keine gesundheitsökonomische Publikation, keine externe Evaluation.

Stattdessen werden drei Datensätze präsentiert, die alle das eigene Argument nicht tragen:

1. **Halbierung der MD-Erstattungsbeträge 2019→2022** (2,38 Mrd. → 1,19 Mrd. EUR) seit Einführung der Prüfquoten. Das beweist nur, dass weniger Prüfung zu weniger Rückforderungen führt — keine Effizienzaussage.
2. **47-50 % Beanstandungsquote** der MD-geprüften Rechnungen (Q4 2023). Heißt zugleich: jede zweite Prüfung ist unberechtigt.
3. **85 % Einigungsquote im Vorverfahren** — belegt den Druckeffekt, nicht die Prüfgüte.

Das Kernargument ist ein Beweislast-Umkehr-Argument: "Für die Alternative liegt weder Konzept noch Folgenabschätzung vor, also bleibt der Status quo." Keine Kosten-Nutzen-Analyse der Prüfverfahren selbst wird angestellt.

Wichtige Klarstellung zum Geltungsbereich: Die GKV-SV-Verteidigung von 2024 bezieht sich primär auf die stationäre Einzelfallprüfung (§ 275c SGB V, MD-Prüfung Krankenhäuser). Die ambulante Arzneimittel-Einzelfallprüfung nach § 106b SGB V wird in derselben Argumentationslinie verteidigt, aber mit anderen Zahlen, die noch dürrtiger sind.

6.2 Wer könnte prüfen — und tut es nicht

Die Wirtschaftlichkeitsprüfung wird von keiner zuständigen Stelle systematisch auf ihre eigene Wirtschaftlichkeit geprüft:

Institution	Befugnis	Tatsächliches Handeln
Bundesrechnungshof (BHO)	(§ 88 ja, vollumfänglich	In den GKV-Berichten 2025: keine Sonderprüfung
Bundesamt für Soziale Sicherung	Aufsicht (§ 90 SGB IV)	Keine Evaluation der Prüfverfahren
SVR Gesundheit	Gutachten	2014 Richtgrößenkritik, seither Schweigen
Bundestags-Gesundheitsausschuss	Evaluationspflichten	Ungenutzt
Beschwerdeausschuss SGB V	§ 106c Streitschlichtung	Keine Systemkontrolle
G-BA	Leistungsdefinition	Nicht zuständig

Faktisch prüft niemand systematisch. Es gibt einzelne Zitate aus SVR-Gutachten 2014 (Richtgrößenkritik) und vereinzelte Stellungnahmen — aber keine durchgehende Effizienzaufsicht. Diese Beobachtung ist methodisch wichtig, weil sie die Beleglage für Effizienzaussagen über das Prüfsystem erklärt: Wer behauptet, das System funktioniere oder funktioniere nicht, stützt sich auf indirekte Daten. Eine systematische Effizienzaufsicht der Wirtschaftlichkeitsprüfung selbst existiert in Deutschland nicht.

6.3 Wer profitiert eigentlich? Eine Public-Choice-Analyse

Methodische Vorbemerkung: Die folgende Analyse arbeitet mit Anreizstrukturen, nicht mit Motiven. *Anreize sind nicht gleich Intentionen.* Es geht nicht darum, einzelnen Akteuren böse Absichten zu unterstellen, sondern darum, zu zeigen, welche strukturellen Verstärker das System unabhängig von den Absichten seiner Beteiligten produziert. Wer in einer Bürokratie einen Anreiz zur Selbsterhaltung hat, handelt deshalb nicht unmoralisch — er handelt strukturkonform.

Wenn niemand das System auf Wirtschaftlichkeit prüft und gleichzeitig die Beleglage für seinen Nutzen leer ist — wer sorgt dann eigentlich für seinen Fortbestand? Die naheliegende Antwort wären die Krankenkassen. Die empirischen Daten zeichnen ein anderes Bild.

6.3.1 Die Nutzen-Bilanz der Spieler

Eine Übersicht der wesentlichen Akteure und ihres Saldos aus dem Regress-System:

Akteur	Was kostet das System?	Was bringt es?
Vertragsarzt	Angst, Defensivmedizin, Existenzrisiko	nichts Direktes
Patient	Unterversorgung, Folgeschäden	nichts
Krankenkasse	Antragskosten, Personal, Gerichtsverfahren, Umlage für GPE	5–50 Mio. EUR Regresse/Jahr (vs. 4,33 Mrd. EUR ambulante Bürokratie)
Pharmaindustrie	Umsatzverluste durch Defensivmedizin	nichts
KV (als Selbstverwaltung)	Verwaltungslast	nichts Direktes
Gemeinsame Prüfungseinrichtungen (GPE)	nichts (durch Umlage finanziert)	Existenzgrund, Stellen, Budget
Beschwerdeausschüsse	nichts	Sitzungspauschalen
Spezialisierte Sozialrechts-Anwälte	nichts	Mandate
Regressschutz-Angebote (Vereine, Versicherer, Beratungen)	Helfen aktiv, politisieren, dokumentieren	Bestand an Existenz des Problems gekoppelt (<i>Ambivalenz — siehe unten</i>)

Aus dieser Übersicht ergibt sich ein bemerkenswerter Befund: **Die einzigen Akteure mit positivem Saldo sind die, die das System verwalten oder von ihm leben — nicht die, die es politisch entworfen oder gerechtfertigt haben.**

Zur Verhältnismäßigkeit der Kosten: Die GPE-Infrastruktur (bundesweit 600–900 Stellen) wird paritätisch aus Beitragsmitteln finanziert. Ihren exakten Kosten (nicht verifizierbar, s. u.) stehen Regress-Einnahmen von geschätzt 5–50 Mio. EUR pro Jahr gegenüber. Zum Vergleich: Die GKV-Arzneimittelausgaben lagen 2024 über 50 Mrd. EUR. Selbst die obere Grenze der Regress-Einnahmen entspricht damit weniger als 0,1 % der kontrollierten Ausgaben — ein Verhältnis, das die Frage nach der Wirtschaftlichkeit der Wirtschaftlichkeitsprüfung selbst aufwirft.

Warum das System dennoch Akzeptanz genießt: Die politische Legitimation des Prüfsystems stützt sich auf zwei Grundannahmen: (1) den *Glauben an Selbstwirksamkeit* — die Überzeugung, dass das Prüfsystem messbar Einsparungen bewirkt (empirisch nicht belegt, siehe GKV-SV 2024) — und (2) den Verweis auf „überragendes Gemeinwohl“ der Beitragssatzstabilität (§ 71 SGB V). Beide Annahmen sind politisch plausibel, aber empirisch ungeprüft. Niemand hat je berechnet, ob die durch das Prüfsystem verhinderten Verordnungen einen höheren Wert haben als die durch Defensivmedizin verursachten Folgekosten.

Gegenargument — natürliche Begrenzungen: Ein häufig unausgesprochenes Argument für die Notwendigkeit des Prüfsystems lautet: Ohne externe Kontrolle würden Ärzte *unbegrenzt* verordnen. Dieses Argument ignoriert drei natürliche Begrenzungsmechanismen: (a) Patienten wollen nicht unnötig medi-

kamentös behandelt werden (Nebenwirkungsaversion, Non-Compliance bei Überversorgung); (b) die medizinische Indikation selbst setzt Grenzen (Leitlinien, Kontraindikationen, Wechselwirkungen); (c) die ärztliche Professionslogik (Freidson, siehe Teil VIII) enthält intrinsische Qualitätsstandards. Das Prüfungssystem reguliert nicht die Medizin, sondern die Abweichung von einer statistischen Norm — eine Funktion, die auch ohne Sanktionen durch Beratung und Information erfüllt werden könnte.

6.3.2 Niskanens Bürokratie-Modell und die GPE

Aus *Public-Choice-Perspektive* lassen sich solche Konstellationen gut beschreiben — ohne damit eine intentionale Motivation einzelner Akteure zu unterstellen. William Niskanen hat 1971 in *Bureaucracy and Representative Government* ein *analytisches Modell* vorgelegt, das zeigt: Behörden, deren Output politisch nicht direkt messbar ist, tendieren strukturell dazu, ihren eigenen Etat statt das Gemeinwohl ihres Auftrags zu maximieren. Der Mechanismus ist eine *Anreizstruktur* der institutionellen Selbsterhaltung, keine böse Absicht. Niskanen identifiziert sechs Kriterien für eine selbsterhaltende Bürokratie. Bei den Gemeinsamen Prüfungseinrichtungen (§ 106c SGB V) sind im Modellrahmen alle sechs formal erfüllt:

Niskanen-Kriterium	Befund für die GPE
(a) Monofunktional	Nur Wirtschaftlichkeitsprüfung; Plausibilitäts-, Abrechnungs- und Qualitätsprüfung liegen NICHT bei der GPE
(b) Output-unabhängige Finanzierung	Umlage durch KV und Krankenkassen, unabhängig von Verfahrenserfolg
(c) Informationsasymmetrie	Keine Haushaltsveröffentlichung; der Bundesrechnungshof hat NIE eine Sonderprüfung durchgeführt
(d) Karrierekopplung	Teamleitung setzt Verfahrensvolumen voraus; Aufstiegswege an Fallzahlen gebunden
(e) Reformresistenz	2017-Abschaffung der Richtgrößenprüfung führte nur zur Umbenennung — <i>nicht zum Personalabbau</i>
(f) Kein eigener Rechtfertigungszwang	Interessen werden indirekt über die Träger-KV vertreten

Punkt (e) ist der entscheidende empirische Beleg. Als der Gesetzgeber 2017 die Richtgrößenprüfung abschaffte, hätte ein Output-orientiertes System Personal abbauen müssen. Stattdessen blieb das Personal und wurde in andere Prüfaufgaben realloziert. Die Prüfungseinrichtung Bayern beschäftigt aktuell ca. 75 Mitarbeiter (Apotheker, PTA, Juristen, BWLer, Rechtsanwaltsfachangestellte) ausschließlich für Wirtschaftlichkeitsprüfungen. Bundesweit etwa 600–900 Stellen.

6.3.3 Kosten extern nicht verifizierbar — und das ist selbst ein Befund

Eine eigene Detailrecherche zum Versuch, exakte Eurozahlen für die Prüfinfrastruktur (Personal, Sachkosten, Sitzungsgelder) zu ermitteln, führt zu einem bemerkenswerten Ergebnis: **Die Kosten sind aus offenen Quellen nicht verifizierbar.** Drei strukturelle Gründe:

- Die GPE sind keine staatlichen Behörden. Sie tauchen in keinem Bundes- oder Landeshaushalt mit eigenständigen Posten auf.
- Die Finanzierung erfolgt paritätisch durch KV und Krankenkassen-Verbände (§ 106c Abs. 2 SGB V), aber die Kostenanteile werden in den allgemeinen Verwaltungsbudgets der Träger nicht granular ausgewiesen — sie erscheinen in den öffentlich zugänglichen Geschäftsberichten nicht als eigenständige Position „Prüfinfrastruktur“.
- Der Bundesrechnungshof prüft die GPE nicht in Form tiefergehender Wirtschaftlichkeits-Sonderberichte — und zwar systematisch nicht, weil hier primär GKV-Beitragsmittel und ärztliche Honorarabzüge fließen, keine direkten Steuermittel des Bundes. Die Zuständigkeit liegt formal außerhalb des klassischen BRH-Prüfungsbereichs.

Diese Nicht-Verifizierbarkeit ist nicht ein Mangel der Recherche, sondern ein strukturelles Merkmal des Systems. Genau diese Informationsasymmetrie ist Niskanens Kriterium (c) — und sie ist der Grund, warum die institutionelle Selbsterhaltung der GPE bisher nicht extern belegt werden *konnte*, obwohl sie strukturell offensichtlich ist. Die Beweislage für die Effizienz des Systems ist nicht nur leer — sie ist strukturell nicht herstellbar, weil die nötigen Kostendaten nicht granular erfasst oder veröffentlicht werden.

IFG-Hebel: Eine systematische IFG-Anfrage an die Prüfungsstellen aller KV-Bezirke (oder als Sammelanfrage über den Spitzenverband) könnte diese Lücke schließen. Die Erfolgsaussichten sind unklar, weil die Gemeinsamen Prüfungseinrichtungen ihre Stellung als "Selbstverwaltung" tendenziell als IFG-frei interpretieren. Eine solche Anfrage wäre damit zugleich Recherche und politischer Test.

6.3.4 Der Drehtür-Effekt

Ein zweites Niskanen-typisches Muster: der Wechsel von Mitarbeitern der Prüfungseinrichtungen in spezialisierte Anwaltskanzleien, die auf Regressabwehr ausgerichtet sind. Dieses Muster ist strukturell beobachtbar: Ehemalige Leitungspositionen in Wirtschaftlichkeitsprüfungseinrichtungen finden sich in Fachkanzleien wieder, die genau diese Verfahren vertreten.

Dieser Personalwechsel ist rechtlich zulässig. Er erzeugt jedoch eine Anreizstruktur, in der spezialisierte Anwaltskanzleien wirtschaftlich von der Fortdauer des Prüfsystems abhängen — auch wenn ihre Mandanten die Verfahren am liebsten gar nicht erst hätten. Die Kanzleien sind damit die zweite Gruppe mit strukturellem Interesse an der Kontinuität des Systems.

6.3.5 Die wahren Profiteure

Aus der empirischen Analyse ergibt sich eine überraschende Reihenfolge der strukturellen Profiteure des Systems:

1. **Spezialisierte Medizinrechts-Kanzleien** (Drehtür-Effekt belegt)
2. **GPE-Beschäftigte** (600–900 Stellen, monofunktional)
3. **Regressschutz-Angebote** (Vereine, Versicherer, Beratungen — siehe Anmerkung zur Ambivalenz unten)

Krankenkassen sind nicht auf Platz 1. Sie kassieren wenige Millionen Euro Regress, zahlen aber die Umlage für die GPE. Ihr Nettonutzen ist nahe Null. *Sie halten das System aus politisch-kultureller Legitimation am Leben, nicht aus rationaler Kostenkalkulation.*

Zur Ambivalenz der Regressschutz-Angebote

Akteure wie Therapiefreiheit e.V., die Beratungsangebote des Virchowbundes und private Regressschutz-Versicherer nehmen in dieser Analyse eine strukturell ambivalente Rolle ein. **Einerseits** sind sie die wichtigsten Verbündeten betroffener Ärzte: Sie helfen konkret, dokumentieren Einzelfälle, politisieren das Thema, verfassen Stellungnahmen, treten als Prozessbegleiter auf und sind häufig die einzigen Stimmen, die das Regress-System öffentlich kritisieren. **Andererseits** ist ihr Bestand strukturell an die Existenz des Problems gekoppelt. Würde das Regress-System morgen abgeschafft, verlöre ihr Angebot seinen Zweck.

Methodischer Hinweis: Diese Beobachtung ist keine moralische Kategorie. Sie beschreibt eine Anreizstruktur, keine Intention. Anreize sind nicht gleich Motive (siehe Vorbemerkung am Anfang dieses Abschnitts). Die Akteure selbst handeln in bester Absicht und leisten für betroffene Ärzte unverzichtbare Arbeit.

Strategische Konsequenz: Gerade diese Akteure sind natürliche Kooperationspartner für ein Regress-Transparenzportal. Wer das Problem wirklich kennt, hat das größte Interesse daran, es messbar und sichtbar zu machen. Die Ambivalenz ist kein Grund zur Distanz, sondern eine Einladung zur gemeinsamen Veränderung des Systems.

6.3.6 Die Forschungslücke

Bemerkenswert ist, dass die deutsche Public-Choice-Literatur die GPE bisher nicht empirisch aufgearbeitet hat. Es existieren keine wissenschaftlichen Studien, die das Niskanen-Modell auf das deutsche Wirtschaftlichkeitsprüfungs-System anwenden. **Diese Forschungslücke ist selbst ein Datenpunkt** — und sie bestätigt die Informationsasymmetrie-These: Wo niemand hinschaut, entstehen genau die strukturellen Eigenlogiken, die Niskanen beschreibt.

7 Verfassungsrechtliche Angriffsvektoren

Ein weiterer Befund der Studie lässt sich aus den vorangegangenen Teilen ableiten: Wenn das System einen rechtsdogmatischen Doppelbind enthält (Teil II), wenn es Patientenschäden in Milliardenhöhe erzeugt (Teil IV) und wenn niemand seine Effizienz prüft (Teil V), liegt die Frage nahe, ob es verfassungsrechtlich angreifbar ist. Diese Frage haben wir aus der Perspektive eines erfahrenen Verfassungsrechtlers analysiert. Das Ergebnis ist nicht eindeutig — aber es ist auch nicht negativ.

7.1 Was nicht funktioniert: Der naheliegende Weg über Art. 12 GG

Der Standard-Angriff auf Regressbescheide läuft über Art. 12 Abs. 1 GG (Berufsfreiheit). Das BVerfG ordnet Regresse jedoch dogmatisch auf der niedrigsten Stufe der Drei-Stufen-Theorie ein und winkt die Finanzstabilität der GKV als "überragendes Gemeinwohl" regelmäßig durch.

Frischer Beleg: Der **Kammerbeschluss 1 BvR 985/24 vom 01.10.2025**. Eine ärztliche Verfassungsbeschwerde gegen einen Regress wurde dort ohne ausführliche Substantiierung als unzulässig abgewiesen. Karlsruhe hat das Thema also bereits auf dem Tisch — und akzeptiert die etablierte Linie.

7.2 Die Backdoor: Art. 20 Abs. 3 GG, Bestimmtheitsgrundsatz und Wesentlichkeitstheorie

Der eigentliche verfassungsrechtliche Hebel liegt eine Ebene tiefer. § 12 SGB V formuliert das Wirtschaftlichkeitsgebot tautologisch ("ausreichend, zweckmäßig, wirtschaftlich"). Für eine Leistungsnorm ist das tragbar. Für eine *Sanktionsnorm mit existenzvernichtender Wirkung* — etwa die 490.000 EUR im Stempelregress (BSG B 6 KA 9/24 R) — ist es ein Bestimmtheitsproblem.

Die Leitentscheidungen des BVerfG sind hier auf der Seite einer Kritik:

- **Kalkar I (BVerfGE 49, 89)** — Wesentliche Entscheidungen muss der Gesetzgeber selbst treffen
- **Numerus Clausus I (BVerfGE 33, 303)** — Wesentlichkeitstheorie auch im Vorfeld grundrechtsrelevanter Eingriffe

Beide Entscheidungen verlangen, dass der Gesetzgeber wesentliche Sanktionsbedingungen selbst regelt — und nicht an selbstverwaltungsrechtliche Prüfvereinbarungen delegiert. Die deutsche Wirtschaftlichkeitsprüfung tut genau das: Sie regelt die Substanz der Einzelfallprüfung in regionalen Prüfvereinbarungen, während das Gesetz selbst nur einen tautologischen Rahmen vorgibt.

7.3 Die BSG-Selbstentlarvung

Eine zusätzliche dogmatische Schwachstelle liegt in der jüngsten BSG-Rechtsprechung selbst. In den Urteilen B 6 KA 5/23 R und B 6 KA 10/23 R (beide vom 05.06.2024) hat der 6. Senat die **Differenzkostenregelung** für einen Teilbereich anerkannt: Bei Wirtschaftlichkeitsregressen wird nur der tatsächliche Mehrschaden ersetzt, nicht der volle Verordnungswert. Für *Formalregresse* gilt das ausdrücklich nicht — dort bleibt der Vollregress.

In der Begründung räumt der BSG offen ein, der Vollregress diene der *Verhaltenssteuerung*. Damit ist er als **Sanktion** klassifiziert, nicht als Schadensausgleich. Sanktionen unterliegen aber strengeren

verfassungsrechtlichen Anforderungen — vor allem an Bestimmtheit. Das BSG hat in eigenen Worten geliefert, was eine Verfassungsbeschwerde braucht.

7.4 Die Eigentumsdogmatik des regressierten Medikaments

Die Eigentumsfrage des regressierten Medikaments ist verfassungsrechtlich anomal:

- Der Hersteller liefert das Medikament an den Großhandel
- Der Großhandel an die Apotheke
- Die Apotheke gibt es an den Patienten ab
- Der Patient verbraucht es (Untergang nach § 90 BGB)
- **Der Arzt war zu keiner Zeit Eigentümer**
- Eine Rückforderung vom Patienten scheitert (§ 812 BGB: kein Leistungsverhältnis)
- Trotzdem haftet der Arzt mit voller Kostenhöhe

Das ist eine verfassungsrechtlich erklärungsbedürftige Konstruktion. Der Arzt zahlt für etwas, das er nie besessen hat, das nicht mehr existiert, das ihm nichts genützt hat — und das dem Patienten genützt hat, ohne dass er von ihm zurückfordern könnte. Eine Verfassungsbeschwerde mit primärem Fokus auf Art. 14 GG (Eigentumsgarantie) hat hier ein nicht ausgeschöpftes Argumentationsfeld.

Methodische Abgrenzung: Die Argumentation behauptet kein Eigentum des Arztes an der ärztlichen Leistung selbst. Was sie behauptet, ist eine eigentumsrechtlich begründete Disposition: Die Regressforderung greift auf Vermögenswerte des Arztes zu, die durch eine Verordnung entstanden sind, an deren Eigentumssache (Medikament) der Arzt zu keinem Zeitpunkt rechtlich beteiligt war. Das ist juristisch ein zweifelhafter Eingriff in das Vermögen, nicht in das Eigentum an einer Sache. Die Linie ist daher Art. 14 Abs. 1 Satz 2 GG (Inhalts- und Schrankenbestimmung) — dort verlangt das BVerfG die Beachtung des Verhältnismäßigkeitsgrundsatzes (siehe BVerfGE 50, 290 — Mitbestimmungsurteil; BVerfGE 100, 226 — Denkmalschutz Rheinland-Pfalz). Das Argument ist also nicht: „Der Arzt war Eigentümer“. Das Argument ist: „Die Vermögensbelastung steht außer Verhältnis zum tatsächlichen Schaden, weil der Schaden *strukturell null* ist.“

7.5 Die Doppelbeschwerde-Strategie

Aus der Persona-Analyse ergibt sich eine konkrete strategische Empfehlung: Eine **Doppelbeschwerde** mit zwei Beschwerdeführer-Profilen.

Beschwerde 1 — der Arzt:

- Hauptangriff: Wesentlichkeitstheorie und Bestimmtheit (Art. 20 Abs. 3 GG)
- Flanke: Art. 14 GG (Differenzkosten als milderer Mittel)
- Flanke: Art. 3 GG (Beratung-vor-Regress-Asymmetrie zwischen Auffälligkeits- und Einzelfallprüfung)

Beschwerde 2 — der Patient:

- Hauptangriff: Art. 2 Abs. 2 Satz 1 GG (staatliche Schutzpflicht für körperliche Unversehrtheit)
- Strategie: Fortentwicklung der Nikolaus-Rechtsprechung (1 BvR 347/98) auf schwere chronische Erkrankungen

Der strategische Wert der Doppelbeschwerde liegt darin, dass die zweite Beschwerde das BVerfG zu einer inhaltlichen Auseinandersetzung mit der Schutzpflicht zwingt. Auch eine formale Ablehnung würde rechtspolitisch wertvolle Begründung produzieren.

7.6 Einschätzung der Erfolgsaussichten

Die folgende Einschätzung ist eine *analytische Einordnung*, keine juristische Prognose. Die tatsächlichen Erfolgsaussichten hängen von der Fallkonstellation, der Begründungsqualität und der verfassungsgerichtlichen Agenda ab:

- Vollumfängliche Stattgabe: nicht absehbar, aber angesichts der Dogmatik-Hürden gering

- Rechtsfortbildende Begründung (auch bei formaler Ablehnung): realistischeres Ziel, da das BVerfG sich zur Schutzpflicht positionieren müsste

Parallel zur Beschwerde gehörten EMRK-Vorbereitung (Art. 6 und Art. 1 ZP 1) sowie eine politische Begleitstrategie.

Methodische Einordnung: Diese Studie ist keine anwaltliche Schrift. Die hier dargestellte Analyse ist eine *Argumentations-Skizze*, keine fundierte Verfassungsbeschwerde-Vorbereitung. Wer das System tatsächlich verfassungsrechtlich angreifen wollte, bräuchte spezialisierten anwaltlichen Beistand und einen konkreten Fall mit dokumentierter Beschwer.

8 Teil VI — Internationaler Vergleich

8.1 Deutschland und die Schweiz als Sonderwege

Deutschland und die Schweiz sind in Westeuropa praktisch die einzigen Länder mit flächendeckender individueller Regress-Prüfung gegen einzelne Ärzte für Verordnungen. Andere Länder steuern ärztliches Verordnungsverhalten ohne Individual-Sanktionen:

Land	Mechanismus
UK (NHS)	QOF / CQUIN / NICE-Empfehlungen, professionelle Selbstregulation, keine individuellen Regress-Verfahren für Verordnungen
Niederlande	Capitation / NHG-Standards, kollektive Steuerung
Schweden, Norwegen, Dänemark	Zentrale Erstattungsregeln, professionelle Selbstregulation
Frankreich	MSO/MSAP-Verfahren (<i>Mise Sous Objectif</i> / <i>Mise Sous Accord Préalable</i>) mit algorithmengestützter Vorauswahl. Seit 2024 wachsender Widerstand durch MG France, FMF und Médecins Pour Demain unter der Begriffsprägung “ <i>délit statistique</i> ” — siehe eigene Subsection unten
Schweiz	Art. 56 KVG / WZW-Verfahren — strukturell vergleichbar zu DE, aber transparenter
Deutschland	§ 106b SGB V plus 17 regionale Prüfvereinbarungen, ohne Beratungsschutz für Einzelfallprüfungen

8.2 Frankreich: Le “Délit Statistique”

Ein Teil der Recherche für diese Studie galt der Frage, ob Deutschland mit seinem Regress-System tatsächlich allein steht. Die kurze Antwort: Nein. Seit etwa 2023 entwickelt sich in Frankreich eine strukturell parallele Debatte, die unter dem von Ärztegewerkschaften geprägten Begriff “**délit statistique**” (“statistisches Delikt” oder “statistisches Vergehen”) geführt wird. Sie ist das direkte Analogon zum deutschen Fall — nur auf ein anderes Verordnungsobjekt zugeschnitten.

8.2.1 Das Instrument: MSO und MSAP

Die französische gesetzliche Krankenversicherung (*Caisse nationale de l'Assurance Maladie*, CNAM) verfügt seit dem **Décret 2011-551 vom 19. Mai 2011** (Regierung Fillon) über ein Verfahren namens **Mise Sous Objectif** (MSO) und sein schärferes Pendant **Mise Sous Accord Préalable** (MSAP). Die Mechanik ist einfach:

- Die CNAM analysiert jährlich statistisch das Verordnungsverhalten jedes Vertragsarztes, im Fokus vor allem *indemnités journalières* (IJ — Arbeitsunfähigkeitsbescheinigungen / Krankschreibungen).
- Ärzte, die laut Algorithmus “signifikant über dem regionalen Durchschnitt” verordnen, werden zu einem Gespräch einbestellt.
- Wer im Gespräch keine zufriedenstellende Erklärung liefert, wird per Verfügung unter MSO gestellt — das bedeutet: sechs Monate lang verpflichtendes “Reduktionsziel” unter Androhung finanzieller Sanktionen durch Finanzstrafkommissionen (*commissions des pénalités financières*).
- Wer bei MSAP landet, muss jede einzelne Krankschreibung vorab von der Kasse genehmigen lassen.

8.2.2 Größenordnung: Was die offiziellen Zahlen zeigen

Die veröffentlichten Zahlen der CNAM und der französischen Ärztegewerkschaften sind für 2023–2024 belastbar dokumentiert (Quellen: *Le Quotidien du Médecin*, *Egora*, *Previssima*, FMF-Cellule-Juridique):

- **Kampagne 2023–2024:** 745 Ärzte wurden unter MSO gestellt; 416 MSO-Verfügungen über jeweils sechs Monate (01.09.2023–29.02.2024). 310 erfüllten ihr Reduktionsziel, **106 wurden vor Finanzstrafkommissionen gebracht**.
- **Gesamtjahr 2024:** ca. 680.000 Kontrollen, davon 230.000 mit medizinischer Prüfung, **ca. 7.000 Sanktionen**.
- **2025:** Fortsetzung der Kampagne in zwei Wellen; die CNAM rechnet mit einer erhöhten Zahl von MSO-Verweigerungen und der Umstellung auf MSAP.

Diese Zahlen sind keine “Massenproteste im Zehntausender-Bereich” — sie bezeichnen strukturellen, institutionell verfestigten Disziplinierungsdruck auf tausende Ärzte, mit existenzrelevanten Konsequenzen für einige Hundert pro Jahr. Sie sind damit größenordnungsmäßig durchaus vergleichbar mit der deutschen Situation.

8.2.3 Die Begriffsprägung und der gewerkschaftliche Widerstand

Den Begriff “*délit statistique*” prägten primär zwei Akteure:

- **MG France** (der größte französische Hausarzt-Verband): “Le délit statistique est illégal” — das statistische Delikt ist ein rechtswidriges Konstrukt. Die CNAM “adjustiere” ihre Statistiken und erschaffe damit eine “pseudo-vergleichbare” Aktivität, die die spezifische Patientenstruktur (Alter, Geschlecht, Multimorbidität, soziale Härten) einer Praxis systematisch unterkalkuliere.
- **Fédération des Médecins de France (FMF):** Ihre juristische Zelle (*cellule juridique*) hat unter dem Titel “Histoire du délit statistique” eine rechtsdogmatische Analyse vorgelegt, die argumentiert, dass die rein statistische Begründung eines Verdachts gegen einzelne Ärzte weder mit dem Bestimmtheitsgebot noch mit dem Prinzip der individuellen Verantwortung vereinbar sei. Der Widerstand gegen MSO hat sich seit 2024 über ein breites Spektrum französischer Ärzte-Verbände ausgeweitet, einschließlich des Kollektivs *Médecins Pour Demain*.

Die Kernargumentation der französischen Verbände liest sich fast wörtlich wie das, was die KBV in Deutschland sagt: Ein statistischer Ausschlag ist kein valider Beweis für unethisches oder unwirtschaftliches Verordnen. Er spiegelt in der Regel die spezifische Patientenstruktur einer lokalen Praxis wider. Die algorithmische Androhung zwingt Ärzte in ein ethisches Dilemma, in dem sie gegen ihr professionelles Gewissen kranken Patienten notwendige Krankschreibungen verweigern müssten, um die eigene Praxis vor Sanktionen zu schützen.

8.2.4 Methodische und strategische Konsequenz

Der Frankreich-Befund verändert die Einordnung des deutschen Sonderwegs in drei Hinsichten:

1. **Der deutsche Fall ist kein isoliertes juristisches Artefakt.** Das Muster der algorithmengestützten Einzelarzt-Sanktionierung findet in mindestens zwei großen europäischen Gesundheitssystemen statt. Es ist Teil eines europäischen Trends zur *mikroindividuellen Kostenkontrolle* — nicht eine pathologische Einzelercheinung des deutschen SGB V.

2. **Das Verordnungsobjekt ist austauschbar, die Steuerungslogik nicht.** In Frankreich zielt der Algorithmus auf Krankschreibungen (IJ), in Deutschland primär auf Arzneimittel und Heilmittel. Der zugrundeliegende Mechanismus — statistischer Vergleich + Einzelfall-Disziplinierung + finanzielle Existenzdrohung — ist strukturell derselbe.
3. **Der kollektive Widerstand ist in Frankreich erfolgreicher organisiert.** Die französischen Ärzteverbände haben ihr Solidaritäts-Gefangenendilemma (siehe Teil III) überwunden, weil sie eine politisch streikfähige Kultur haben. Die deutsche Ärzteschaft schafft diesen Übergang zur gemeinsamen öffentlichen Artikulation bisher nicht — ein Befund, der die in Teil III beschriebene spieltheoretische Konstellation zusätzlich belegt.

Der deutsche und der französische Fall bestätigen sich also gegenseitig: Es geht in beiden Systemen um dieselbe Frage, und in beiden Fällen wird auf dieselbe Ursache ein unterschiedlich organisierter Widerstand gebaut. Der Import des Begriffs “*délit statistique*” in die deutsche Debatte ist nicht polemisch — er ist sachlich präzise.

8.3 Was andere Länder anders machen

- **Positive Anreize statt Sanktionen:** QOF in UK belohnt Qualität, statt Abweichung zu bestrafen.
- **Capitation statt Einzelleistung:** Pauschale Vergütung pro Patient (NL, UK) reduziert den Anreiz, jede Verordnung einzeln zu kontrollieren.
- **Zentrale Preisbildung:** NICE in UK, Spain, Australien — der “richtige Preis” wird nicht im Einzelfall ermittelt, sondern systemisch festgelegt.
- **Professionelle Selbstregulation:** GP-Körperschaften sanktionieren Fehlverhalten kollegial, nicht über finanzielle Drohung.

Die deutsche Praxis ist nicht alternativlos. Sie ist eine spezifische historische Wahl, die in ihrer heutigen Ausprägung international die Ausnahme ist.

8.4 Diametrale Manifestation desselben Mechanismus

Die internationale Defensivmedizin-Literatur belegt einen Mechanismus, der auch für Deutschland gilt — aber sich diametral entgegengesetzt manifestiert. Diese Beobachtung ist methodisch zentral, weil sie erklärt, warum die deutschen Folgekosten schwerer messbar sind als die US-amerikanischen, ohne dass der zugrundeliegende Mechanismus ein anderer wäre.

8.4.1 USA: Druck vom Patienten → Überbehandlung

In den USA ist die zentrale Druckquelle das Tort Law (Kunstfehlerklage). Der Aggressor ist der Patient (und sein Anwalt). Die Reaktion der Ärzte ist *Defensive Medicine* im engeren Sinne: zusätzliche Tests, zusätzliche Bildgebung, häufigere stationäre Aufnahmen, prophylaktische Eingriffe.

Klassische empirische Belege:

- Kessler & McClellan (Quarterly Journal of Economics 111[2], 1996, S. 353-390): Haftungsreformen senken Gesundheitsausgaben um 5–9% ohne negative Auswirkungen auf Mortalität oder Komplikationen — ein direkter Effizienzbeleg für defensive Überbehandlung.
- Currie & MacLeod (Quarterly Journal of Economics 2008): Schadensersatzdeckelungen verändern die Wahl von Behandlungswegen (z.B. C-Sections) systematisch.
- Mello et al. (Health Affairs 2010): Schätzen die Kosten der Defensivmedizin in den USA auf 45,6 Mrd. USD/Jahr.

8.4.2 Deutschland: Druck von der Krankenkasse → Fehlversorgung in zwei Richtungen

In Deutschland ist die zentrale Druckquelle nicht der Patient, sondern die Krankenkasse (über das Wirtschaftlichkeitsprüfungs-System). Die Reaktion der Ärzte ist jedoch **nicht eindimensional “weniger”**, sondern eine *Fehlversorgung in zwei Richtungen*:

- **Unterversorgung bei Verordnungen:** Ärzte verschreiben weniger, vermeiden teure Medikamente, verzichten auf Off-Label-Therapien — selbst wenn sie medizinisch indiziert wären.
- **Überversorgung bei Diagnostik und Überweisungen:** Ärzte veranlassen zusätzliche Bluttests, überweisen an Fachärzte, fordern bildgebende Diagnostik an — nicht weil der Patient es braucht, sondern zur eigenen Absicherung (Goetz 2024: 54 % wöchentlich unnötige Labortests; Ribbat 2023: 51 % überweisen trotz eigener Behandlungskompetenz).
- **Belastung des Patienten:** Die defensive Überweisung geht zu Lasten des Patienten: zusätzliche Arzttermine, Wartezeiten, Urlaubstage, Anfahrtswege — für Untersuchungen, deren Ergebnis im Grunde bereits feststeht. Kranke Menschen werden gezwungen, noch häufiger zum Arzt zu gehen, weil ihr Arzt sich absichern muss.

Der präzisere Begriff ist daher **Fehlversorgung** (SVR 2000/2001, Band III; § 135a SGB V): Das System lenkt ärztliche Ressourcen von der Therapie (Unterversorgung bei Verordnungen) in die Absicherung (Überversorgung bei Diagnostik und Überweisungen) um. Beide SVR-Kategorien treten zugleich auf; der Nettoverlust liegt beim Patienten — nicht nur als unterlassene Therapie, sondern auch als Zeit-, Wege- und Belastungskosten durch die umgeleiteten Zusatzuntersuchungen (siehe Glossar-Eintrag *Überversorgung*).

Zur Originalitätsfrage. Die *allgemeine Dimension* der Patientenlast — dass Überversorgung nicht nur die Solidargemeinschaft belastet, sondern auch den Patienten (iatrogene Risiken, Zeit-, Wege-, Belastungskosten) — ist in der Versorgungsforschungsliteratur etabliert: SVR 2000/2001 Band III (Über-/Unter-/Fehlversorgung) [15], DEGAM-S2e-Leitlinie “Schutz vor Über- und Unterversorgung” [7], DGIM-Initiative “Klug entscheiden” [6] und das Standardlehrbuch der Versorgungsforschung (Pfaff/Neugebauer/Glaeske/Schrapppe [2]) arbeiten diese Dimension seit Jahren auf. Der *spezifische Beitrag* dieser Studie ist eine andere Kausalverknüpfung: **Regress → defensive Überversorgung (Überweisung, Zusatzdiagnostik) → Patient zahlt mit Zeit und Wegen**. Diese Zuschreibung der Diagnostik- und Überweisungsüberversorgung auf die *Regress-Prüfstruktur* (und nicht auf medizinische Unsicherheit als Primärursache) ist, soweit im Rahmen der Recherche auffindbar, in dieser Form bislang nicht explizit als Kausalfaden in der deutschen Versorgungsforschungsliteratur ausgewiesen. Sie ist der Originalitätsanspruch der Studie an dieser Stelle — vorbehaltlich künftiger Gegenbelege.

8.4.3 Methodische Konsequenz

Der psychologische Wirkmechanismus (Antizipation eines Schadens, Verlustaversion nach Kahneman/Tversky, defensives Risikoverhalten) ist in beiden Systemen *identisch*. Was sich unterscheidet, ist die institutionelle Anreizstruktur, die das defensive Verhalten in eine bestimmte Richtung lenkt:

	USA (Tort Law)	Deutschland (SGB V)
Druckquelle	Patient (Klage)	Krankenkasse (Regress)
Sanktionsrichtung	“zu wenig getan”	“zu viel/falsch verordnet”
Defensive Reaktion	<i>mehr</i> Behandlungen	Verordnungen ↓, Diagnostik/Überweisungen ↑
Netto-Effekt	Überversorgung	Fehlversorgung (weniger Therapie, mehr Absicherung)
Empirische Sichtbarkeit	gut messbar (Kostensteigerung)	schlecht messbar (Versorgungslenkung unsichtbar)
Wer trägt die Last?	System (Kosten)	Patient (Termine, Wartezeiten, Lebenszeit)
Folgekosten	Überversorgung	Unterversorgung + Hospitalisierung

Die diametrale Manifestation erklärt, warum die internationale Literatur (vor allem die US-amerikanische) so umfangreich zur Defensivmedizin existiert, während die deutsche Variante kaum quantifiziert ist: **Unterversorgung ist methodisch viel schwerer zu messen als Überversorgung**. Wenn ein US-Arzt einen unnötigen Test anordnet, taucht das in der Abrechnung auf. Wenn ein deutscher Arzt eine

notwendige Verordnung unterlässt, taucht es nirgends auf — außer später in der Hospitalisierungsstatistik, und auch dort ohne Ursachenzuschreibung.

Diese Asymmetrie ist die zentrale methodische Begründung für das Konzept eines Regress-Transparenzportals. Solange Unterlassungen nicht sichtbar sind, kann ihre Verbreitung nicht bewiesen werden — und solange sie nicht bewiesen ist, gibt es keinen politischen Reformdruck. Das Portal würde diese Sichtbarkeitslücke erstmals systematisch schließen.

Die Tort-Reform-Studien aus den USA können damit als *methodische Validierung* des deutschen Falls gelesen werden: Sie zeigen, dass regulatorischer Druck auf Ärzte systematisch ihr Verhalten verändert. Was sie nicht zeigen, weil sie es nicht zeigen können, ist die spezifisch deutsche Ausprägung dieses Effekts.

9 Grenzen der Evidenz und Gegenposition

Diese Studie argumentiert, dass das Wirtschaftlichkeitsprüfsystem systemische Fehlanreize setzt — insbesondere die Einzelfallprüfung (V2) mit ihrem fehlenden Beratungsschutz und dem normativen Schadensbegriff, aber auch die Auffälligkeitsprüfung (V1) über den Zertifikatsfehler. Eine ehrliche Analyse muss die stärksten Gegenargumente benennen und ihnen standhalten. Die folgenden sechs Einwände sind die gewichtigsten, die gegen die zentrale These vorgebracht werden können. Wo möglich, wird angegeben, welches Verfahren (V1, V2 oder beide) der jeweilige Einwand betrifft.

9.1 Einwand 1: Korrelation ist keine Kausalität (betrifft V1+V2)

Der Einwand: Die Ribbat-Studie (2023) misst *subjektive Wahrnehmung und selbstberichtetes Verhalten*, keine objektiven Versorgungsergebnisse. Dass 47 % der Hausärzte angeben, die Regressgefahr beeinflusse ihr Verschreibungsverhalten, beweist nicht, dass Patienten tatsächlich unterversorgt werden. Steigende GKV-Arzneimittelausgaben (über 50 Mrd. EUR 2024) sprechen gegen eine systematische Unterversorgung.

Befund: Der Einwand trifft einen realen Punkt. Diese Studie verfügt nicht über eine kausalanalytische Studie, die Versorgungsergebnisse direkt mit Prüfintensität korreliert — etwa einen Vergleich von KV-Regionen mit unterschiedlicher Einzelfallprüfungsfrequenz. Ein solches natürliches Experiment wäre methodisch der stärkste Beleg, existiert aber nicht.

Was die Studie zeigen kann: (a) Die verhaltensökonomische Literatur belegt, dass regulatorischer Druck ärztliches Verhalten systematisch verändert (Kessler & McClellan 1996, Currie & MacLeod 2008). (b) Steigende Gesamtausgaben schließen sektorale Unterversorgung nicht aus — Biosimilar-Wachstum und Hochpreistherapien treiben das Volumen, während bei Standardverordnungen Zurückhaltung herrschen kann. (c) Die Datenlücke selbst — dass niemand misst, ob Unterlassungen stattfinden — ist ein Befund über das System, nicht über die Behauptung.

Zur Operationalisierung: Steigende GKV-Arzneimittelausgaben sind als Gegenargument gegen Unterversorgung methodisch ungeeignet. Die Ausgabensteigerung wird primär durch drei Faktoren getrieben, die mit dem Ordnungsverhalten niedergelassener Ärzte wenig zu tun haben: (1) Hochpreisarzneimittel (Onkologika, Biologika, Gentherapeutika), deren Stückpreise in die Hunderttausende gehen; (2) demografischer Wandel (mehr Multimorbidität, mehr Polypharmazie); (3) Patentauslauf-Zyklen, die kurzfristig zu Generika-Einsparungen und langfristig zu neuen Hochpreistherapien führen. Ein Arzt, der aus Regressangst auf ein 30-EUR-Standardmedikament verzichtet, erscheint in der GKV-Gesamtstatistik nicht — während ein einziges neues Krebsmedikament für 100.000 EUR den Aggregatwert dominiert. Die Gesamtausgaben messen den Preistrend des Arzneimittelmarkts, nicht das Ordnungsverhalten der Praxis.

9.2 Einwand 2: Der Zertifikatsfehler ist ein Strohhalm (betrifft V1+V2)

Der Einwand: § 106b prüft Wirtschaftlichkeit, nicht Qualität. Das System *verspricht* kein medizinisches Zertifikat. Die Studie erfindet ein Sollkriterium und kritisiert dessen Nicht-Erfüllung.

Befund: Der Einwand ist dogmatisch korrekt: Das Wirtschaftlichkeitsprüfsystem ist als Ausgabensteuerungsinstrument konzipiert, nicht als Qualitätssicherung. Der Zertifikatsfehler beschreibt nicht einen Fehler *im* System, sondern die Lücke zwischen Systemmessung und öffentlicher Bedeutungszuschreibung: Die niedrige Regressquote wird in der politischen Kommunikation als Beleg für ein “funktionierendes System” herangezogen — aber was “funktioniert”, ist die Ausgabenkontrolle, nicht die Versorgungsqualität.

Der Kern des Arguments bleibt: Wer die öffentlich kommunizierte Gesamtquote (<1 %, V1+V2 zusammen, dominiert durch V1) als Entwarnung kommuniziert, setzt implizit ein Qualitätsversprechen voraus, das das System nicht einlöst. Diese Interpretationslücke ist real, auch wenn das System sie nicht selbst produziert.

Präzisierung: Die Analyse in Teil II zeigt, dass das Prüfsystem — insbesondere V2 — faktisch Formeinhaltung kontrolliert, nicht Ausgaben und nicht Versorgungsqualität. Der normative Schadensbegriff (Abschnitt 3.6.5) definiert den “Schaden” als formale Regelabweichung, unabhängig von medizinischem Nutzen oder tatsächlicher Kostenwirkung. Das Prüfsystem ist damit weder ein Kostenkontrollinstrument (es fragt nicht, ob die Ausgabe sinnvoll war) noch ein Qualitätsinstrument (es fragt nicht, ob die Behandlung angemessen war) — es ist ein Formkontrollinstrument mit Sanktionswirkung. Diese funktionale Einordnung verschärft den Strohhalm-Einwand: Der Zertifikatsfehler ist nicht nur eine Interpretationslücke, sondern eine strukturelle Fehlzurordnung des gesamten Verfahrenszwecks.

9.3 Einwand 3: Das Präventions-Paradoxon — der Nutzen wird nie gerechnet (betrifft primär V1)

Der Einwand: Die Studie rechnet nur Kosten (Unterversorgung, Defensivmedizin, Folgeschäden), nicht den Nutzen. Ohne Prüfsystem könnten die Arzneimittelausgaben unkontrolliert steigen. Die Abschreckungswirkung ist real und möglicherweise volkswirtschaftlich bedeutsam.

Befund: Der Einwand ist berechtigt. Diese Analyse fokussiert auf die Schadensseite und erhebt nicht den Anspruch einer vollständigen Kosten-Nutzen-Analyse. Die Abschreckungswirkung des Prüfsystems ist real und schwer messbar — das macht sie nicht weniger real. Beide Seiten — Nutzen wie Schaden — argumentieren mit nicht-messbaren Größen. Dieses symmetrische Problem einzuräumen ist methodisch redlich. Ein natürliches Experiment bot sich 2017 mit der Abschaffung der Richtgrößenprüfung: Wenn der Verordnungsanstieg nach 2017 messbar war, spräche das für eine substantielle Abschreckungswirkung. Eine Auswertung der verfügbaren Daten (WIdO, GKV-Arzneimittelindex) zeigt: Die GKV-Arzneimittelausgaben stiegen nach 2017, jedoch primär durch patentgeschützte Hochpreisarzneimittel, nicht durch einen Mengenanstieg bei Standardverordnungen. Die Verordnungsmenge (DDD) war 2018 sogar rückläufig. Ein klarer “Dammbruch” nach Wegfall der Richtgrößen ist nicht nachweisbar — was darauf hindeutet, dass die Abschreckung durch Richtgrößen ohnehin begrenzt war. Allerdings substituierten regionale Prüfverfahren (Zielwerte, Durchschnittswerte) die Richtgrößen teilweise, sodass der kausale Schluss begrenzt ist.

9.4 Einwand 4: “Deterministisch” ist eine Setzung, kein Befund (betrifft V2)

Der Einwand: Die Eskalationspipeline für V2 (Einzelfallprüfung) ist fast komplett “k.D.” (keine Daten). “Deterministisch” als Eigenschaft zuzuschreiben, ohne über Transitionswahrscheinlichkeiten zu verfügen, ist ein *argumentum ad ignorantiam* — aus der Abwesenheit von Daten wird ein Befund konstruiert.

Befund: Der Einwand ist formal gültig. “k.D.” heißt: keine publizierten Daten verfügbar. Die Bezeichnung “deterministisch” beschreibt die *strukturelle Anlage* des Verfahrens (kein Beratungsschutz, normativer Schadensbegriff, kein Ermessensspielraum bei Formfehlern), nicht eine empirisch gemessene Transitionsrate. Wir formulieren deshalb: “strukturell so angelegt, dass nach Kassenantrag eine hohe Übergangswahrscheinlichkeit anzunehmen ist — empirisch jedoch nicht verifizierbar, weil die nötigen

Verfahrensdaten nicht publiziert werden.“ Die Ehrlichkeit über die Datenlücke schwächt das Argument nicht — sie ist selbst ein Befund über die Transparenz des Systems.

9.5 Einwand 5: Ein Drittel des Systems ist rationale Steuerung (betrifft V2)

Der Einwand: Geschätzt 35 % der V2-Prüfungen codieren medizinische Evidenz als Formregeln (AM-RL, G-BA-Beschlüsse, Biosimilar-Pflicht). Das System *ist* eine Evidenzsteuerung — die Studie übertreibt die Dysfunktionalität und zeichnet ein zu einseitiges Bild.

Befund: Der Einwand ist berechtigt und hat geschätzt 35–40 % Erklärungskraft (getestet als alternative Hypothese H2, siehe Anhang B). Drei Einschränkungen:

1. **Auch bei evidenzbasierter Steuerung fehlt der Lernkanal.** Der Arzt erfährt *dass* er zahlen muss, nicht *warum* die Evidenzlage so entschieden hat. Der punitive Kanal (V2) läuft parallel zum edukativen Kanal (CME/Fortbildung, § 95d SGB V), ohne mit ihm verbunden zu sein. Ein Arzt, der eine AM-RL-Anlage nicht kennt, wird bestraft, statt informiert.
2. **V2b (Kategorie B, ~40 %) bleibt vollständig dysfunktional.** Stempel-Regress 490.000 EUR bei medizinisch korrekter Behandlung ist durch keine Evidenzsteuerungslogik rechtfertigbar.
3. **Kein Beratungsschutz — auch nicht bei Kategorie A.** § 106b Abs. 2 S. 4 schließt “Beratung vor Regress” bei V2 gesetzlich aus, unabhängig davon ob die Prüfung evidenzbasiert oder rein formal ist.

Die Forderung dieser Studie präzisiert sich durch den Einwand: Nicht Abschaffung der Evidenzsteuerung (Kategorie A), sondern Ergänzung des punitiven Kanals um einen edukativen — Beratungsschutz und Vorabinformation *auch* bei V2 (vgl. Abschnitt 3.7).

9.6 Einwand 6: Positive Entwicklungen ausgeblendet (betrifft V1+V2)

Der Einwand: Das System reformiert sich: Abschaffung der Richtgrößenprüfung (2017), Differenzkostenregelung (BSG 2024), regionale Bagatellgrenzen. Die Studie zeichnet ein statisches Bild eines dynamischen Systems.

Befund: Drei wesentliche Reformen sind anzuerkennen:

- **Abschaffung Richtgrößenprüfung (2017):** Positiv, aber betrifft ausschließlich V1 (Auffälligkeitsprüfung). Die Einzelfallprüfung (V2) — deren strukturelle Asymmetrie den Kern dieser Studie bildet — blieb unangetastet.
- **Differenzkostenregelung (BSG B 6 KA 5/23 R, 2024):** Positiv, aber vom BSG explizit auf “wirtschaftlich unzumutbare” Verordnungen beschränkt. Bei “unzulässigen” Verordnungen (= Formfehler) wurde die Anwendung ausdrücklich ausgeschlossen — also genau dort, wo Lesart C den operativen Schwerpunkt verortet.
- **Regionale Bagatellgrenzen:** Regional unterschiedlich, nicht bundeseinheitlich. Schließen Hochbetragsregresse nicht aus.
- **Fristenverkürzung (TSVG 2019 / GVWG 2021):** Positiv. Die Ausschlussfrist wurde von 4 Jahren (BSG-Richterrecht) auf 2 Jahre (V1) bzw. 2,5 Jahre (V2) verkürzt (siehe Abschnitt 3.5.1). Das begrenzt die zeitliche Rückreichweite neuer Prüfungen — beseitigt aber nicht die strukturellen Probleme innerhalb laufender Verfahren.

Das System reformiert sich punktuell. Die strukturelle Asymmetrie zwischen V1 und V2 — insbesondere der fehlende Beratungsschutz (§ 106b Abs. 2 S. 4) und die Nicht-Anwendbarkeit der Differenzkostenregelung bei Formfehlern — bleibt unangetastet. Die Reformen adressieren die Symptome, nicht den in dieser Studie beschriebenen Mechanismus.

Zusammenfassung: Was diese Studie behauptet — und was nicht

Diese Studie behauptet **nicht**, dass das Wirtschaftlichkeitsprüfsystem abgeschafft werden sollte, dass alle Regresse ungerechtfertigt sind, oder dass Ärzte keiner Kontrolle bedürfen. Sie behauptet:

1. Das System misst überwiegend nicht, was es zu messen vorgibt (Zertifikatsfehler) — wobei ~35 % der V2-Prüfungen durchaus evidenzbasierte Steuerung leisten (Abschnitt 3.7). Das Problem ist nicht die Evidenz, sondern der Kommunikationskanal: punitiv statt edukativ.
2. Die Einzelfallprüfung ist strukturell asymmetrisch gegenüber der Auffälligkeitsprüfung ausgestaltet (kein Beratungsschutz, normativer Schadensbegriff).
3. Die Datenlage über die Wirkung des Systems ist so dünn, dass weder Befürworter noch Kritiker ihre Position empirisch vollständig belegen können.
4. Die Transparenzlücke ist nicht zufällig, sondern strukturell — und sie zu schließen wäre der wirksamste einzelne Schritt zur Versachlichung der Debatte.

10 Teil VII — Lösungsraum

10.1 Verweis auf PP-003: Das Regress-Transparenzportal

Die zentrale Lösung, die diese Studie unterstützt, ist nicht in ST-001 selbst beschrieben, sondern im Konzeptpapier **PP-003 – Regress-Transparenzportal**. Es schlägt ein anonymes, verifiziertes Meldeportal für ärztliche Regressforderungen vor, das die Datenlücke schließt, die in dieser Studie als zentrale institutionelle Lücke identifiziert wurde.

PP-003 ist ein Lösungsangebot, kein Anspruch. Die Studie ST-001 begründet, warum die Lücke existiert und welche Folgen sie hat. PP-003 zeigt einen praktikablen Weg, sie zu schließen.

10.2 Das Transparenz-Paradoxon — und warum PP-003 es berücksichtigt

Eine Transparenzforderung ist in der technokratisch aufgeklärten Debatte bequem — sie klingt selbstverständlich richtig. Die Organisationsforschung der letzten zwei Jahrzehnte hat aber gezeigt, dass Transparenz keine neutrale Eigenschaft eines Systems ist. Sie wirkt verhaltensändernd, und zwar nicht immer in die gewünschte Richtung. Wer ein Transparenzportal vorschlägt, muss diese Gegenwirkung ernst nehmen — sonst baut er einen weiteren Schritt im bürokratischen Rüstungswettlauf, den er eigentlich beenden will. Die entscheidende Referenz zu diesem Punkt ist Ethan Bernstein.

10.2.1 Bernsteins Befund

In einer heute vielzitierten Feldstudie in der zweitgrößten Mobiltelefon-Fabrik der Welt (China) hat Ethan S. Bernstein von der Harvard Business School dokumentiert, was er das “Transparency Paradox” nennt. Veröffentlicht als “*The Transparency Paradox: A Role for Privacy in Organizational Learning and Operational Control*” in *Administrative Science Quarterly* 57 (2), Juni 2012, S. 181–216 (DOI: 10.1177/0001839212453028). Die Kernbefunde:

- **Entgegen der Management-Erwartung** führt mehr Sichtbarkeit nicht zu mehr Produktivität. Sie führt, unter bestimmten Bedingungen, zu *weniger*.
- Beobachtete Akteure entwickeln *Verbergungstechniken* und bauen “Compliance Theater” auf, das der Beobachtung genügt, aber mit dem tatsächlichen Arbeitsvorgang nur noch lose verbunden ist.
- Sie verfallen in einen *Spotlight-Effekt*: Risiko- und Innovationsbereitschaft sinken, weil jede Abweichung vom Muster als potenzieller Fehler registriert werden könnte.
- Bernsteins empirisch belegter Gegenvorschlag: “**Zones of Privacy**” — bewusst entkoppelte, beobachtungsfreie Räume, in denen Akteure experimentieren, lernen und professionelle Urteilskraft einsetzen können, ohne unmittelbar sanktionsexponiert zu sein.

10.2.2 Die ernsthafte Kritik an PP-003

Angewandt auf das deutsche Regress-Transparenzportal ist das eine unbequeme, aber notwendige Kritik. Wer ein anonymes Meldeportal baut, das aggregierte Regressdaten pro Kasse, Wirtschaftsraum und Wirkstoffgruppe sichtbar macht, *verändert das Verhalten der Beteiligten* — nicht nur der Ärzte, die das

Portal befüllen, sondern vor allem der Kostenträger, die später darin auftauchen. Zwei pessimistische Szenarien sind anhand der Bernstein-Literatur zu erwarten:

1. **Compliance Theater auf Kassenseite:** Kassen, die sich als “Top-Ablehner” oder “Ärzte-Schreck” in einem öffentlichen Dashboard wiederfinden, haben nicht unbedingt den Anreiz, milder zu prüfen. Sie haben zunächst den Anreiz, ihr Prüfverhalten *informeller* und *weniger sichtbar* zu machen — etwa über Beratungsgespräche, vertrauliche Vergleiche, modifizierte Auswahl-Algorithmen, die die statistischen Spitzen glätten, ohne die Praxis zu ändern.
2. **Spotlight-Effekt auf Arztseite:** Die öffentliche Sichtbarkeit dokumentierter Regressfälle könnte, anders als intendiert, die subjektive Bedrohungswahrnehmung verstärken, statt sie zu kalibrieren. Einzelne Fallbilder — etwa der 491.000-EUR-Stempelregress (BSG B 6 KA 9/24 R) — sind psychologisch hochwirksam und lassen sich im Aggregations-Dashboard nicht wegrechnen. Die Verfügbarkeitsheuristik würde die reale Wahrscheinlichkeit überformen und die Defensivmedizin eher zusätzlich befördern.

Beide Szenarien sind nicht zwangsläufig — aber sie sind plausibel genug, um bei der Gestaltung des Portals mitgedacht zu werden.

10.2.3 Warum PP-003 robuster ist, als es auf den ersten Blick wirkt

Eine detaillierte Prüfung von PP-003 zeigt, dass mehrere Gestaltungsentscheidungen das Bernsteinsche Paradoxon bereits bewusst umgehen — wenngleich im Konzeptpapier nicht unter diesem Namen:

- **Wahlkabinen-Prinzip:** Die strikte kryptografische Trennung zwischen Identitätsprüfung (EFN-Verifikation) und Falldatenbank stellt sicher, dass die meldende Person nicht auf ihren Meldungen zurückverfolgt werden kann. Das ist *präzise* das, was Bernstein eine “Zone of Privacy” für den Frontlinien-Akteur nennt: Der Arzt kann seine Erfahrung in den Datenpool einspeisen, ohne dass sie auf ihn zurückfällt. Die Bereitschaft, überhaupt zu melden, steht und fällt mit diesem Schutz.
- **k-Anonymität ($k \geq 5$):** Keine Zelle im öffentlichen Dashboard wird veröffentlicht, in der weniger als fünf Einzelmeldungen zusammenlaufen. Das verhindert die Rück-Identifikation einzelner Ärzte über Kombinationen seltener Merkmale — und begrenzt zugleich die psychologische Wirkung von Einzelfall-Spotlights.
- **Fokus auf Aggregate, nicht auf Einzelfälle:** Das Dashboard publiziert Verhältniszahlen und Trends, keine anekdotischen Erzählungen. Das zielt bewusst auf die Kalibrierung des Wahrscheinlichkeits-Empfindens und gegen den Spotlight-Effekt einzelner Schock-Geschichten. Einzelfall-Dokumentation bleibt Journalismus und Zivilgesellschaft überlassen, nicht dem Portal selbst.

10.2.4 Was PP-003 allein nicht lösen kann

Ehrlich gesagt: Ein Portal allein wird das Bernsteinsche Paradoxon auf der Kassenseite nicht beheben. Wenn Krankenkassen sich aus der öffentlichen Sichtbarkeit zurückziehen und ihre Sanktionspraxis in informellere Kanäle verlagern, verschiebt das Portal das Problem nur, ohne es zu lösen. Der strukturelle Anreiz zum Compliance Theater auf Kostenträgerseite bleibt — es sei denn, das Portal wird durch **rechtlich bindende Berichtspflichten** und **unabhängige Aufsicht** flankiert. Genau diese Flankierung leisten die in der nächsten Subsection vorgeschlagenen minimal-invasiven Reformhebel (Halbsatz-Streich § 106b Abs. 2 S. 4, Publikationspflicht der Prüfungsstellen, Sichtbarmachung § 48 BMV-Ä).

Strategische Konsequenz: PP-003 ist ein notwendiger, aber nicht hinreichender Schritt. Seine Wirkung wird voll erst im Verbund mit strukturellen Reformen sichtbar. Das Portal erzeugt den *informationellen Druck*, die Reformhebel den *institutionellen*. Eines ohne das andere verpufft.

10.3 Die juristisch belegten Top-3-Schutzmaßnahmen

Eine eigene Detailrecherche zur Praxisrealität zeigt: Es gibt drei juristisch wirksame Schutzmaßnahmen, die in Sozialgerichtsverfahren regelmäßig den Unterschied machen:

1. **Lückenlose Dokumentation zum Zeitpunkt der Verordnung.** SG Marburg 14.02.2024 (S 18 KA 96/23): Wer die Behandlungsdokumentation vorlegen kann, gewinnt. BSG B 6 KA 26/13: nachgeordnete Dokumentation reicht nicht; sie muss zeitnah erstellt sein.
2. **Vorab-Klärung in den expliziten Ausnahmefällen** (Cannabis nach § 31 Abs. 6 SGB V, häusliche Krankenpflege § 37, Soziotherapie § 37a, stationäre Reha § 40, bestimmte Heil-/Hilfsmittel). **Wichtig:** Bei normalen Arzneimitteln mit Indikation ist Vorab-Genehmigung gesetzlich verboten (§ 29 BMV-Ä). Hier hilft nur defensive Dokumentation oder im Grenzfall eine BSG-konforme Bitte um Stellungnahme (B 6 KA 27/12 R) — die juristisch nicht bindet, aber Beweislast-Vorteile schafft.
3. **Substanziierter Vortrag von Praxisbesonderheiten BEREITS im Verwaltungsverfahren** — nicht erst vor dem Sozialgericht (LSG BW 15.11.2023, SG Marburg 31.01.2024).

Alle drei Maßnahmen sind softwaregestützt umsetzbar. Genau das ist der Anlass für die folgende Skizze.

10.4 Open-Source-Verordnungstool: Konkrete MVP-Spezifikation

Eine eigene Detailrecherche (siehe `RECHERCHE_PVS_TOOL_MACHBARKEIT_DETAIL.md`) zeigt: Ein fokussiertes Browser-Tool ohne Patientendaten ist in 6–9 Monaten von 1–2 Entwickler:innen machbar (Prototype-Fund-Volumen ca. 47.500 EUR). Es ist ausdrücklich *kein Praxisverwaltungssystem* (PVS), sondern ein Companion-Tool, das daneben arbeitet.

Eingabe: ICD-10-GM-Code + Wirkstoff/ATC.

Verarbeitung: Plausibilitätsprüfung gegen öffentliche Regelwerke (AM-RL Anlage III/V/VI, PRISCUS 2.0, GKV-SV-Praxisbesonderheiten).

Ausgabe: Ampel (grün / gelb / rot) mit Begründungstext und Quellenverweis.

MUST-Have-Funktionen für den MVP:

1. Echtzeit-Plausibilitätsprüfung gegen AM-RL Anlage III/V/VI
2. Strukturierte Begründungspflicht-Templates mit Direkt-Eintrag in die Patientenakte (Audit-Trail)
3. Container-sensitiver Vorab-Klärungs-Workflow (Cannabis vs. normale Arzneimittel — verschiedene Rechtswege)
4. Bundesweite Praxisbesonderheiten-Erkennung mit Quartalsmarkierung
5. Manipulationssicherer Compliance-Log (Beweiskraft im Sozialgerichtsverfahren)

Trägermodell-Empfehlung: Eine gemeinnützige Trägerorganisation in Kooperation mit einem medizinischen Review-Partner (z. B. Therapiefreiheit e.V., DDG, BVDN). Förderprofil: Prototype Fund der Open Knowledge Foundation Deutschland oder vergleichbare Civic-Tech-Förderlinien. Keine KV als Bauträger (struktureller Interessenkonflikt).

Begründung gegen ein vollständiges Open-Source-PVS: Ein vollständiges KBV-zertifiziertes PVS würde 60–120 Personenjahre Initialentwicklung plus 1–2 Mio. EUR/Jahr Betrieb erfordern (Hauptknackpunkte: Datenlizenzen ABDA/MDM, KBV-Zertifizierung, gematik-Audits). Für einen Think Tank nicht machbar. Das Companion-Tool umgeht diese Hürden, indem es ausdrücklich kein PVS ist und keine Patientendaten verarbeitet.

10.5 Politische Reform: Drei minimal-invasive Hebel

Aus den vorangegangenen Befunden ergeben sich drei Reformschritte, die jeweils einzellig im Gesetztext umsetzbar sind und politisch realistisch erscheinen, weil sie den bestehenden Container nicht sprengen, sondern entgräten. Sie sind nach Aufwand-Wirkung-Verhältnis priorisiert:

Hebel 1: Halbsatz-Streich § 106b Abs. 2 S. 4 SGB V

Der vierte Satz von § 106b Abs. 2 SGB V schließt die Einzelfallprüfung explizit aus dem Schutz "Beratung vor Regress" aus. Eine Streichung dieses Halbsatzes wäre die kleinste mögliche Änderung mit der größten Wirkung: Damit gälte auch für Einzelfallprüfungen, dass beim erstmaligen Anlass eine Beratung statt eines Regresses erfolgt.

Begründung: Die Asymmetrie zwischen Auffälligkeits- und Einzelfallprüfung beim Beratungsschutz (siehe Teil II) ist die einzige rechtsdogmatisch erklärungsbedürftige Schutzlücke. Sie wurde 2017 im GKV-VSG eingefügt und nicht begründet.

Aufwand: Eine Zeile.

Wirkung: Senkt den Druck auf alle Vertragsärzte ohne die Prüfungsmöglichkeit aufzuheben.

Politische Akzeptanz: Hoch, weil bereits in der KBV-Kritik 2015 vorgeschlagen.

Hebel 2: Publikationspflicht der Prüfungsstellen (Vollzugsstatistik)

§ 106c SGB V regelt heute die Aufgaben der Prüfungsstellen, enthält aber keine Veröffentlichungspflicht für die Vollzugsstatistik. Eine Ergänzung um einen neuen Absatz "Die Prüfungsstelle veröffentlicht jährlich eine Statistik über Verfahrenseinleitungen, -einstellungen und -gründe. Die Daten sind in maschinenlesbarer Form bereitzustellen" wäre die zweite minimale Reform.

Begründung: Ohne diese Daten ist jede Effizienzdiskussion unmöglich. Der Wegfall der Informationsasymmetrie ist nach der spieltheoretischen Analyse (Teil III) die wirkungsmächtigste Einzelintervention. Sie würde auch das in PP-003 vorgeschlagene Transparenzportal teilweise überflüssig machen — was gewollt ist.

Aufwand: Ein Absatz.

Wirkung: Ermöglicht erstmals empirische Aufsicht und kalibriert die Risikowahrnehmung der Ärzte.

Politische Akzeptanz: Mittel, weil die GPE strukturell verlieren — aber durch die KV RLP bereits präzedenzlos erlaubt.

Hebel 3: Sichtbarmachung von § 48 BMV-Ä im SGB V

§ 48 BMV-Ä ("Sonstiger Schaden") ist die rechtliche Grundlage des Stempelregresses (BSG B 6 KA 9/24 R, 490.000 EUR), lebt aber außerhalb des SGB V im Bundesmantelvertrag. Wer "nur" das Gesetz liest, übersieht ihn. Eine Aufnahme des Tatbestands als neuer § 106e SGB V (oder eine ausdrückliche Verlinkung im SGB V) wäre der dritte minimale Schritt.

Begründung: Die Sichtbarmachung ist eine Bedingung dafür, dass die rechtsdogmatische Diskussion über Bestimmtheit und Verhältnismäßigkeit (siehe Verfassungsrechts-Teil) überhaupt im allgemeinen Rechtsbewusstsein geführt werden kann.

Aufwand: Ein neuer Paragraf oder eine Verlinkung.

Wirkung: Ändert die Norm nicht inhaltlich, hebt aber die Sichtbarkeit.

Politische Akzeptanz: Hoch, weil rein redaktionell — kein Akteur verliert dadurch.

Was diese drei Hebel nicht lösen

Die Reform-Skizze adressiert nicht den *strukturellen Doppelbind* aus Teil II (§ 12 SGB V als Drei-Code-Kollision). Dessen Auflösung wäre eine größere Reform — sie müsste das Wirtschaftlichkeitsgebot von der Sanktionsmechanik trennen. Die natürliche Anschlussfrage führt zu einem breiteren Lösungsraum.

10.6 Sieben weitere Interventionspfade

Die folgende Liste wurde durch eine unabhängige Gegenlesung der Studie ermittelt (frischer Blick ohne Kenntnis der Recherchegeschichte). Die Vorschläge leiten sich ausschließlich aus den in ST-001 dokumentierten Befunden ab. Reihenfolge nach geschätzter Wirksamkeit, nicht nach Realisierbarkeit.

1. **Öffnung der operativen Prüfkataloge für Ärzte.** Die Studie zeigt (Teil II), dass Kassen und Apotheken Echtzeit-Prüfsoftware besitzen, während der verordnende Arzt die konkreten Prüfkriterien nicht kennt. Das verletzt das rechtsstaatliche Bestimmtheitsgebot: Wer für Formfehler existenziell haftet, muss die Maßstäbe kennen. Eine Veröffentlichungspflicht für die operativen Prüfkataloge in den regionalen Prüfvereinbarungen würde die Informationsasymmetrie direkt beseitigen. *Aufwand: mittel (Verwaltungsvorschrift). Realisierbarkeit: mittel — rechtsstaatlich schwer abzulehnen.*

2. **Sanktionsfolge für unbegründete Kassenanträge.** Die Studie belegt (Teil II, Machtungleichgewicht): Für die Kasse ist ein unbegründeter Antrag folgenlos — keine Kostentragung, keine Mengenbegrenzung. Das erzeugt das Abmahnwesen-Muster. Eine Kostenfolge bei vollständiger Verwerfung des Antrags (z. B. Pflicht zur Übernahme der Stellungnahmekosten des Arztes) würde die Antragsqualität strukturell erhöhen. Das Prinzip existiert in der ZPO (§ 91) und im Abmahnrecht bereits. *Aufwand: mittel (neuer Absatz in § 106b). Realisierbarkeit: niedrig–mittel.*
3. **Positive Rückkopplungssignale im Prüfsystem.** Die Regelkreisanalyse (Teil III) identifiziert: Das System sendet ausschließlich Minus-Signale. Kein Arzt erfährt je “Ihre Ordnungspraxis ist unauffällig”. Eine institutionalisierte positive Rückmeldung — etwa ein jährliches Unauffälligkeits-Zertifikat der KV bei regelkonformer Praxis — würde das Panoptikum-Gleichgewicht durchbrechen und eine kalibrierbare Risikoeinschätzung ermöglichen. Internationales Vorbild: QOF im NHS. *Aufwand: gering (KV-interne Maßnahme, kein Gesetz nötig). Realisierbarkeit: hoch.*
4. **Kostenfolgen-Pflichtabschätzung bei Regressanträgen.** Die Public-Choice-Analyse (Teil V) zeigt: Die Netto-Einnahmen aus Regressen (5–50 Mio. EUR/Jahr) stehen in keinem Verhältnis zu den Systemkosten (4,33 Mrd. EUR ambulante Bürokratie). Eine Pflichtabschätzung des erwarteten Regressbetrags vs. der Verfahrenskosten vor jedem V2-Antrag würde irrationale Kleinstanträge unterbinden. *Aufwand: mittel (Verwaltungsvorschrift). Realisierbarkeit: mittel — das Argument “Wirtschaftlichkeit der Wirtschaftlichkeitsprüfung” ist politisch schwer abzulehnen.*
5. **Bundeseinheitliche Bagatellgrenze für die Einzelfallprüfung.** Die Studie dokumentiert (Top-10 Inkonsistenzen, Nr. 4): Regionale Bagatellgrenzen variieren zwischen 30 und 150 EUR — eine verfassungsrechtlich bedenkliche Ungleichbehandlung. Eine bundesgesetzliche Mindestgrenze (z. B. 200 EUR) in § 106b SGB V würde Formfehler-Regresse bei Niedrigbeträgen eliminieren, die maximal Angst und minimal Ertrag produzieren. *Aufwand: gering (ein Absatz). Realisierbarkeit: hoch — bereits in KBV-Forderungsliste.*
6. **Maximale Gesamtverfahrensdauer gesetzlich begrenzen.** Die Studie dokumentiert (Abschnitt 3.5.1): Ausschlussfristen begrenzen nur den Erstbescheid. Das BSG entschied Fälle 8–11 Jahre nach dem Verordnungszeitraum. Eine gesetzliche Gesamtverfahrensobergrenze (z. B. 5 Jahre ab Verordnung bis rechtskräftiger Abschluss) würde die psychologische Dauerbelastung begrenzen, die Ribbat 2023 als Haupttreiber der Defensivmedizin identifiziert. *Aufwand: mittel (neuer Absatz in § 106). Realisierbarkeit: mittel — justizpolitisch anschlussfähig an die TSVG-Fristenverkürzung 2019.*
7. **Unabhängige Effizienzprüfung des Prüfsystems selbst.** Die Studie belegt (Teil V, Niskanen-Analyse): Kein Akteur (BRH, BAS, SVR, Bundestag) prüft die Wirtschaftlichkeit der Wirtschaftlichkeitsprüfung. Die GPE-Kosten sind extern nicht verifizierbar. Ein gesetzlicher Evaluationsauftrag an den SVR Gesundheit oder das IQWiG — alle 5 Jahre eine Kosten-Nutzen-Analyse des Prüfsystems — würde die Niskanen-Dynamik der institutionellen Selbsterhaltung durchbrechen. *Aufwand: gering (Evaluationsklausel in § 106c). Realisierbarkeit: hoch — das Prinzip “Evaluation öffentlicher Ausgaben” ist politischer Konsens.*

Der ursprünglich an dieser Stelle aufgeführte achte Interventionspfad — die Versorgungsprüfung als symmetrisches Messinstrument für §§ 70, 135a SGB V — ist aus Kohärenzgründen in eine eigene Sub-section herausgelöst (siehe folgender Abschnitt 10.7). Er adressiert den übergeordneten Zertifikatsfehler — die Messrichtung — und verlangt eine eigene methodische Diskussion, die über den Rahmen einer Enumerate-Zeile hinausgeht.

10.7 Versorgungsprüfung: Messinstrument für §§ 70, 135a SGB V

Die vorangegangenen Interventionspfade adressieren Asymmetrien *innerhalb* des bestehenden Wirtschaftlichkeitsprüfsystems: Beratungsschutz, Transparenz, Verfahrensdauer, Kostenfolgen. Eine strukturell andere Lücke bleibt jedoch offen: Das gesamte Regresssystem misst ausschließlich in eine Richtung (“zu viel verordnet”). Für die andere Richtung — Unterversorgung, Fehlversorgung im Sinne der SVR-Trias — existiert im ambulanten Bereich *kein institutionalisiertes Monitoring-Verfahren*. Das ist der übergeordnete Zertifikatsfehler (siehe Teil II): eine **Messrichtungs-Asymmetrie**, die gesetzlich im § 70 SGB V (bedarfsgerechte Versorgung) und § 135a SGB V (Qualität nach wissenschaftlichem Erkenntnisstand) verankert ist, aber ohne eigenes Prüfinstrument bleibt.

10.7.1 Der Vorschlag: Symmetrische Prüfarchitektur

Analog zur Wirtschaftlichkeitsprüfung (V1/V2) schlägt diese Studie ein **Versorgungsprüfverfahren** vor, das die zweite Richtung der SVR-Trias adressiert — nicht als Sanktionsinstrument gegen Einzelärzte, sondern als institutionelles Signaldetektions-Instrument für Unterversorgung und Fehlversorgung auf Praxis- und Regionalebene. Die Kerngestaltung:

- **Anzeichenprüfung.** Signalorientiert statt durchsuchend: auffällige Hospitalisierungsraten bei ambulant-sensitiven Diagnosen (ACSC-Indikatoren, Zi-Versorgungsatlas [1]), Kaskadenüberweisungen, verzögerte Facharzttermine, Medikationsunterlassung bei leitlinienklaren Indikationen (DEGAM-S2e [7], DGIM “Klug entscheiden” [6]).
- **Beratung statt Sanktion im Erstzyklus.** Die “Beratung vor Regress“-Systematik aus § 106b Abs. 2 S. 2 SGB V (Regelungsentscheidung mit Verwaltungsaktqualität, BSG B 6 KA 21/15 R) wird symmetrisch übertragen: Erstauffälligkeiten lösen strukturierte Feedback-Gespräche aus, nicht finanzielle Rückforderungen.
- **Anonymisierte Aggregation.** Keine personalisierte Fahndung; Ziel ist Versorgungskartografie auf Regional- und Fachgruppenebene (vergleichbar der Zi-Versorgungsatlas-Logik), nicht individuelle Schuldzuweisung.
- **Plausible Trägerschaft.** Rechtsgrundlage analog § 136 SGB V (G-BA-Qualitätssicherung); operative Umsetzung durch KV-Qualitätszirkel, erweiterten Medizinischen Dienst oder ein gestärktes Zi. Kein neuer Apparat zwingend nötig — bestehende Strukturen rekombinieren.

Die konzeptionelle Leitidee: Das System soll Unterlassung nicht mehr strukturell belohnen (wie es die gegenwärtige Messrichtungs-Asymmetrie tut), sondern sie aktiv sichtbar machen. Das adressiert den in Teil II als “übergeordneter Zertifikatsfehler” bezeichneten Strukturmangel an der Wurzel.

10.7.2 Grenzen und methodische Vorbehalte

Eine Versorgungsprüfung ist kein Selbstläufer. Drei methodische Vorbehalte müssen offen benannt werden, bevor der Vorschlag in politische Umsetzung übersetzt werden kann:

1. **Kodier-Arbitrage.** Signale wie Hospitalisierungsraten reagieren nicht nur auf tatsächliche Versorgungsqualität, sondern auch auf Kodierverhalten (Upcoding, Diagnosenverschiebung). Vor jeder Verwendung als Prüfsignal müsste eine Kodier-Qualitätskontrolle etabliert werden — vergleichbar den Plausibilitätsprüfungen in der stationären DRG-Abrechnung. Ohne diese Flankierung entstehen Scheinsignale.
2. **ACSC-Aggregat-Vorbehalte.** Die Ambulatory Care Sensitive Conditions sind ein anerkannter internationaler Indikator für ambulant vermeidbare Hospitalisierungen (Schwartz/Glaeske-Tradition, vgl. [2]). Der Indikator ist jedoch **aggregiert** gedacht (Regionalebene), nicht als Einzelpraxis-Benchmark. Versuche, ACSC-Raten auf Praxisebene herunterzubrechen, scheitern typischerweise an Ko-Morbidität, Patientenselektion und Case-Mix-Heterogenität. Eine Versorgungsprüfung auf Praxisebene müsste diese Heterogenität methodisch berücksichtigen — oder sich auf Fachgruppen- und Regionalebene beschränken.
3. **Datenschutz und Doppelbind.** Eine Prüfung, die “zu wenig versorgt” misst, benötigt Daten über tatsächlich *nicht erfolgte* Leistungen — eine strukturell schwierigere Beobachtungsaufgabe als die Prüfung tatsächlich erfolgter Leistungen. Operationalisierbar wird das nur über Proxy-Indikatoren (Leitlinienadhärenz, ACSC, Patient-Reported Outcomes), deren Aussagekraft für Einzelfallentscheidungen systematisch begrenzt ist.

10.7.3 Anschlussfähigkeit

Politische und fachliche Anschlusspunkte existieren: Der SVR Gesundheit hat in seinen Gutachten 2000/2001 Band III (Über-, Unter-, Fehlversorgung; [15]) und in nachfolgenden Fortschreibungen (2018, 2023, 2024) die Unterversorgungs-Diagnose mehrfach aufgegriffen, ohne dass ein operatives Messinstrument etabliert wurde. Die DEGAM-S2e-Leitlinie “Schutz vor Über- und Unterversorgung” (053/045, 5. Aktualisierung 2025, [7]) liefert bereits priorisierte Negativ- und Positiv-Empfehlungen für den hausärztlichen Bereich; die DGIM-Initiative “Klug entscheiden” [6] ist das internistische Pendant. Beide Instrumente

sind *Empfehlungen ohne Messinfrastruktur*. Eine Versorgungsprüfung würde diese Lücke schließen — und zugleich den in Teil II begründeten übergeordneten Zertifikatsfehler strukturell adressieren.

Aufwand: hoch (neue gesetzliche Grundlage, Messmethodikentwicklung, Datenschutzkonzept, Kodierqualitätskontrolle). *Realisierbarkeit*: mittel–niedrig kurzfristig, mittel im Mehrjahreshorizont — politisch anschlussfähig an “Klug entscheiden”, DEGAM-Negativempfehlungen und die G-BA-Qualitätssicherung. *Wirkung*: transformativ; adressiert als einzige Lösung den übergeordneten Zertifikatsfehler.

10.7.4 Konzeptioneller Vorschlag: Governance-Pharmakovigilanz

Die Pharmakovigilanz überwacht systematisch die Nebenwirkungen von Arzneimitteln nach der Zulassung. Für regulatorische Eingriffe in die Versorgungspraxis existiert kein Äquivalent. Weder der SVR Gesundheit noch das IQWiG noch der Bundesrechnungshof evaluieren systematisch, ob die Wirtschaftlichkeitsprüfung *mehr Schaden anrichtet als sie verhindert*. Die vorliegende Studie argumentiert, dass ein solches Monitoring — eine **Governance-Pharmakovigilanz** — institutionalisiert werden sollte: eine regelmäßige, unabhängige Bewertung der Versorgungs-Nebenwirkungen regulatorischer Maßnahmen, mit denselben methodischen Standards, die für Medikamente selbstverständlich sind (Meldepflichten, Signaldetektion, regelmäßige Benefit-Risk-Assessments).

Verhältnis zu PP-003 und den drei Minimalhebeln: PP-003 und die Hebel 1–3 (Abschnitt oben) sind kurzfristig umsetzbar und brauchen keine politische Mehrheit. Die sieben hier genannten Pfade setzen teilweise institutionelle Initiative voraus, ergänzen aber den Lösungsraum in Dimensionen, die PP-003 allein nicht adressiert: Machtungleichgewicht (Nr. 2, 4), Informationsasymmetrie beim Normadressaten (Nr. 1), Verfahrensdauer (Nr. 6), Systemselbstevaluation (Nr. 7) und positive Anreizsetzung (Nr. 3).

10.8 Kosten-Nutzen-Vergleich aller Lösungsvorschläge

Die folgende Tabelle bewertet alle in dieser Studie entwickelten Lösungsvorschläge nach Aufwand, politischer Realisierbarkeit, erwartetem Nutzen und resultierendem Kosten-Nutzen-Verhältnis (KNV). Die Einschätzungen stützen sich auf die in den vorhergehenden Abschnitten dargestellten Begründungen.

#	Maßnahme	Aufw.	Realis.	Nutzen	KNV	Zeit	Zivil-gesell-schaft
1	Halbsatz-Streich § 106b Abs. 2 S. 4 (Beratungsschutz für V2)	gering	hoch	hoch	A+	kurz	indirekt
2	Sichtbarmachung BMV-Ä im SGB V	gering	hoch	mittel	A	kurz	indirekt
3	Bundeseinheitliche Bagatellgrenze	gering	hoch	mittel	A	kurz	indirekt
4	Positive Rückkopplung (Unauffälligkeits-Zertifikat)	gering	hoch	mittel	A	kurz	indirekt
5	Unabhängige Effizienzprüfung des Prüfsystems	gering	hoch	hoch	A	mittel	indirekt
6	Publikationspflicht der Prüfungsstellen (Hebel 2)	gering	mittel	transform.	A–	kurz	indirekt
7	PP-003: Regress-Transparenzportal	mittel	mittel	hoch	B+	mittel	direkt
8	Öffnung der operativen Prüfkataloge	mittel	mittel	hoch	B+	mittel	indirekt

9	Kostenfolgen-Pflichtabschätzung bei Anträgen		mittel	mittel	mittel	B	mittel	indirekt
10	Maximale Gesamtverfahrensdauer		mittel	mittel	mittel	B	mittel	indirekt
11	Open-Source-Verordnungstool (vgl. VerordnungsAmpel)		mittel	mittel	mittel	B	mittel	direkt
12	Sanktionsfolge für unbegründete Kassenanträge		mittel	niedrig	hoch	B	lang	indirekt
13	IFG-Anfragen an Prüfungsstellen		gering	niedrig	gering–mittel	C	kurz	direkt
14	Governance-Pharmakovigilanz		hoch	niedrig	transform.	B–	lang	indirekt
15	Versorgungsprüfung (§§ 70, 135a SGB V)		hoch	mittel	transform.	B	lang	indirekt

*Aufw. = legislativer, technischer, finanzieller Aufwand. Realis. = politische Machbarkeit. KNV = Kosten-Nutzen-Verhältnis (A+ bis C). Zeit: kurz < 1 J., mittel 1–3 J., lang > 3 J. **Zivilgesellschaft:** direkt = von zivilgesellschaftlichen Akteuren ohne gesetzgeberische Beteiligung umsetzbar; indirekt = nur über Information, PR, Lobby an Gesetzgeber/Selbstverwaltung adressierbar.*

Drei direkt zivilgesellschaftlich adressierbare Maßnahmen. Von den 15 Maßnahmen sind nur drei *ohne* parlamentarische, exekutive oder selbstverwaltungsrechtliche Beteiligung umsetzbar: **Rang 7** (PP-003 Transparenzportal — empirische Datenerhebung durch eine gemeinnützige Trägerorganisation), **Rang 11** (Open-Source-Verordnungstool — vgl. die bestehende Software VerordnungsAmpel, GitHub research-line/verordnungsampel) und **Rang 13** (IFG-Anfragen an Prüfungsstellen — niedrighschwellige Bürgerrechtsnutzung). Die übrigen zwölf Maßnahmen (Ränge 1–6, 8–10, 12, 14–15) erfordern legislative oder selbstverwaltungsinterne Akteursentscheidungen — die Zivilgesellschaft kann sie nur mittelbar über Öffentlichkeitsarbeit, Lobby und Information beeinflussen. **Diese Konvergenz ist nicht zufällig:** Ein Forschungsbericht, ein Konzeptpapier und eine Software-Veröffentlichung sind genau die drei Hebel, die Um:bruch in dieser Publikation tatsächlich auf den Weg bringt — die anderen zwölf Maßnahmen sind Forderungen an andere Akteure.

Einordnung PP-003: Das Regress-Transparenzportal positioniert sich im oberen Mittelfeld (Rang 7). Es ist — wie diese Studie betont — *notwendig, aber nicht hinreichend*. Seine strategische Funktion ist die eines zivilgesellschaftlichen Druckaufbaus: Wird die Publikationspflicht (Rang 6) politisch realisiert, wird das Portal teilweise überflüssig — was ausdrücklich das gewünschte Ergebnis wäre. PP-003 ist der Plan B, der Plan A erzwingen soll.

Strategisches Fazit: Die höchste Hebelwirkung liegt in der Kombination der Ränge 1–6: geringe Aufwände, hohe Realisierbarkeit, kurzfristig umsetzbar. Der Halbsatz-Streich (Rang 1) ist der effizienteste Einzelhebel — *eine Zeile Gesetzestext* würde die strukturelle Asymmetrie zwischen V1 und V2 beseitigen und den wichtigsten einzelnen Treiber der Regressangst eliminieren.

11 Was diese Studie zeigt — und was nicht

Nach sieben Teilen (historische Schichtung, rechtsdogmatische Analyse, Verhaltensökonomie, Folgekosten, institutionelle Analyse, internationaler Vergleich, Lösungsraum) lohnt ein Bogenschluss: Was ist nach 95 Seiten Analyse belegt, was ist plausibel gemacht, und was bleibt Hypothese?

11.1 Der Bogenschluss: Die drei Zertifikatsfehler

Die Studie verdichtet ihr Gesamtergebnis in einer einzigen diagnostischen Konstruktion: **Das Wirtschaftlichkeitsprüfsystem leidet an drei Zertifikatsfehlern**, die nicht auf der gleichen Ebene liegen, sondern aufeinander aufbauen:

1. **V1-Zertifikatsfehler (Messinhalt I).** Die Auffälligkeitsprüfung misst *Kostenabweichung vom Fachgruppendurchschnitt*, gibt aber vor, *medizinische Unwirtschaftlichkeit* zu messen. Für ein Screening-Verfahren ist die hohe Verwerfungsquote (99,7 %) technisch erwartet — sie ist nicht das Problem. Das Problem ist der Transfer der Verfahrenskosten (Angst, Dokumentationsaufwand, Verhaltensänderung) auf alle markierten Ärzte, auch wenn 913 von 916 keinen Regress erhalten. V1 schadet nicht durch falsche Sanktionen, sondern durch diffuse Disziplinierung.
2. **V2-Zertifikatsfehler (Messinhalt II).** Die Einzelfallprüfung beansprucht, medizinische Unwirtschaftlichkeit zu prüfen (§ 106b Abs. 1 SGB V), prüft faktisch aber *Formkonformität*. Dieser Befund gilt uneingeschränkt für **V2b (i)** (reine Formfehler), abgeschwächt für **V2b (ii)** (inhaltliche Unzulässigkeit; codiert Evidenz indirekt) und gar nicht für **V2a** (unwirtschaftliche leitlinienkonforme Verordnungen; dort besteht echte Verteidigungsmöglichkeit). Die Konsequenz: Rund 60–65 % der V2-Verfahren sind dysfunktional, ca. 35–40 % codieren medizinische Evidenz punitiv statt edukativ.
3. **Übergeordneter Zertifikatsfehler (Messrichtung).** Beide Verfahren prüfen ausschließlich *„zu viel verordnet“*. Für die andere Richtung — Unterversorgung und Fehlversorgung im Sinne der SVR-Trias nach §§ 70, 135a SGB V — existiert im ambulanten Bereich kein Sanktions- oder Korrekturinstrument auf Praxisebene. Aggregate werden gemessen (Bedarfsplanung, Zi-Versorgungsatlas, ACSC-Hospitalisierungen), aber nicht mit operativer Einzelleistungserbringer-Rückkopplung verbunden. Ergebnis: Das System belohnt Unterlassung und bestraft Handeln.

Die Reihenfolge ist nicht beliebig. Der erste Fehler wäre durch bessere Kalibrierung und positive Rückkopplungssignale (Unauffälligkeits-Zertifikat, Lösung #4) handhabbar. Der zweite verlangt die Trennung des punitiven vom edukativen Kanal (Beratungsschutz auch für V2, Hebel 1). Der dritte verlangt eine strukturelle Erweiterung des Systems um ein symmetrisches Gegeninstrument (Versorgungsprüfung, Abschnitt 10.7). Die ersten beiden sind innerhalb des bestehenden Containers reformierbar. Der dritte verlangt, den Container selbst zu erweitern.

11.2 Was belegt ist, was plausibel ist, was Hypothese bleibt

Belegt (empirisch abgesichert, peer-reviewed oder offiziell publiziert):

- Die Messrichtungs-Asymmetrie (§ 70 SGB V ohne Praxisebenen-Korrekturinstrument) — Rechtsdogmatik und Systembeschreibung.
- Der normative Schadensbegriff und seine Konsequenzen für V2b (BSG B 6 KA 5/09 R, B 6 KA 9/24 R, 490.000 EUR Stempel-Regress).
- Die strukturelle Asymmetrie zwischen V1 und V2 (§ 106b Abs. 2 S. 2 vs. S. 4 SGB V, Beratungsschutz-Lücke).
- Die V1-Endquote von ca. 0,1 % (Virchowbund 2018, KV BaWü 2022).
- Die Existenz regional höherer Antragszahlen bei V2 (BMG GVSG 2024: ca. 47.000 Verfahren bundesweit; SpiFa 2024: 13.332 festgesetzte Regresse in Bayern).
- Die Verhaltenseffekte aus Ribbat 2023 (n=770, 41/39 % Rücklauf; 47/37/51/72 % auf den Kernindikatoren; 95 %-CIs berechnet).

Plausibel gemacht (theoretisch und modellgestützt, aber nicht empirisch replikationssicher):

- Die 60–99 %-Bandbreite der Verfahrensbetroffenheit in drei Jahren (Poisson-Modell mit $\lambda \in [0,30; 1,48]$).
- Die Niskanen-Dynamik der GPE als Public-Choice-Modell (keine direkte Motivationsaussage, sondern Strukturbeschreibung).
- Die Spieltheorie-Einordnung (Nash-Gleichgewicht defensiv) und die Lipsky-SLB-Interpretation der Coping-Strategien.
- Die Folgekosten-Bandbreite 0,9–1,7 Mrd. EUR/Jahr (mittleres Szenario ca. 1,1 Mrd.).

- Die kausale Zuschreibung von Überweisungs- und Diagnostiküberversorgung auf die Regress-Prüfstruktur (spezifischer Originalitätsanspruch dieser Studie).

Hypothese / Datenlücke (IFG-Anfragen laufen, Bestätigung ausstehend):

- Die genaue Verteilung V2a/V2b und die Widerspruchs-Erfolgsquoten.
- Die 70–80 %-Vergleichsquote bei V2 (Praxisbericht, nicht publiziert).
- Die Korrelation zwischen Prüfintensität je KV-Region und Verordnungsvolumen (DDD/Kopf).
- Die KV-Nordrhein-Antragszahl (konservative Bandbreite 15.000–25.000, extern nicht verifizierbar; IFG-Anfrage anhängig).

11.3 Genre-Klärung

Diese Studie ist nicht als Original-*Studie* im Sinne einer neuen empirischen Primärerhebung zu lesen. Sie ist eine **multiperspektivische Bestandsaufnahme mit Pilot-Charakter**: Sie integriert rechtsdogmatische, statistische, verhaltensökonomische, institutionentheoretische und verfassungsrechtliche Perspektiven auf einen Gegenstand, der in der deutschen Versorgungsforschung bislang nicht synthetisiert wurde. Ihr Beitrag liegt in der Diagnose-Konstruktion (drei Zertifikatsfehler), nicht in der Produktion neuer Primärdaten. Sie ist damit näher an einem “Working Paper” bzw. “Discussion Paper” als an einer empirischen Originalstudie. Diese Genre-Klärung ist nicht defensiv gemeint, sondern methodisch redlich: Der Geltungsanspruch ist genau der einer Bestandsaufnahme, die weitere empirische Forschung provozieren soll.

11.4 Was wäre der nächste Schritt?

Drei Forschungs- und Reform-Schritte folgen natürlich aus dieser Bestandsaufnahme:

1. **Empirische Validierung:** Unabhängige Replikation der Ribbat-Befunde mit strengerem Design (höherer Rücklauf, Non-Respondent-Follow-up, objektive Verhaltensmarker neben Selbstbericht).
2. **Korrelationsanalyse:** Verknüpfung von Prüfintensität je KV-Region mit Verordnungsvolumen (DDD/Kopf) — die entscheidende empirische Testfrage der Kernhypothese.
3. **Rechtssetzung:** Der Halbsatz-Streich in § 106b Abs. 2 S. 4 SGB V (Rang 1 im KNV-Vergleich) als minimal-invasiver Einzelhebel mit der größten erwartbaren Wirkung.

Die Studie gibt keine abschließende Antwort auf die Frage, ob das deutsche Wirtschaftlichkeitsprüfsystem insgesamt mehr schadet als nutzt. Sie macht plausibel, dass die Frage stellbar ist, dass sie empirisch beantwortbar wäre, und dass die aktuelle Daten- und Transparenzlage es systematisch verhindert, sie zu beantworten. Diese Transparenzlücke zu schließen, wäre der wirksamste Einzelschritt zur Versachlichung der Debatte. Dafür sind PP-003 (Transparenzportal als Plan B) und die Publikationspflicht der Prüfungsstellen (Hebel 2 als Plan A) gemacht.

12 Quellen und Recherche-Dateien

Diese Studie integriert Befunde aus zahlreichen parallelen Recherchesträngen. Die folgende Übersicht listet die thematischen Blöcke, zu denen eigene Arbeitsdokumente im projektinternen Infomaterial-Ordner existieren:

- Grundzahlen und Fallbeispiele (Regressquoten, KV-Statistiken, dokumentierte Einzelfälle)
- Pipeline-Daten und Prüfungsarten (Auffälligkeitsprüfung, Einzelfallprüfung, Abrechnungsprüfung)
- Formfehler-Rechtsprechung und Eigentumsdogmatik (BSG B 6 KA 9/24 R u. a.)
- Bürokratiekosten und Kodierungsbelastung in Arztpraxen
- Akademische Einordnung (Chilling Effect, CIRS, Pharmakovigilanz)
- Folgekosten und Patientenschäden (Ribbat 2023, HCHE, OECD, Verhältnisrechnung)
- Internationaler Vergleich und wissenschaftliche Primärliteratur
- Gesetzgebungshistorie der Prüfverfahren (1989–2026)

- Mechanik und Selbstverständnis der Einzelfallprüfung
- Changelog der Einzelfallprüfung (1989–2026)
- Argumentation des GKV-Spitzenverbandes zur Einzelfallprüfung
- Container-Genealogie der Wirtschaftlichkeitsprüfung
- Liga-Tabelle der volkswirtschaftlichen Kostentreiber
- Software-Markt und OpenPrescribing.net (internationaler Vergleich)
- PVS-Kostenanalyse und Open-Source-Realisierbarkeit
- Machbarkeitsanalyse des Verordnungs-Plugin-Tools
- Eigenanalyse zum Systemwiderspruch der Prüfverfahren (Reliabilität vs. Validität)
- Anonymisierte Fallstudie zu GLP-1-Verordnung bei Leberzirrhose
- GPE-Selbsterhaltung (Niskanen-Analyse)
- Strukturelle Inkonsistenzen im Normgefüge (Top-10)
- Container-Virus (rechtsdogmatische Zielkonflikte)
- Verfassungsrechtlicher Angriffsvektor (Backdoor-Analyse)
- Theoretische Einordnung: Managerialismus und Audit Society (Freidson 1970/2001, Power 1997)
- Ärzte als Street-Level Bureaucrats (Lipsky 1980)
- Administrative Burden als Policymaking by Other Means (Herd & Moynihan, Russell Sage 2018)
- Transparency Paradox (Bernstein, ASQ 2012) als Selbstkritik des Transparenzportal-Konzepts
- Frankreich: Délit statistique, MSO/MSAP-Verfahren der CNAM (MG France, FMF, Médecins Pour Demain; 2023–2025)

Die in v0.4 neu eingearbeiteten internationalen und theoretischen Primärquellen (alle extern verifiziert):

- Freidson, Eliot (1970): *Profession of Medicine*. New York: Dodd, Mead.
- Freidson, Eliot (1970): *Professional Dominance*. New York: Atherton Press.
- Freidson, Eliot (2001): *Professionalism: The Third Logic. On the Practice of Knowledge*. Cambridge: Polity Press.
- Power, Michael (1997): *The Audit Society: Rituals of Verification*. Oxford: Oxford University Press. ISBN 0-19-828947-2.
- Lipsky, Michael (1980, erw. 2010): *Street-Level Bureaucracy: Dilemmas of the Individual in Public Services*. New York: Russell Sage Foundation. 30th Anniversary Expanded Edition 2010, ISBN 9780871545442.
- Herd, Pamela & Moynihan, Donald P. (2018): *Administrative Burden: Policymaking by Other Means*. New York: Russell Sage Foundation. ISBN 9780871544445. Louis Brownlow Book Award 2019, Herbert Simon Best Book Award 2022.
- Bernstein, Ethan S. (2012): "The Transparency Paradox: A Role for Privacy in Organizational Learning and Operational Control". *Administrative Science Quarterly* 57(2): 181–216. DOI: 10.1177/0001839212453028.
- Décret n° 2011-551 du 19 mai 2011 (Frankreich): Rechtsgrundlage für MSO-Verfahren der CNAM gegen Vertragsärzte.
- MG France: Stellungnahmen zum "délit statistique" (2024/2025), z. B. in *Le Quotidien du Médecin, Egora*.
- Fédération des Médecins de France (FMF), Cellule Juridique: "Histoire du délit statistique" und "La responsabilité juridique de la CNAM face à la pression exercée sur les médecins pour délit statistique" (fmfpro.org, 2024–2025).
- CNAM-Kontrollzahlen 2024: ca. 680.000 Kontrollen, 230.000 mit medizinischer Prüfung, 7.000 Sanktionen; MSO-Kampagne 2023–2024 mit 745 betroffenen Ärzten und 106 Finanzstrafkommissions-Verfahren (Quellen: *Le Quotidien du Médecin*, *Previssima*, *Egora*).

Formales Literaturverzeichnis

Das folgende Verzeichnis listet alle 50 formalisierten Quellen dieser Studie — peer-reviewed Artikel, Monographien, Rechtsprechung, institutionelle Quellen und Gesetzestexte. Inline-Zitationen im Text werden schrittweise auf `\cite{}` umgestellt.

Literatur

- [1] Zentralinstitut für die kassenärztliche Versorgung (Zi). Versorgungsatlas – regionale versorgungsforschung. <https://www.versorgungsatlas.de/>, 2025. Zi-Plattform für regionale Versorgungsforschung, u. a. ACSC-Indikatoren (Ambulatory Care Sensitive Conditions), Bedarfsplanungsdaten, chronische Krankheiten. Laufende Publikation von Trendreports und Papers. Abgerufen 14.04.2026.
- [2] Holger Pfaff, Edmund A.M. Neugebauer, Gerd Glaeske, and Matthias Schrappe. *Lehrbuch Versorgungsforschung: Systematik – Methodik – Anwendung*. Schattauer, Stuttgart, 2. aktualisierte und erweiterte auflage edition, 2017. Standardwerk der deutschen Versorgungsforschung. Systematisierung zu Über-/Unter-/Fehlversorgung, Routinedaten-Analyse, Selektivvertrag, G-BA-Rolle. Verifiziert über Schattauer/Lehmanns-Buchhandel.
- [3] Daniel Kahneman and Amos Tversky. Prospect theory: An analysis of decision under risk. *Econometrica*, 47(2):263–291, 1979. Standardreferenz zu Verlustaversion, Zertaintätseffekt, Isolationseffekt. Basis für die Risikoverzerrung bei Regressangst-Wahrnehmung.
- [4] Bundesärztekammer – Gutachterkommissionen und Schlichtungsstellen. Behandlungsfehler-statistik 2023. <https://www.aerztekammern-schlichten.de/statistik>, 2024. Bundesweite Arzthaftungsverfahren über die Gutachterkommissionen und Schlichtungsstellen der Landesärztekammern. Bearbeitete Anträge und Bestätigungsquote kausaler Behandlungsfehler (ca. 24–25 %).
- [5] Medizinischer Dienst Bund. Behandlungsfehler-begutachtung – jahresstatistik 2023. <https://md-bund.de/themen/behandlungsfehlerbegutachtung.html>, 2024. Jahresbericht zur Behandlungsfehlerbegutachtung durch den MD; rund 14.000 Begutachtungen jährlich.
- [6] Deutsche Gesellschaft für Innere Medizin (DGIM). Initiative “klug entscheiden”: Empfehlungen gegen Über- und unterversorgung in der inneren medizin. <https://www.klug-entscheiden.com/empfehlungen/uebersicht>, 2025. Seit 2015; aktuell 168 Positiv- und Negativempfehlungen der internistischen Fachgesellschaften, abgestimmt durch Konsensus-Kommission “Klug entscheiden”. Deutsche Version der Choosing-Wisely-Initiative. Abgerufen 14.04.2026.
- [7] Deutsche Gesellschaft für Allgemeinmedizin und Familienmedizin (DEGAM). S2e-leitlinie 053/045: Schutz vor Über- und unterversorgung – gemeinsam entscheiden. <https://www.degam.de/leitlinie-s2e-053-0451g>, 2025. Living Guideline, 5. Aktualisierung Mai 2025, gültig bis März 2026. Priorisierte Negativ-Empfehlungen für den hausärztlichen Alltag sowie Handlungsoptionen gegen Unterversorgung. Langfassung, Kurzfassung, Synopse und Patienteninformation öffentlich. Abgerufen 14.04.2026.
- [8] Betsy Q. Cliff, V. Avanceña, Anton L. Richard A. Hirth, and Shooou-Yih Daniel Lee. The impact of Choosing Wisely interventions on low-value medical services: A systematic review. *Milbank Quarterly*, 99(4):1024–1058, 2021.
- [9] Carrie H. Colla, Alexander J. Mainor, Caroline Hargreaves, Thomas Sequist, and Nancy Morden. Interventions aimed at reducing use of low-value health services: A systematic review. *Medical Care Research and Review*, 74(5):507–550, 2017. Systematic Review zu Interventionen gegen Low-Value Care (Choosing-Wisely-Kontext): Dissemination allein wirkungslos, multifaktorielle Interventionen mit struktureller Verankerung effektiver.
- [10] Tim Doran, Catherine Fullwood, Hugh Gravelle, David Reeves, Evangelos Kontopantelis, Urara Hiroeh, and Martin Roland. Pay-for-performance programs in family practices in the United Kingdom. *New England Journal of Medicine*, 355(4):375–384, 2006.
- [11] L. Forbes, Lindsay J. Catherine Marchand, Tim Doran, and Stephen Peckham. The role of the Quality and Outcomes Framework in the care of long-term conditions: a systematic review. *British Journal of General Practice*, 67(664):e775–e784, 2017.
- [12] Martin Roland and Stephen Campbell. Pay for performance in primary care in England and California: Comparison of unintended consequences. *Annals of Family Medicine*, 7(2):121–127, 2009.

- [13] Pieter Van Herck, Delphine De Smedt, Lieven Annemans, Roy Remmen, Meredith B. Rosenthal, and Walter Sermeus. Systematic review: Effects, design choices, and context of pay-for-performance in health care. *BMC Health Services Research*, 10:247, 2010.
- [14] Thomas G. McGuire and Mark V. Pauly. Physician response to fee changes with multiple payers. *Journal of Health Economics*, 10(4):385–410, 1991. Formalisierung der Multi-Payer-Agentur (Grundmodell für Multi-Principal-Agent-Analyse des Arztverhaltens).
- [15] Sachverständigenrat für die Konzertierte Aktion im Gesundheitswesen (SVR). Bedarfsgerechtigkeit und wirtschaftlichkeit – gutachten 2000/2001. band iii: Über-, unter- und fehlversorgung. Technical report, Sachverständigenrat, 2001. Kurzfassung online verfügbar; Vollfassung erschienen im Nomos-Verlag (Baden-Baden). Primärquelle der SVR-Trias Über-/Unter-/Fehlversorgung, sachverständige Einordnung qualitativer Versorgungsdefizite in Deutschland. Verifiziert über SVR-Website. Abgerufen 14.04.2026.
- [16] Leon Ribbat, Klaus Linde, Antonius Schneider, and Bernhard Riedl. Effects of the Risk of Recourse Claims on the Work of General Practitioners and Orthopedists – A Nationwide Survey. *Gesundheitswesen*, 85(2):111–118, 2023. PMID: 34587633. Bundesweite Zufallsstichprobe, je 1.000 Hausärzte und 1.000 Orthopäden, Rücklauf 41%/39% (n=770). TU München, Institut für Allgemeinmedizin. Deutschsprachig mit englischem Abstract.
- [17] Junyao Zheng, Yongbo Lu, Wenjie Li, Bin Zhu, Fan Yang, and Jie Shen. Prevalence and determinants of defensive medicine among physicians: a systematic review and meta-analysis. *International Journal for Quality in Health Care*, 35(4):mzad096, 2023. PMID: 38060672. 64 Studien, 35.900 Ärzte, 23 Länder. Gepoolte Prävalenz 75,8%.
- [18] Katja Goetz, Dorothee Oldenburg, Christina Jana Strobel, and Jost Steinhäuser. The influence of fears of perceived legal consequences on general practitioners' practice in relation to defensive medicine – a cross-sectional survey in germany. *BMC Primary Care*, 25(1):23, 2024. PMID: 38216861. n=413 deutsche Hausärzte. Deutsche Replikation der Defensivmedizin-Befunde.
- [19] Ethan S. Bernstein. The transparency paradox: A role for privacy in organizational learning and operational control. *Administrative Science Quarterly*, 57(2):181–216, 2012.
- [20] Daniel P. Kessler and Mark B. McClellan. Do doctors practice defensive medicine? *The Quarterly Journal of Economics*, 111(2):353–390, 1996.
- [21] Janet Currie and W. Bentley MacLeod. First do no harm? tort reform and birth outcomes. *The Quarterly Journal of Economics*, 123(2):795–830, 2008.
- [22] Michelle M. Mello, Amitabh Chandra, Atul A. Gawande, and David M. Studdert. National costs of the medical liability system. *Health Affairs*, 29(9):1569–1577, 2010. PMID: 20820010.
- [23] Konrad Himmel and Udo Schneider. Ambulatory care at the end of a billing period. *HCHE Research Paper*, (14), 2017. Hamburg Center for Health Economics. Basierend auf TK-Daten 2013/14. EconStor-Handle: 10419/157532.
- [24] Tobias Effertz, Susanne Engel, Frank Verheyen, and Roland Linder. The costs and consequences of obesity in germany: a new approach from a prevalence and life-cycle perspective. *The European Journal of Health Economics*, 17(9):1141–1158, 2016. PMID: 26701837.
- [25] Eliot Freidson. *Profession of Medicine: A Study of the Sociology of Applied Knowledge*. Dodd, Mead & Company, New York, 1970.
- [26] Eliot Freidson. *Professional Dominance: The Social Structure of Medical Care*. Atherton Press, New York, 1970.
- [27] Eliot Freidson. *Professionalism: The Third Logic. On the Practice of Knowledge*. Polity Press, Cambridge, 2001.
- [28] Michael Power. *The Audit Society: Rituals of Verification*. Oxford University Press, Oxford, 1997.
- [29] Michael Lipsky. *Street-Level Bureaucracy: Dilemmas of the Individual in Public Service*. Russell Sage Foundation, New York, 30th anniversary expanded edition edition, 2010. Erstauflage 1980.

- [30] Pamela Herd and Donald P. Moynihan. *Administrative Burden: Policymaking by Other Means*. Russell Sage Foundation, New York, 2018. Louis Brownlow Book Award 2019, Herbert Simon Best Book Award 2022.
- [31] William A. Niskanen. *Bureaucracy and Representative Government*. Aldine-Atherton, Chicago, 1971.
- [32] Michel Foucault. *Surveiller et punir: Naissance de la prison*. Gallimard, Paris, 1975. Dt.: Überwachen und Strafen. Die Geburt des Gefängnisses, Suhrkamp 1976.
- [33] Bundessozialgericht. Urteil vom 05.05.2010 – b 6 ka 5/09 r, 2010. Normativer Schadensbegriff: Schaden entsteht ab Bezahlung der fehlerhaften Verordnung durch die Kasse.
- [34] Bundessozialgericht. Urteil vom 20.03.2013 – b 6 ka 27/12 r, 2013. Stellungnahme der Krankenkasse zur Verordnungsfähigkeit: §29 BMV-Ä verbietet Genehmigung, nicht Stellungnahme. Vertrauensschutz möglich.
- [35] Bundessozialgericht. Urteile vom 05.06.2024 – b 6 ka 5/23 r und b 6 ka 10/23 r, 2024. Differenzkostenregelung für unwirtschaftliche Verordnungen (V2a). Explizit ausgeschlossen für unzulässige Verordnungen (V2b/Formfehler).
- [36] Bundessozialgericht. Urteil vom 27.08.2025 – b 6 ka 9/24 r, 2025. Formalregress ca. 491.000 EUR wegen fehlendem Arztstempel. Medizinisch korrekte Behandlung, nur Dokumentationsfehler.
- [37] Bundessozialgericht. Urteil vom 20.09.1995 – 6 rka 40/94, 1995. Vierjährige Ausschlussfrist für Wirtschaftlichkeitsprüfungen (Richterrecht, später gesetzlich verkürzt). Korrektur 2026-04-12: Datum zuvor irrtümlich als 16.06.1995 angegeben.
- [38] Bundessozialgericht. Urteil vom 02.07.2014 – b 6 ka 26/13 r, 2014. Nachgereichte Dokumentation nach Verfahrensbeginn: Heilung bei V2b nicht möglich.
- [39] Bundesverfassungsgericht. Beschluss vom 06.12.2005 – 1 bvr 347/98 (nikolaus-beschluss), 2005. Grundrecht auf Leben (Art. 2 Abs. 2 GG) kann bei lebensbedrohlichen Erkrankungen GKV-Leistungsanspruch begründen.
- [40] Bundesverfassungsgericht. Beschluss vom 08.08.1978 – 2 bvl 8/77 (kalkar i, bverfge 49, 89), 1978. Wesentlichkeitstheorie: Wesentliche Entscheidungen müssen vom Gesetzgeber getroffen werden.
- [41] Bundesverfassungsgericht. Urteil vom 18.07.1972 – 1 bvl 32/70 und 25/71 (numerus clausus i, bverfge 33, 303), 1972. Teilhaberecht und Zugangsgleichheit.
- [42] Bundesverfassungsgericht. Kammerbeschluss vom 01.10.2025 – 1 bvr 985/24, 2025. Regress-Verfassungsbeschwerde: Kammer nahm nicht zur Entscheidung an, aber ohne inhaltliche Prüfung (Subsidiarität).
- [43] KBV and Universität Trier. Berufsmonitoring medizinstudierende, 2018. Dritte Erhebungswelle. 46,7% der ca. 13.900 Befragten nennen Regressdrohung als Niederlassungshindernis.
- [44] Bundesministerium für Gesundheit. Referentenentwurf gvsg (gesundheitsversorgungsstärkungsgesetz), 2024. Datum: 12.04.2024. Begründung zu § 106b SGB V: ca. 47.000 V2-Verfahren/Jahr bundesweit (2022); Schwellenanhebung 50 EUR auf 300 EUR spart 70% ein.
- [45] SpiFa (Spitzenverband Fachärzte Deutschlands). Unbürokratische bagatellgrenze für regresse als sofortmaßnahme. <https://spifa.de/unbuerokratische-bagatellgrenze-fuer-regresse-als-sofortmassnahme/>, 2025. Bayern 2023: 15.375 Verfahren, 12.930 Regresse, 3.458.890 EUR. Bayern 2024: 16.288 Verfahren, 13.332 Regresse, 4.447.820 EUR (Ø 334 EUR). Beitragsautorin: Anna Zschommler (SpiFa-Pressestelle), zitiert Kathrin Blaschek (Leiterin Prüfstelle Bayern) und Dr. André Byrla (SpiFa-Hauptgeschäftsführer). Datum: 28.02.2025. Abgerufen 11.04.2026.
- [46] Virchowbund. Regress: Selten bedrohlich, aber lästig. <https://www.virchowbund.de/praxisaerzte-blog/regress-selten-bedrohlich-aber-laestig>, 2022. 0,065%: Weniger als 100 rechtskräftige Regresse bundesweit (Berichtsjahr 2018) bei 155.000 Vertragsärzten. Publikation des Blog-Beitrags am 09.05.2022, letzte Aktualisierung 29.05.2025. Basierend auf Ärzte-Zeitung-Auswertung.

- [47] GKV-Spitzenverband. Stellungnahme zum khvvg (krankenhausversorgungsverbesserungsgesetz), 2024. Argumentationspapier zur Wirtschaftlichkeitsprüfung.
- [48] GKV-Spitzenverband. Rahmenvorgaben nach §106b abs. 2 sgb v, 2020.
- [49] OECD. Health at a glance, 2025.
- [50] WIdO (Wissenschaftliches Institut der AOK). Krankenhaus-report 2016, 2016. ACSC-Daten (Ambulatory Care Sensitive Conditions).
- [51] Vitali Gorennoi, Matthias P. Schönermark, and Anja Hagen. Maßnahmen zur verbesserung der compliance bzw. adhärenz in der arzneimitteltherapie mit blick auf therapeutischen erfolg und kosten. HTA-Bericht 65, DIMDI (Deutsches Institut für Medizinische Dokumentation und Information), 2007. Non-Adhärenz-Folgekosten ca. 10 Mrd. EUR/Jahr Deutschland (konservative Lesart der Bandbreite 7–17 Mrd.). Verifiziert via York CRD / GMS Health Innovation. Abgerufen 14.04.2026.
- [52] AOK Baden-Württemberg. Prüfungsthemen einzelfallprüfung arzneimittel. <https://www.aok.de/gp/verordnung/wirtschaftlichkeit/baden-wuerttemberg/pruefungsthemen-einzelfallpruefung-arzneimittel>, 2025. Öffentlich publizierte Liste mit ca. 14 Prüfthemen (Generelle Verordnungsausschlüsse der Arzneimittel-Richtlinie, Bagatellerkrankungen, Off-Label-Use u.a.). Basis für CORE4-Kategorien A/B/C. Abgerufen 11.04.2026.
- [53] KV Rheinland-Pfalz. Regress-ranking: Top-10 krankenkassen nach prüfanträgen. <https://www.kv-rlp.de/praxis/berufspolitik/regress-ranking>, 2025. Regelmäßige Veröffentlichung der Top-10 Krankenkassen mit den meisten Prüfanträgen. Aktueller Stand (abgerufen 14.04.2026): 4. Quartal 2025. Spitzenreiter: AOK Rheinland-Pfalz/Saarland, gefolgt von TK und DAK-Gesundheit. Nur Ränge, keine absoluten Zahlen.
- [54] Deutscher Bundestag. Sozialgesetzbuch fünftes buch – gesetzliche krankenversicherung (sgb v). Insb. §§ 106, 106a, 106b, 106c, 106d (Wirtschaftlichkeitsprüfung), § 12 (Wirtschaftlichkeitsgebot), § 95d (Fortbildungspflicht).
- [55] Deutscher Bundestag. Gesundheits-reformgesetz (grg), 1989. Einführung § 106 SGB V (Wirtschaftlichkeitsprüfung ambulant).
- [56] Deutscher Bundestag. Gesundheitsstrukturgesetz (gsg), 1993. Lahnsteiner Kompromiss 1992.
- [57] Deutscher Bundestag. Gkv-versorgungsstärkungsgesetz (gkv-vsg), 2015. Zentrale Wendepunkt-Reform: Beratungsschutz für V1, explizit nicht für V2 (§ 106b Abs. 2 S. 4).
- [58] Deutscher Bundestag. Terminservice- und versorgungsgesetz (tsvg), 2019. Ausschlussfrist auf 2 Jahre (V1) bzw. 2,5 Jahre (V2) verkürzt.
- [59] Décret n° 2011-551 du 19 mai 2011. <https://www.legifrance.gouv.fr/loda/id/JORFTEXT000024045471>, 2011. Frankreich: Rechtsgrundlage für MSO-Verfahren (Mise sous Objectifs) der CNAM gegen Vertragsärzte. Schuf Art. R148-1 bis R148-9 Code de la sécurité sociale.
- [60] CNAM (Caisse nationale de l'assurance maladie). Rapport charges et produits 2024 et campagne mso 2023–2024. Sekundärquellen: Le Quotidien du Médecin, Previssima, Egora, FMF Cellule Juridique, 2024. Kontrollzahlen 2024: ca. 680.000 Kontrollen, 230.000 mit medizinischer Prüfung, 7.000 Sanktionen. MSO-Kampagne 2023–2024: 745 betroffene Ärzte, davon 106 vor Finanzstrafkommission. Primärer CNAM-Rapport Charges et Produits Juli 2024; Kampagnen-Zahlen aus französischen Fach- und Verbandsmedien.
- [61] Wolf-Dieter Ludwig, Bernd Mühlbauer, and Roland Seifert, editors. *Arzneiverordnungs-Report 2024: Aktuelle Daten, Kosten und Trends der Arzneiverordnungen*. Springer Berlin Heidelberg, 2025. Datengrundlage: 737 Mio. Verordnungen von 153.726 Vertragsärzten und 62.753 Vertragszahnärzten für 74,3 Mio. GKV-Versicherte. Nettokosten GKV-Arzneimittel 2023 ca. 54,0 Mrd. EUR (+2,1 % ggü. 2022). Abgerufen 14.04.2026.
- [62] KV Nordrhein. Prüfvereinbarung über die prüfung der wirtschaftlichkeit der vertragsärztlichen versorgung nach §§ 106, 106b sgb v (gültig ab 1. januar 2024). https://www.kvno.de/fileadmin/shared/pdf/online/amtliche_bekanntmachungen/2023/20231219_pruefvereinbarung.pdf, 2023. Ab 2024 gilt Neuregelung: max. 20 Einzelfallprüfungsverfahren je Kasse und Quartal;

Bagatellgrenze 150 EUR Regressforderung. Richtgrößenprüfung faktisch eingestellt. Befristung bis Ende 2026. Abgerufen 14.04.2026.

- [63] Kassenärztliche Vereinigung Bayerns (KVB). Wirtschaftlichkeitsgebot und -prüfung: Informationen für Mitglieder. <https://www.kvb.de/mitglieder/praxisfuehrung/pflichten/wirtschaftlichkeitsgebot>, 2025. Rechtsgrundlage §§ 106, 106a, 106b, 106c SGB V in Verbindung mit Prüfungsvereinbarung KVB/Kassen. Abgerufen 14.04.2026.
- [64] Bundesrechnungshof (BRH). Entwicklung der Finanzlage in der gesetzlichen Krankenversicherung – Bericht an den Haushaltsausschuss und den Ausschuss für Gesundheit des Deutschen Bundestages. <https://www.bundesrechnungshof.de/SharedDocs/Downloads/DE/Berichte/2025/finanzlage-gkv-volltext.pdf>, 2025. BRH-Bericht zu strukturellen Finanzproblemen der GKV, Hinweis auf Ausgabensteigerungen patentgeschützter Arzneimittel. Defizit GKV 2024 ca. 6,6 Mrd. EUR. Abgerufen 14.04.2026.
- [65] Kassenärztliche Bundesvereinigung (KBV). Statistische Informationen aus dem Bundesarztregister – Bundesgebiet insgesamt, Stichtag 31.12.2024. <https://www.kbv.de/documents/infothek/zahlen-und-fakten/Bundesarztregister/2024-12-31-BAR-Statistik.pdf>, 2025. 189.551 an der ambulanten Versorgung teilnehmende Ärztinnen/Ärzte und Psychotherapeuten 2024 (+1,1 % ggü. Vorjahr); 123.752 in eigener Niederlassung, ca. 55.000 angestellt; Frauenanteil 52,4 %. Primärquelle für Vertragsarztzahlen. Abgerufen 14.04.2026.
- [66] Reinhard Busse, Miriam Blümel, Franz Knieps, and Till Bärnighausen. Statutory health insurance in Germany: a health system shaped by 135 years of solidarity, self-governance, and competition. *The Lancet*, 390(10097):882–897, 2017. Lancet Germany Series, Paper 1. Beschreibt 135 Jahre GKV-Entwicklung, Selbstverwaltung, Steuerungsmechanismen. Wissenschaftliche Leit-Quelle zum deutschen Gesundheitssystem in internationaler Peer-Review-Perspektive. Verifiziert via thelancet.com.
- [67] Bundessozialgericht. Urteil vom 22.10.2014, b 6 ka 3/14 r — Heilmittelregress / Grundsatz “Beratung vor Regress”. <http://juris.bundessozialgericht.de>, 2014. Grundsatzentscheidung zur Vorgängernorm § 106 Abs. 5e SGB V (Beratungsvorrang bei Erstmaligkeit). Wirtschaftlichkeitsprüfung Heilmittel.
- [68] Bundessozialgericht. Urteil vom 11.12.2019, b 6 ka 23/18 r — Beratung nach § 106b Abs. 2 SGB V. https://www.bsg.bund.de/SharedDocs/Entscheidungen/DE/2019/2019_12_11_B_06_KA_23_18_R.html, 2019. Direkte Bestätigung: Individuelle Beratung vor Regressfestsetzung gilt bei statistischen Erstauffälligkeiten, nicht bei Einzelfallprüfungen. Belegt zugleich die strukturelle V2-Beratungslücke.
- [69] Um:bruch – Denkfabrik für gesellschaftlichen Wandel. Pp-003: Regress-transparenzportal – Konzeptpapier, 2026. v2.8, 31 Seiten. Begleitkonzept zu ST-001.

Interne Arbeitsdokumente

Anhang: Glossar

Diese Studie verwendet einige fachliche Begriffe, die hier kurz erklärt werden:

- **Administrative Burden** — Begriff der US-amerikanischen Policy-Forschung (Herd & Moynihan, Russell Sage 2018). Bezeichnet administrative Hürden nicht als zufälliges Bürokratie-Nebenprodukt, sondern als “*Policymaking by Other Means*” — strategisch eingesetzte Lasten zur impliziten Zugangsbegrenzung. Drei Kostenkategorien: Learning Costs, Compliance Costs, Psychological Costs.
- **Audit Society** — Theorie von Michael Power (Oxford UP, 1997). Beschreibt die Ausweitung von Prüfungs- und Rechenschaftspflichten auf alle gesellschaftlichen Bereiche. Prüfungen wirken performativ (sie verändern das Verhalten der Geprüften) und dienen primär der Legitimationsbeschaffung, nicht der Qualitätssicherung (“Rituale der Verifikation”).

- **Auffälligkeitsprüfung** — Statistisches Prüfverfahren nach § 106 SGB V, das von der Prüfungsstelle von Amts wegen durchgeführt wird, wenn ein Arzt im Vergleich zur Fachgruppe statistisch auffällig wirtschaftet.
- **Container (im Sinne dieser Studie)** — Ein einzelner Paragraph oder eine zusammenhängende Norm, in dem rechtliche Konzepte “aufbewahrt” werden. Der Begriff ist eine analytische Hilfe, um die Wanderung von Konzepten zwischen verschiedenen Normstandorten nachzuverfolgen, nicht ein juristischer Fachbegriff.
- **Délit statistique** — Aus dem Französischen: “statistisches Delikt”. Begriffsprägung der französischen Ärztegewerkschaften MG France und FMF seit 2023, gerichtet gegen die rein statistisch begründete Sanktionspraxis der CNAM (MSO/MSAP-Verfahren). Bezeichnet den Vorwurf, dass ein rein statistischer Ausschlag gegenüber dem regionalen Durchschnitt kein valider Beweis für unethisches oder unwirtschaftliches Verordnen sein kann, weil er die spezifische Patientenstruktur einer Praxis systematisch unterkalkuliert.
- **Differenzkostenregelung** — Berechnungsmethode, bei der nur der tatsächliche Mehrschaden ersetzt wird, nicht der volle Verordnungswert. Vom BSG 2024 (B 6 KA 5/23 R, B 6 KA 10/23 R) für einen Teilbereich anerkannt; bei Formalregressen ausgeschlossen.
- **Drei-Code-Kollision** — Eigenprägung dieser Studie. Beschreibt das systemtheoretische Phänomen, dass auf einer Operationseinheit (ärztliche Verordnung) drei verschiedene Funktionssystem-Codes (medizinisch / ökonomisch / juristisch) zusammentreffen, ohne dass die Differenzierung an dieser Operationseinheit aufgehoben wäre. Bezugspunkt: Niklas Luhmann, Theorie funktional differenzierter Gesellschaften.
- **Einzelfallprüfung** — Prüfverfahren nach § 106b SGB V, das von einer Krankenkasse auf Antrag eingeleitet wird und sich auf eine konkret bezeichnete Verordnung bezieht. Der Antrag muss substantiierten Anfangsverdacht enthalten. Die Einzelfallprüfung ist explizit vom Schutz “Beratung vor Regress” (§ 106b Abs. 2 SGB V) ausgeschlossen.
- **Fehlversorgung** — Versorgung, durch die ein *vermeidbarer Schaden* entsteht bzw. deren Schadenspotenzial das Nutzenpotenzial übersteigt (SVR 2000/2001, Band III; § 135a SGB V). In der Gesundheitsökonomie steht Fehlversorgung formal als dritte, gleichrangige Kategorie neben Über- und Unterversorgung (Trias), inhaltlich beschreibt sie zugleich eine Querkategorie, die mit beiden einhergehen kann: Eine Leistung, die nicht indiziert *und* schädlich ist, ist sowohl Überversorgung als auch Fehlversorgung. In dieser Studie wird der Begriff für den Kombinationsfall genutzt, in dem beide Richtungen (Unter- *und* Überversorgung) zusammen auftreten, etwa wenn defensive Ärzte weniger therapieren und gleichzeitig vermehrt überweisen.
- **GPE — Gemeinsame Prüfungseinrichtung** — Körperschaft des öffentlichen Rechts nach § 106c SGB V, paritätisch von KV und Krankenkassen-Spitzenverbänden getragen. Zuständig ausschließlich für die Wirtschaftlichkeitsprüfung. Bundesweit ca. 600–900 Stellen.
- **Managerialismus** — Steuerungslogik, die professionelle Autonomie durch externe, quantifizierbare Leistungsindikatoren und formale Rechenschaftspflichten ersetzt. Nach Eliot Freidson eine der drei konkurrierenden “Logiken” der Arbeitsorganisation neben dem freien Markt und dem Professionalismus (“Third Logic”).
- **MSO / MSAP** — Französisch: *Mise Sous Objectif* (Setzung unter Reduktionsziel) und *Mise Sous Accord Préalable* (Vorab-Genehmigungspflicht). Sanktionsverfahren der französischen CNAM gegen Ärzte, deren Verordnungen statistisch über dem regionalen Durchschnitt liegen. Eingeführt durch Décret 2011-551 (Regierung Fillon). Das zentrale Analogon zum deutschen § 106b SGB V.
- **Niskanen-Modell** — Ökonomisches Modell der Bürokratie nach William Niskanen (1971), das beschreibt, wie Behörden mit nicht direkt messbarem Output ihre eigenen Etats statt das Gemeinwohl ihres Auftrags maximieren. Sechs Identifikationskriterien.

- **Nikolaus-Beschluss** — Entscheidung des BVerfG vom 06.12.2005 (1 BvR 347/98). Bei lebensbedrohlichen oder regelmäßig tödlichen Erkrankungen und Fehlen einer alternativen Behandlung besteht ein Anspruch auf nicht regulär erstattete Behandlung. Kodifiziert 2012 in § 2 Abs. 1a SGB V. Gilt nicht für die Normalversorgung.
- **Professional Dominance** — Konzept von Eliot Freidson (*Profession of Medicine* 1970, *Professional Dominance* 1970, *Professionalism: The Third Logic* 2001). Beschreibt die gesellschaftlich legitimierte Autonomie, Selbstregulation und Definitionsmacht einer echten Profession. Wird laut Freidson seit den 1980er-Jahren durch Managerialismus systematisch erodiert.
- **Public Choice** — Theorierichtung der ökonomischen Analyse politischer und administrativer Prozesse. Untersucht, wie Eigeninteressen von Akteuren in Bürokratien und politischen Institutionen kollektive Ergebnisse prägen.
- **Street-Level Bureaucracy (SLB)** — Theorie von Michael Lipsky (*Street-Level Bureaucracy*, Russell Sage 1980). Beschreibt Akteure an der Frontlinie staatlicher Leistungserbringung (Lehrer, Polizisten, Sozialarbeiter, Ärzte im GKV-System), die in direktem Kontakt mit Bürgern stehen, über erheblichen Ermessensspielraum verfügen und unter unauflösbaren Zwangslagen (Ressourcenknappheit + widersprüchliche Vorgaben) agieren. Sie entwickeln zwangsläufig Coping-Mechanismen: Rationing, Referral/Outsourcing, Creaming, Routinization, Limiting Engagement.
- **Substantiierungsschwelle** — Beweisanforderung an einen Antrag auf Einzelfallprüfung. Die Krankenkasse muss laut § 106b Abs. 1 SGB V und den Rahmenvorgaben (KBV/GKV-SV, Stand 01.05.2020) einen "ausreichenden Verdacht auf Unwirtschaftlichkeit" substantiiert vortragen.
- **Überversorgung** — Gesundheitsleistungen, die ohne hinreichend gesicherten (Zusatz-)Nutzen und über den individuellen Bedarf hinaus erbracht werden (SVR 2000/2001, Band III; § 135a SGB V). Der SVR unterscheidet *medizinische* Überversorgung (nicht indiziert, Zusatznutzen nicht belegt) und *ökonomische* Überversorgung (unwirtschaftlich erbracht). Gesetzlicher Anknüpfungspunkt für die Sanktionierung ist § 12 SGB V (Wirtschaftlichkeitsgebot); die Wirtschaftlichkeitsprüfung nach § 106 ff. SGB V adressiert primär diese Richtung. **Patientenlast (allgemeine Dimension):** Überversorgung erzeugt nicht nur Kosten für die Solidargemeinschaft, sondern auch unmittelbare Patientenbelastung — iatrogene Risiken (Nebenwirkungen, Komplikationen, Kaskaden-Diagnostik), psychische Belastung durch Overdiagnosis (Labeling Gesunder als krank), sowie Zeit- und Wegekosten (Arztbesuche, Fahrten, Urlaubs-/Arbeitszeit). Etablierte Referenzen: SVR 2000/2001 Band III, DGIM "Klug entscheiden", Choosing Wisely, DEGAM-S2e-Leitlinie "Schutz vor Über- und Unterversorgung". **Spezifischer Beitrag dieser Studie:** Die kausale Zuschreibung einer Teilmenge der diagnostik- und überweisungsgetriebenen Überversorgung an die *Regress-Prüfstruktur* (defensive Überversorgung als Absicherungsreaktion) — und nicht nur an medizinische Unsicherheit oder ökonomische Anreize. Siehe Teil III (Verhaltensökonomie) und Teil IV (Folgekosten).
- **Unterversorgung** — Gesundheitsleistungen mit belegtem (Zusatz-)Nutzen werden bei individuell, professionell und wissenschaftlich anerkanntem Bedarf nicht oder nicht erreichbar erbracht (SVR 2000/2001, Band III; § 70 SGB V). Umfasst Unterlassung, verzögerte Erbringung und räumlich/sozial ungleiche Erreichbarkeit. Gesetzlicher Anknüpfungspunkt ist der Versorgungsauftrag des § 70 SGB V. Anders als bei Überversorgung existiert *kein individuelles Sanktions- oder Prüfreime* gegen den Arzt, der aus Angst, Budgetdruck oder Absicherungsverhalten weniger tut als medizinisch geboten. Indirekt messbar über ACSC-Hospitalisierungen (Ambulatory Care Sensitive Conditions; Sundmacher et al. 2015: ca. 27 % aller deutschen Krankenhaufälle).
- **Transparency Paradox** — Organisationstheoretischer Befund von Ethan S. Bernstein (*Administrative Science Quarterly* 57[2], 2012, S. 181–216). Mehr Sichtbarkeit und Beobachtung kann kontraproduktiv wirken: Akteure entwickeln Verbergungstechniken, bauen "Compliance Theater" auf und verfallen in einen Spotlight-Effekt (Risiko- und Innovationsvermeidung). Bernsteins Gegenvorschlag: "Zones of Privacy" als bewusst entkoppelte, beobachtungsfreie Räume zur Ermöglichung professionellen Urteils.
- **Verdachtsprüfung vs. Screening** — Normative Unterscheidung. Verdachtsprüfung verlangt einen substantiierten Anfangsverdacht und führt im Trefferfall zu einer Sanktion. Screening ist ein systemati-

sches Suchverfahren ohne Anfangsverdacht und führt im Trefferfall zu Empfehlung oder Beratung. Die Einzelfallprüfung ist nach geltendem Recht eine Verdachtsprüfung.

- **Wesentlichkeitstheorie** — Verfassungsrechtliche Doktrin des BVerfG (Kalkar I, BVerfGE 49, 89; Numerus Clausus I, BVerfGE 33, 303). Wesentliche Entscheidungen — insbesondere grundrechtsrelevante — müssen vom Gesetzgeber selbst getroffen werden und dürfen nicht an untergesetzliche Ebenen delegiert werden.
- **Wirtschaftlichkeitsprüfung** — Sammelbegriff für die Prüfung der Wirtschaftlichkeit ärztlicher Verordnungen nach § 106 ff. SGB V. Umfasst heute Auffälligkeitsprüfung, Einzelfallprüfung sowie weitere Spezialverfahren.

Dieses Dokument steht unter CC BY 4.0.

Kontakt: hallo@um-bruch.org

Web: um-bruch.org

V.i.S.d.P.: Lukas Geiger, Um:bruch — Denkfabrik für gesellschaftlichen Wandel. Vollständige Anbieterkennzeichnung nach § 18 MStV: um-bruch.org/impressum

Quellcode, Rechercheprotokolle und Versionsgeschichte:

github.com/research-line/regressangst

Companion-Software (Open Source): github.com/research-line/verordnungsampel

VerordnungsAmpel — Werkzeug zum Abgleich ärztlicher Verordnungen mit bekannten öffentlichen Regelwerken (AM-RL, G-BA, KV-Prüfvereinbarungen). Regress-Risikoindikatoren-Anzeige ohne Gewähr. Zu Forschungs- und Weiterentwicklungszwecken.

Anhang B: Methodik — Walk of Analysis

Diese Studie entstand in einem mehrstufigen, KI-gestützten Analyseprozess zwischen dem 08. und 11. April 2026. 31 Recherche-Dateien, 3 Session-Berichte und 108 manuelle PDF-Kommentare dokumentieren den Verlauf. Die vollständige erweiterte Methodendokumentation mit allen Teilanalysen, rekonstruierten Prompt-Kernen, Modellrechnungen und Cross-Model-Divergenzen ist verfügbar unter `WALK_OF_ANALYSIS_EXTENDED.md`.

Methode der Methodenrekonstruktion: Die Dokumentation des eigenen Analyseprozesses wurde selbst mehrstufig erstellt: (1) Haiku-Schwarm-Extraktion der Prompt-Kerne aus 31 Recherche-Dateien, (2) Opus-Synthese aus Session-Kontexten, (3) menschliche Erinnerung an Richtungsentscheidungen (LG), (4) Konsolidierung aus 3 Session-Berichten. Diese Meta-Methode — die Rekonstruktion der Analyse durch die analysierten Werkzeuge selbst — ist Teil der methodischen Transparenz.

Multi-Modell-Architektur

Modell	Rolle	Kontrollfunktion
Claude (Opus 4.6)	Primäranalyse, Synthese (29/31 Dateien)	Kohärenzprüfung, Konsistenz-Review
Copilot (OpenAI)	Konzeptschärfung, Core-Etablierung	Fehlkonzept-Erkennung, Begriffsklärung
Gemini (Deep Research)	Theorierahmen, Quellenergänzung	Unabhängige Literatursuche, Visualisierung
LG (Mensch)	Fragestellungen, Richtungsentscheidungen	Plausibilitätsprüfung, Fallkenntnis, Freigabe

Analyseverlauf in 9 Phasen

Phase	Dateien	Leitfrage	Schlüsselbefund
I. Empirie	4	Was wissen wir gesichert über das Regresssystem?	Regressquote <1 %, gefühlte Bedrohung >85 %. Diskrepanz = Ausgangspunkt
II. Einordnung	7	Ist das Phänomen in der Literatur bekannt?	Goetz 2024, Zheng 2023. Pipeline: 916→3 (KV Hessen). Lücke: Kein "Governance-Pharmakovigilanz"-Konzept
III. Kosten	6	Was kostet das System? Gibt es Präventionssoftware?	0,9–1,7 Mrd. EUR Folgekosten (konservativ). Keine Open-Source-Präventionssoftware
IV. Rechtsstruktur	5	Wie funktioniert V2 genau?	V2 nahezu deterministisch nach Antrag. Kein Beratungsschutz. Container-Genealogie: 1 Norm → 8 Container
V. Modellierung	5	Kann man das Verhalten formal modellieren?	Nash-Gleichgewicht = defensive Unterverordnung. 9 Normdefekte. § 12 SGB V unauflösbar
VI. Verfassung	2	Verfassungsrechtliche Angriffsvektoren?	Art. 2 Abs. 2 GG (Patientenschutzpflicht) = stärkster Hebel. GPE = Niskanen-Bürokratie
VII. Gemini	2	Wo sind Lücken? Externes Double-Check	GPE-Kosten nicht verifizierbar. Ribbat medial "still"
VIII. Theorie	5 Quellen	Welche Theorien fundieren die Befunde?	Freidson, Power, Lipsky, Herd/Moynihan, Bernstein. Alle bestätigen: Audit-Bürokratie funktioniert wie vorgesehen
IX. Core	Dialog	Was ist die kanonische Wahrheit?	7+2 CORE-Referenzpunkte (CORE 1–7 + CORE3: Schutzstufenmodell/V2a-V2b + CORE4: Definitionsdivergenz/Doppelfunktion). 4 Messebenen. $V1 \neq V2$. Drei Schichten Regressbegriff

Gesamtumfang: 31 Recherche-Dateien, 6+ Session-Berichte, 3 Review-Sessions (13-Phasen-Review-Zyklus mit 9 parallelen Agenten), 108 manuelle PDF-Kommentare als Sichtprüfung. Geschätzte Gesamtarbeitszeit: ca. 60–80 Stunden (Mensch + KI kombiniert, April 2026).

Dokumentierte Korrekturen und Hypothesenrevisionen

Korrektur	Anlass	Ergebnis
“Moosazadeh 2023”	Literatur-Double-Check	Fehlzuordnung in Gemini-Quelle → korrigiert auf Zheng et al. 2023
Einzelfallprüfung ab GSG 1992	Rechtshistorische Tiefenrecherche	Bereits GRG 1988 (Blüm) → Hypothese um 4 Jahre verschoben
7–17 Mrd = attribuierte Kosten	Copilot-Review	Systemrahmen, nicht Attribution → Dreistufenmodell eingeführt
“125 GPs protestierten 2024” (FR)	Faktencheck Frankreich	Gemini-Halluzination → entfernt, echte CNAM-Zahlen eingesetzt
1 %-Quote = V1-only	Core-Etablierung	Korrigiert: V1+V2 zusammen, keine Verfahrenstrennung publiziert

Abhängigkeitsstruktur

Die 31 Analysen bilden eine gerichtete Wissenskaskade in fünf Schichten: (1) Empirie → (2) Vertiefung → (3) Synthese → (4) Bewertung → (5) Theorierahmen + Core. Jede Schicht baut auf den Befunden der vorherigen auf. An keiner Stelle wurde eine Schlussfolgerung ohne dokumentierte Quellengrundlage gezogen.

Methodische Regel: Etablierte Klassiker (Freidson, Power, Lipsky) waren bei Gemini Deep Research zuverlässig. Aktuelle politische Ereignisse mit spezifischen Akteuren (Frankreich: “délit statistique”) erforderten systematischen Double-Check — Größenordnungen und Urheberschaften waren verzerrt.

Phase XIV: Multi-Agenten-Experiment (Cross-Source-Divergenz)

In einer späteren Analysephase wurden 15 spezialisierte Agenten (6 Opus, 9 Sonnet) parallel eingesetzt, um die Quellen-Bubble der “unter 1 %”-Zahl systematisch zu durchbrechen:

Agent	Modell	Aufgabe und Schlüsselbefund
Agent 1–3	Sonnet	Datensammlung (25 Datenpunkte, 14 Domains), Impressum-Verifizierung, Tenor-Kategorisierung
Agent A–B	Sonnet	Widerspruchs-Erklärungen (6/14 thematisieren den Widerspruch, alle als “Wahrnehmungsfehler”); Naïve Suche (“unter 1 %” in ersten 5 Treffern)
Agent C	Opus	Unabhängige V2-Zahlen-Suche → BMG GVSG: 47.000 V2-Verfahren bundesweit
Prior-Art	Opus	Systematische Suche (20+ Anfragen) → Synthese (Definitionsdivergenz) nirgends publiziert
EFP-1/2	Sonnet/Opus	KVBW-Prüfthemen; Alternative Hypothese H2 → 35–40 % Erklärungskraft
KK-1–4	Sonnet	Krankenkassen-Website-Bewertung (Bias-Kontrolle: 2 Agenten, umgekehrte Reihenfolge)
Evidenz	Opus	Suche nach These “Evidenz in formaler Verkleidung” → originär

Zentrale methodische Erkenntnis: Cross-Model-Divergenz (Claude vs. Copilot vs. Gemini) kontrolliert Modell-Bias, aber *nicht* Quellen-Bias. Alle drei Modelle schöpften aus denselben Quellen (Ärzteblatt,

Virchowbund). Erst Cross-Source-Divergenz (14 Domains, verschiedene Akteursgruppen) brachte die SpiFa-Bayern-Zahlen ans Licht. Für quantitative Befunde ist Multi-Quellen-Recherche zwingend.

Zwei Prior-Art-Checks bestätigt: Beide zentralen Synthesen (Definitionsdivergenz als Erklärung für Ribbat-Diskrepanz; Evidenz in formaler Verkleidung als Doppelfunktion des Systems) sind nach systematischer Recherche **originär** — alle Einzelbausteine publiziert, Verbindung nirgends.

Vollständige Dokumentation: 14 RECHERCHE-Dateien in den Arbeitsmaterialien und METHODIK_RECHERCHE_PROTOKOLL

Prompt-Archäologie: Quantitative Analyse der Mensch-KI-Interaktion

Über den gesamten Analysezeitraum (07.–11.04.2026) wurden **208 Prompts** systematisch dokumentiert und klassifiziert: 127 menschliche Eingaben und 81 LLM-generierte Aufträge (an Sub-Agenten, Gemini, Copilot). Die Klassifikation erfolgte nach einer eigens entwickelten 5-Stufen-Taxonomie (Rohdaten → Themenfilter → Klassifikation → Aggregation → Statistik).

Zentrale Befunde zur Mensch-KI-Forschungsdynamik:

1. **Alle 6 Wendepunkte waren menschliche Startprompts** (SP = neue Richtung öffnen, nicht zu verwechseln mit Nachfragen/NT = bestehende Richtung vertiefen). Kein einziger Durchbruch wurde von der KI eigenständig ausgelöst. Die Wendepunkte entstanden durch kurze, oft beiläufig formulierte *Richtungsöffnungen* (Median: 10,5 Wörter — kürzer als der Durchschnitt aller Prompts). Die entscheidende Unterscheidung: *Öffnen* erzeugt Erkenntnis, *Vertiefen* liefert Details.
2. **Bestätigungs-zu-Korrektur-Verhältnis: 1,25:1**. Bei unkritischer Mensch-KI-Interaktion wäre ein Verhältnis von 5:1 oder höher zu erwarten. LG korrigierte fast so oft wie er bestätigte — Indikator für fehlenden Zustimmungsbias.
3. **Korrekturrate stieg von 2,8 % (Tag 1) auf 15,8 % (Tag 5)**. Der Mensch wurde im Verlauf kritischer, nicht zahmer. Die produktivsten Korrekturen (H104, H108, H111) lösten die CORE3- und CORE4-Paradigmenwechsel aus.
4. **33,9 % der Prompts erzeugten ~95 % der Kernerkenntnisse**. Startprompts (Hebelfaktor 2,9×) und Korrekturen (2,7×) waren die produktivsten Prompt-Typen. Vertiefende Nachfragen (Typ NT) und Bestätigungen (Typ BE) waren für den Arbeitsfluss nötig, erzeugten aber keine originären Befunde. *Wichtige Unterscheidung:* Die 6 Wendepunkte waren Startprompts (SP), nicht Nachfragen (NT) — der Unterschied liegt im *Öffnen* einer neuen Richtung vs. dem *Vertiefen* einer bestehenden.
5. **Proaktiv:Reaktiv = 1,74:1**. Der Mensch agierte 1,7× so oft proaktiv (neue Fragen, neue Richtungen) wie reaktiv (Bestätigung, Korrektur). Die Forschung war klar menschlich geführt, nicht KI-getrieben.
6. **KI-Autonomie-Gradient:** Die KI war bei strukturierten Aufgaben zuverlässig (Tabellen, Recherche, Dokumentation). Bei synthetischen, interpretierenden Aufgaben (Bedeutung der 99,7 %, Definitionsartefakt, Bilanzbewertung) lag sie ohne menschliche Korrektur falsch oder unvollständig. Konservative Schätzung: Ohne menschliche Korrekturen wären mindestens 3 der 5 zentralen CORE-Referenzpunkte nicht in ihrer jetzigen Form entstanden.

Die 6 Wendepunkt-Fragen im Wortlaut:

#	Wörter	Frage (Wortlaut) → Ergebnis
H19	12	“Warum gibt es überhaupt zwei Prüfverfahren — widerspricht sich das nicht?” → V1/V2-Systemwiderspruch erkannt
H33	11	“Stell dir vor du bist ein BVerfG-Anwalt — wo würdest du ansetzen?” → 5 verfassungsrechtliche Angriffsvektoren
H53	14	“Das System prüft doch gar nicht das was es zu prüfen vorgibt?” → Doppelter Zertifikatsfehler (CORE 4)
H101	9	“Ich dachte das Richtgrößenverfahren wurde abgeschafft?” → V1-Schutzstufenmodell + V2a/V2b (CORE3)
H112	7	“Die ein Prozent sind auch zufällig oder?” → Definitionsdivergenz, Faktor 500× (CORE4, Originalbeitrag 1)
H120	10	“Meine Hypothese ist dass wir es falsch eingeschätzt haben” → Doppelfunktion: 35 % Evidenzsteuerung (CORE4, Originalbeitrag 2)

Einschränkungen der Prompt-Analyse:

- **Dunkelziffer Copilot/Gemini:** Die 127 Human-Prompts erfassen nur Eingaben an Claude. Der menschliche Forscher (LG) hat zusätzlich Prompts an Copilot (GPT-4o) und Gemini (Deep Research) gesendet, deren Wortlaut nicht systematisch dokumentiert ist. Die *Ergebnisse* dieser Prompts wurden als Copy-Paste an Claude weitergeleitet (11 Copilot-Inputs, 9 Gemini-Outputs nachweisbar), aber die *steuernden Eingaben* des Menschen an diese Modelle sind eine echte Dokumentationslücke. Die tatsächliche Prompt-Zahl liegt geschätzt 30–50 % höher.
- **Experimentelle Prompt-Formen:** Im Verlauf wurden innovative Ansätze entwickelt, die über klassische Recherche-Prompts hinausgehen: *Naive-Suche-Test* (verblindeter Agent simuliert Journalisten — geht er denselben Irrweg?), *Reihenfolge-Bias-Kontrolle* (zwei Agenten bewerten in umgekehrter Reihenfolge), *Prior-Art-Check* (systematische Suche nach eigener These), *Alternative-Hypothese-Test* (aktives Testen der Gegenthese H2). Diese Methoden sind nicht Standard und verdienen eigenständige methodische Dokumentation.

Methodische Selbstkritik — invertierter Forschungsprozess:

Der wissenschaftliche Formalismus sieht vor: theoretischer Hintergrund → Datenlage → Lücken → Fragestellung → Methode → Analyse. Diese Studie hat den Prozess teilweise invertiert: Die Analyse begann, bevor die Verfahrensstrukturen (V1/V2, §§ 106/106b) vollständig verstanden waren. Der Forscher (LG) konnte zu Beginn nicht zwischen V1 und V2 unterscheiden — er brauchte die Fehler zum Lernen. Die CORE3-Entdeckung (V1-Schutzstufenmodell, V2a/V2b) und die CORE4-Entdeckung (Definitionsdivergenz) entstanden *während* der Analyse, nicht davor.

Das ist einerseits eine Stärke (explorative Entdeckung unter Unsicherheit), andererseits eine Schwäche: Eine systematischere Lektüre der Gesetzestexte und des Verfahrensrechts *vor* Beginn der Analyse hätte den Umweg über fehlerhafte Annahmen (“V1 ist unfair”, “keine V2-Daten”, “unter 1 % ist Täuschung”) möglicherweise verkürzt. Die 5 dokumentierten Hypothesenrevisionen (Anhang B) sind zugleich Beleg für intellektuelle Redlichkeit und für einen methodisch imperfekten Ausgangspunkt.

Fazit: “Mensch fragt, KI sucht, Mensch korrigiert und synthetisiert” beschreibt die Dynamik. Die entscheidende Wertschöpfung liegt in den Fragen und Korrekturen — nicht in den Antworten. Der wissenschaftliche Formalismus (erst lesen, dann fragen) bleibt wichtig und sollte in künftiger KI-gestützter Forschung bewusster eingehalten werden.

Methodische Kniffe — systematische Inventur: Eine nachgelagerte Analyse aller 208 Prompts identifizierte **68 methodische Techniken** in 7 Kategorien (Agentensteuerung, Rollenzuweisungen, experimentelle Designs, wissenschaftliche Methoden auf Agenten übertragen, Steuerungsmuster, innovative Techniken, meta-reflexive Techniken). Davon 25 Standard (37 %), 35 adaptiert aus anderen Disziplinen (51 %), 8 genuine Neuentwicklungen (12 %). **Zentraler Befund:** Das Projekt ist weniger ein Methodenerfinder als ein *Methodentransporteur* — es überträgt etablierte Techniken aus Psychologie

(Reihenfolge-Bias-Kontrolle), Metrologie (Definitionsdivergenz), Software Engineering (Bug-Report, Container), Journalismus (Naive-Suche) und Patentrecht (Prior-Art-Check) auf die KI-gestützte Forschung.

Die vollständige Prompt-Dokumentation (208+ Prompts, 5 Aggregationsstufen, 68 Techniken, statistische Auswertung) ist in den Arbeitsmaterialien verfügbar.

Anhang C: Offene Forschungsfragen und eingereichte IFG-Anfragen

Die zentrale Empfehlung der Review-Zyklen dieser Studie lautete: „Ein realer V2-Datensatz wäre der größte einzelne Qualitätssprung.“ Die Gesamtzahl der V2-Verfahren ist inzwischen bekannt (BMG GVSG-Referentenentwurf 2024: ca. 47.000 bundesweit). Was fehlt, ist die Aufschlüsselung: nach V2a/V2b, nach Kassenart, nach Ausgang (Regress/Vergleich/Einstellung), nach Betragsklasse. Um die Datenlücke aktiv zu adressieren, wurden im April 2026 neun IFG-Anfragen (Informationsfreiheitsgesetz, §§ 1 ff. IFG) zu zentralen offenen Forschungsfragen eingereicht. Die Anfragen sind öffentlich einsehbar auf [FragDenStaat.de](https://fragdenstaat.de) und auf um-bruch.org/presse/ifg-anfragen/.

Übersicht der Anfragen

#	Empfänger	Forschungsfrage	Status
A1	BMG	Bundesweite Prüfstatistiken §§ 106b/106d: Verfahrenszahlen, Ergebnisse, Dropout-Gründe, Volumen gefordert vs. durchgesetzt	Eingereicht
A2	GPE Rheinland-Pfalz	Regionale Prüfstatistiken (gleicher Fragenkatalog, regional zugespielt)	Eingereicht
A3	BAS	Eurozahlen GPE: Personalkosten, Sachkosten, Verwaltungsbudgets, monofunktionale Stellen	Eingereicht
A5	GKV-Spitzenverband	Berechnungsgrundlage der „500 Mio. EUR Mehrausgaben“-Behauptung (Stellungnahme KHVVG, BT-Drs 20(14)220(6))	Eingereicht
A6	Bundesrechnungshof	Sonderprüfungen der Wirtschaftlichkeitsprüfung seit 2005 — falls keine: Begründung	Eingereicht
A7	SVR Gesundheit / BMG	Interne Berichte oder Beratungspapiere zur Effizienz der Wirtschaftlichkeitsprüfung nach 2014	Eingereicht
A8	BMJ / Statistisches Bundesamt	Sozialgerichtsstatistik zu Wirtschaftlichkeitsprüfungsverfahren (Anzahl, Ausgang, Dauer)	Eingereicht
A9	BMG	Normwidersprüche und Regelungslücken: 10 dokumentierte strukturelle Inkonsistenzen im Normgefüge	Eingereicht
A11	KBV	Anwendung § 48 BMV-Ä („Sonstiger Schaden“) in den letzten fünf Jahren	Eingereicht

Was die Antworten für diese Studie bedeuten würden

- **A1 + A2:** Würden erstmals die Eskalationspipeline der Einzelfallprüfung (V2) mit realen Zahlen füllen. Die gesamte Spalte „k.D.“ in den Pipeline-Tabellen (Abschnitt 2.4) könnte durch Daten ersetzt werden. Dies wäre der „größte einzelne Qualitätssprung“ für die Studie.
- **A3:** Würde den Niskanen-Befund (Abschnitt 5.3) empirisch untermauern oder widerlegen. Erstmals wären die Kosten der Prüfinfrastruktur quantifizierbar.
- **A5:** Würde zeigen, ob die 500-Mio.-Behauptung des GKV-SV auf belastbaren Daten basiert oder eine politische Schätzung ist.
- **A6:** Die Antwort „keine Sonderprüfung seit 2005“ wäre selbst ein Befund über die institutionelle Prüffreiheit des Systems.
- **A9:** Würde erzwingen, dass das BMG schriftlich zu konkreten, dokumentierten Schwachstellen im Normgefüge Stellung nimmt.

- **A11:** Würde den “unsichtbaren Container” § 48 BMV-Ä erstmals quantifizierbar machen.

Antwortfrist: 30 Tage nach Zugang (§ 7 Abs. 5 IFG). Erste Empfangsbestätigungen liegen vor (BMG: A1, A7, A9 — bestätigt 10.04.2026). Sobald substantielle Antworten eintreffen, werden sie in eine aktualisierte Version dieser Studie eingearbeitet.

Transparenzhinweis: Alle Anfragen sind öffentlich einsehbar. Auch Verweigerungen sind publizistisch verwertbar und werden dokumentiert — eine Antwort “diese Daten liegen uns nicht vor” bestätigt die in dieser Studie diagnostizierte Transparenzlücke.

Änderungshistorie

- **v0.22** (April 2026, 2026-04-14) — **PDF-Kommentare Runde 6 (Pfad-Färbung + V2-Designprobleme)**. (1) Verzweigungs-Header in V1 *direkt nach* Schritt 3 platziert (vorher zwischen Schritt 4a und 5). (2) **Pfad-Färbung** eingeführt: `colortbl` geladen; Schritte 0–3 + Pfad 4a in Teal-Hintergrund (■), Pfad 4b und Folgeschritte 5–8 in Rot-Hintergrund (■); Verzweigungs-Header benennt die Pfad-Farben explizit. Auch V2-Tabelle entsprechend gefärbt: Schritte 0–4 in Teal (Verfahrenslauf bis Bewertung), 5–9 in Rot (Sanktionsphase). (3) V2-Spaltenbreiten neu balanciert (Ich-wehre-mich- und Regress-Aufgehoben-Designprobleme): Schritt 3.3→2.8, Sprachform 1.9→2.2, Verfahrens-Begriff 3.0→2.5, Dropout 2.3→3.0; lange Begriffe (“Widerspruchsentscheidung”, “Unterlagenanforderung”) mit Trennstrichen versehen. (4) Methoden-Antwort an LG zur Pipeline-Darstellung in Begleitchat protokolliert: CONSORT-Stil-Flussdiagramm + Sankey für künftige Visualisierung (TODO).
- **v0.21** (April 2026, 2026-04-14) — **PDF-Kommentare Runde 5 (V1-Pipeline 4a/4b, V2-Spaltenbreiten)**. (1) V1-Pipeline restrukturiert nach Lukas-Vorschlag: Schritt 5 (Regressfestsetzung, Zweitzyklus) wird zu **Pfad 4b**, Schritt 4 (Beratung, Erstzyklus) wird zu **Pfad 4a**; Folgeschritte 6–9 (Widerspruch/Klage/Rechtskraft) werden zu Schritten 5–8 und greifen nur nach Pfad 4b. Verzweigungslogik in Schritt 3 (Bewertung) jetzt explizit als Tabellen-Multicolumn-Header dargestellt; Kernaussage und Präzisierungs-Box entsprechend angepasst. (2) V2-Tabellen-Spaltenbreiten neu balanciert: “Verfahrens-Begriff” 2.5 → 3.0 cm (lange Bezeichnungen wie “Regress aufgehoben od. bestätigt” brauchen Platz), “Schritt” 3.5 → 3.3, “Sprachform” 2.4 → 1.9, “Reg.” 0.6 → 0.5, “Dropout” 1.8 → 2.3. (3) LG-Wunsch in TODO erfasst: Baum-Diagramm der Pipelines für künftige Versionen.
- **v0.20** (April 2026, 2026-04-14) — **PDF-Kommentare Runde 4 (6 Annotationen, V2-Tabelle methodisch konsolidiert)**. (1) V1-Schritt 4 P | S0: “klein” → “< 1 %” mit Erläuterung, dass die 0,3 % in Schritt 5 die Zyklus-2-Fälle sind. (2/6) Tabellen-Header “Umgangs-sprache” → “Sprachform” (Designproblem behoben), Spaltenbreiten in V1+V2 angepasst. (3) Seitenumbruch zwischen Verfahren-Überschrift und Tabelle: `needspace`-Paket geladen, beide Pipelines mit `\needspace{12\baselineskip}` geschützt. (4) V2-Tabelle methodisch konsolidiert (Lukas-Korrektur): P | S5-Doppelbasis verworfen, durchgängig P | S0; Schritt 5 mit KV-Nordrhein-Datenpunkt ~95 %; eigene neue Spalte “Dropout-Anmerkung” für Vergleichsausstieg + V2a/V2b-Hinweise (statt Re-Basierung in derselben Spalte). (5) V2-Spalte “P ges.” entfernt (war durchgängig k.D., sinnlos). Bezugswechsel-Multicolumn-Zeile entfernt (jetzt obsolet, da konsistente Basis).
- **v0.19** (April 2026, 2026-04-14) — **PDF-Kommentare Runde 3 (V2-Tabelle Bezugsbasis)**. V2-Pipeline-Tabelle methodisch konsistent gemacht: Bis Schritt 5 ist P | S0 die Bezugsbasis (alle V2-Anträge); ab Schritt 6 wechselt die Basis zu P | S5 (Regressbescheid-Population). Schritt 5 erhält den belastbaren KV-Nordrhein-Datenpunkt ~95 % (Vergleich rechnet als Regress); V2a/V2b-Differenzierung wandert systematisch in die Schritte 6+ (wo sie auf der neuen Basis sauber zuordenbar ist), nicht mehr in Schritt 5 (wo sie eine implizite Re-Basierung bedeutete). Header-Spalte und Legenden um P | S5 erweitert.
- **v0.18** (April 2026, 2026-04-14) — **PDF-Kommentare Runde 2 (4 Annotationen)**. (1) Schlagworte-Spacing in Klasse reduziert (Zusammenfassung+Schlagworte sollen auf S.1 passen). (2) V1-Pipeline restrukturiert: Schritt 3 ist jetzt *Bewertung der Wirtschaftlichkeit* (Verneinung = Endpunkt für >99 %; Bejahung = Übergang zu Schritt 4); Schritt 4 ist die *Beratung statt Regress* bei Erstmaligkeit (Minderheit der bejahten Fälle). Klarstellung: Mehrheit scheidet bereits in Schritt 2/3 aus, Beratung ist ein Erstmaligkeits-Privileg für die <1 %, deren Wirtschaftlichkeitsverletzung bejaht wurde. (3) V2-Tabelle: “Beratung statt Regress”-Lückenzeile mit korrektem Multicolumn-Wrap (lief vorher über den Rand).
- **v0.17** (April 2026, 2026-04-14) — **PDF-Kommentare-Bearbeitung (8 Annotationen)**. (1) V1-Pipeline-Erläuterung präzisiert: Beratung (Schritt 3) ist Regress-Substitut nach festgestellter Wirtschaftlichkeitsverletzung, nicht sanktionsfreie Vorstufe (Belege: BSG 22.10.2014 B 6 KA

3/14 R; BSG 11.12.2019 B 6 KA 23/18 R; GPE BaWü). (2) V2-Pipeline: Position der gesetzlich ausgeschlossenen Beratung systematisch zwischen Schritt 4 (Bewertung) und Schritt 5 (Festsetzung) verortet (§ 106b Abs. 2 S. 3 Hs. 2 SGB V), nicht zwischen Schritt 2 und 3 wie zuvor. (3) R3 erweitert um belastbaren Datenpunkt: KV Nordrhein/Dt. Ärzteblatt: "ca. 95 % der Einzelfallprüfungen führen zu Regress" — konsistent mit ST-001-Schätzung 70–80 % Vergleich. (4) Zertifikate-Tabelle (Abschn. 2.7): Spaltenüberschreibung behoben (erste Spalte 3cm → 4cm + Trennstriche). (5) KNV-Tabelle (Abschn. 7.X): neue Spalte "Zivilgesellschaft" (direkt/indirekt) + Erläuterungs-Absatz: drei direkt zivilgesellschaftlich adressierbare Maßnahmen (Rang 7 PP-003, Rang 11 Open-Source-Verordnungstool/VerordnungsAmpel, Rang 13 IFG-Anfragen). (6) Vorwärtsverweis von "Praxisebene"-Befund (Abschn. 2.8) auf Asymmetrie-Subsubsection (Belohnungssystem-Idee). Recherche-Bericht: `_review_chain_2026-04-13/RECHERCHE_BERATUNG_R1R4_2026-04-14.md`.

- **v0.16** (April 2026, 2026-04-14) — **Asymmetrie-Gegengratifikation + BibCheck-Korrektur.** *BibCheck-Korrektur:* colla2017cw war Frankenstein-Eintrag (Titel von Rich-Editorial, DOI von Bitton et al., falsche Pages); ersetzt durch Colla et al. (2017) "Interventions Aimed at Reducing Use of Low-Value Health Services" Med Care Res Rev 74(5):507–550 (DOI 10.1177/1077558716656970), inhaltlich passend zur Aussage. *Asymmetrie:* Neuer Unterabschnitt in Teil III „Asymmetrische Sanktionsstruktur ohne Gegengratifikation“ zwischen Regelkreisanalyse und Modellarzt: bidirektionaler Sanktionsdruck (Kasse über §§ 106, 106b SGB V + Patient über §§ 630a ff., 823 BGB, §§ 223, 229 StGB, Approbationsentzug § 5 BÄO, rund 12.000 Schlichtungsverfahren/Jahr); fehlende institutionelle Gegengratifikation für evidenzbasierte Versorgung; internationaler Kontrast QOF/Choosing-Wisely; Konsequenz Exposition-Minimierung statt Qualitätsmaximierung; Verweis auf KNV-Rang 4 (positive Rückkopplung). 8 neue Bib-Einträge: Schlichtungsstellen-Statistik 2023, MD-Bund 2023, Doran 2006 (NEJM), Forbes 2017 (BJGP), Roland/Campbell 2009 (Ann Fam Med), Van Herck 2010 (BMC HSR), McGuire/Pauly 1991 (JHE), Cliff 2021 (Milbank Q), Colla 2017 (JGIM). Alle per WebSearch verifiziert.
- **v0.15** (April 2026, 2026-04-14) — **P1-Umsetzung Review-Chain (14 Punkte).** Median-Lognormal-Fußnote bei SpiFa 334 EUR; Bib-Lücken geschlossen (AVR 2024, KV Nordrhein Prüfvereinbarung 2024, KVB Bayern, Zi-Versorgungsatlas, BRH GKV 2025, KBV Bundesarztregister 2024, Kahneman/Tversky 1979); Versorgungsforschungs-Primärliteratur ergänzt (SVR 2000/2001 Band III, Busse/Blümel Lancet 2017, Pfaff/Neugebauer/Glaeske/Schrapp 2017, DGIM "Klug entscheiden", DEGAM-S2e 053/045); Versorgungsprüfung als eigene § 7.X-Subsection mit Grenzen-Unterabschnitt (Kodier-Arbitrage, ACSC-Aggregat-Vorbehalte, Datenschutz-Doppelbind) und KNV-Zeile 15; Patientenlast-Originalität präzisiert (allgemeine vs. spezifische Dimension) in Abschnitt 2.7.3 und Glossar; Ribbat-Theorie-Mapping auf Spieltheorie+Lipsky reduziert, Foucault/Herd als Marginalien, Falsifikationsbedingungen pro Theorie; Devil's-Advocate-Wirksamkeit (60–65 %-Einschränkung in V2-Kernaussage + Vorwärtsverweis Einwand 4 + Einwand 5 in Hauptthese); 5-Jahres-Reset-Fundstelle präzisiert (Rahmenvorgaben § 6 statt § 106b Abs. 2 S. 3), Anhörungsgrundlage § 24 SGB X ergänzt; normativer Schadensbegriff präzisiert (Schaden entsteht mit unzulässiger Verordnung, wird durch Bezahlung konkretisiert); Konfidenzintervalle für Ribbat-Kernzahlen (47/55/51/72/85 %); Bias-Diskussion (Non-Response/Response/Recall/Publikation); Niskanen sprachlich abgefedert ("aus Public-Choice-Perspektive"); § 70-Argumentation präzisiert (kein Sanktions-/Korrekturinstrument auf Praxisebene, nicht "kein Messinstrument"); neues Schluss-Kapitel "Was diese Studie zeigt — und was nicht" mit Bogenschluss drei Zertifikatsfehler, Belegt/Plausibel/Hypothese-Gliederung und Genre-Klärung (Working Paper / Bestandsaufnahme mit Pilot-Charakter).
- **v0.14** (April 2026, 2026-04-14) — **P0-Umsetzung Review-Chain (10 Punkte).** Summierungsrechnungs-Label-Fix (totes ?? repariert); 60–99 %-Bandbreite konsistent (Poisson- λ 0,30–1,48 korrigiert); § 135a SGB V als SVR-Trias-Verankerung; KV-Nordrhein 20.000-Zahl als "extern nicht verifizierbar" markiert (IFG-Anfrage anhängig); BSG 27.08.2025 (B 6 KA 9/24 R) mit 490.000 EUR global; Untergerichts-Urteile verifiziert (SG Mainz, LSG BW, SG Marburg); V.i.S.d.P. § 18 MStV; BibCheck mit 46 Einträgen (dimdi_hta65-Halluzination korrigiert, 6 Warnungen eingearbeitet); Zertifikatsfehler-Framing als "analytische Konstruktion"; Leseorientierungs-Box mit V1/V2/V2a/V2b-Legende. 95 Seiten.

- **v0.13** (April 2026, 2026-04-13) — **Schutzstufen-Re-Review (Korrekturleitfaden F1–F5)**. V1-Pipeline-Tabelle zweizyklisch gegliedert (Erstzyklus endet mit Beratung; Zyklus 2 nur bei Wiederauffälligkeit nach 2-J.-Karenz, gedeckelt 25.000 EUR, 5-J.-Reset). TikZ-Flussdiagramm Pipeline A korrigiert: “pädagogische Korrektur” → rechtsverbindliche Entscheidung (§ 106b Abs. 2 S. 2); invertierter NEIN-Pfad (“häufig direkte Regressfestsetzung”) entfernt. Neuer Kasten “V1-Schutzstufenmodell im Detail” (dreistufig sequenziell, mit Kernaussage “Schutz greift, fast niemand kommt am Ende an”). V2-Kernaussage ergänzt um Unterscheidung rechtskräftig vs. faktisch (V2b-Fokus, Vergleichsminderheit). Neuer Kasten “Offene Recherchepunkte R1–R4” (Dropout-Quoten, Widerspruchs-Erfolg, Vergleichsanteile, V2a/V2b-Quantifizierung). Terminologie durchgehend: “Beratung *statt* Regress” statt “vor Regress”. Datierungswiderspruch Z. 157/536 (GKV-VStG 2012 vs. GKV-VSG 2015) aufgelöst.
- **v0.12** (April 2026, 2026-04-11) — **CORE4-Integration + Encoding + BibTeX**. Drei-Schichten-Tabelle des Regressbegriffs (Definitionsdivergenz, Faktor 470–500×). Neuer Abschnitt “Evidenz in formaler Verkleidung” (Zwei Ebenen der Formalität, Doppelfunktion A/B/C, CME vs. V2). Einwand 5 neu: “Ein Drittel des Systems ist rationale Steuerung”. Zertifikatsfehler-Qualifier (“überwiegend nicht messen”, V2b-Fokus vorgezogen). Abstract CORE4-konform umgeschrieben. Bayern SpiFa-Daten (13.332 Regresse, 334 EUR Durchschnitt). Appendix B: Phase XIV Multi-Agenten-Experiment (15 Agenten, Prior-Art-Checks). Appendix C: A1-Framing korrigiert (47.000 bekannt, Aufschlüsselung fehlt). CORE-Referenzpunkte 7→7+2. Encoding: Alle escaped Umlaute → echtes UTF-8. amsmath-Package ergänzt. **BibTeX-Literaturverzeichnis** mit 50 Einträgen (ST-001_references.bib). 87 Seiten.
- **v0.11** (April 2026, 2026-04-11) — **CORE3-Integration**. V2a/V2b-Differenzierung in 7 Abschnitten. V1-Schutzstufenmodell eingearbeitet (Anhörung, Beratung, Karenzzeit, Deckel). Zertifikatsfehler nur noch V2b in voller Schärfe. § 106/§ 106b Sachfehler korrigiert. Kommunikationsasymmetrie-Absatz mit Poisson-Modell ($\lambda=0,85$, 57 %/Jahr). Bayern/BMG-Zahlen (47.000 V2-Verfahren). Summierung “Kleines Risiko pro Fall, großes Risiko pro Arzt”. 99,7 %-Verwerfungsrate auf V1 beschränkt. Lesarten-Abschnitt komplett umgeschrieben. Executive Summary (ST-001 ES, v1.0) erstellt. 82 Seiten.
- **v0.10** (April 2026, 2026-04-11) — **Review-Zyklus + Methodenteil + KNV**. Methodenteil von 12 auf ~60 Zeilen erweitert (Forschungsdesign, Suchstrategie, Multi-Modell-Architektur, Ein-/Ausschlusskriterien, Bias-Management). Ribbat-Operationalisierung (Mapping-Tabelle, Falsifizierbarkeit). Gegeneinwände-Callouts (Vorwärtsverweise auf Einwände 1–3). KNV-Tabelle (14 Maßnahmen, Rang 1–14). Goodhart’s/Campbell’s Law. Governance-Pharmakovigilanz. Bidirektionale Fehlversorgung. KBV-Berufsmonitoring korrigiert (46,7 %/13.900). 3 Review-Agenten: Major Revision → knapp Minor Revision. 76 Seiten.
- **v0.9** (April 2026, 2026-04-11) — LG-Sichtprüfung mit 108 PDF-Kommentaren eingearbeitet: “Die Diagnose” statt “Worum es geht”, neue Fragestellung-Überschrift, 50:1-Framing ersetzt durch Ribbat 72 %-Befund, Container-Definition, Richtgrößen definiert, Stufenmodell gestrichen, Selektionsbias → Machtungleichgewicht mit SG Mainz 2022, “Lesart C” → “System als Formfehler-Erkennung”, Hessendata-Verfassungsrecht (1 BvR 1547/19), Doppelprüfungsverbot (LSG BaWü L 5 KA 1505/23), natürliches Experiment 2017 (WldO-Daten). Appendix B: Walk of Analysis (Methodenteil). V1/V2 konsequent getrennt. 66 Seiten.
- **v0.8** (April 2026, 2026-04-10) — 13-Phasen-Review-Zyklus: 26+ Korrekturen (Tonalität, Advocacy-Sprache entschärft, Zertifikatsfehler als “Interpretationslücke” reformuliert); normativer Schadensbegriff (BSG B 6 KA 5/09 R) als neuer Abschnitt; **neue Synthese “Drei Scanner, keine Qualitätsprüfung”**: Lesart C (System als Formfehler-Optimierer), Informationsasymmetrie Prüfkatalog, offene Rechtsfrage automatisiertes Screening vs. § 106b-Verdacht. 59 Seiten.
- **v0.7** (April 2026, 2026-04-10) — Zwei Eskalationspipeline-Tabellen (V1 Auffälligkeitsprüfung + V2 Einzelfallprüfung, je 6 Spalten + Kernaussagen); Vier-Messebenen-Kommentierung; 17-Zeilen-Vergleichstabelle Auffälligkeits- vs. Einzelfallprüfung (3 Gruppen: Verfahrens-, Schutz-, Risikoprofil); Tabelle Vier informelle Ausgleichsmechanismen (Optionen A–D); strukturelles Framing V1 = probabilistisch / V2 = nahezu deterministisch; Quellenbelege in Fußnoten: KV BaWü 2022 (kvbaewue.de,

0,097 %, 21 / 21.500) und KV Hessen 2015 (*Dt. Ärzteblatt* Art. 113630, 3 / 916 = 0,3 % | S0); Klarstellung dass die „unter 1 %“-Zahl für V1+V2 zusammen gilt (keine Verfahrenstrennung veröffentlicht); Version 0.7.

- **v0.6** (April 2026, 2026-04-09) — Neue Abschnitte: Begriffsklärung der Regressmetriken (Vier Messebenen), Termination without Determination, Doppelter Zertifikatsfehler, Stufenmodell, Selektionsbias, Formfehler als Strategie, Praxisbesonderheiten. 52 Seiten.
- **v0.5** (April 2026) — Niskanen-Analyse der GPE (6 Kriterien), Spieltheorie (Nash-Gleichgewicht, Schweigeprämium), verfassungsrechtliche Angriffsvektoren (Bestimmtheit, Doppelbeschwerde Arzt + Patient), Modellarzt-Hochrechnung mit Sensitivitätstabelle (direkte + anteilige Folgekosten), Verhältnisrechnung Schaden : Einnahme.
- **v0.4** (April 2026) — Google-Research-Review: Freidson (Managerialismus, Professional Dominance, Third Logic), Power (Audit Society), Lipsky (Street-Level Bureaucracy), Herd/Moynihan (Administrative Burden), Bernstein (Transparency Paradox als Selbstkritik zu PP-003). Frankreich-Sektion: Délit statistique, MSO/MSAP, CNAM-Kampagnen 2023–2025, MG France, FMF.
- **v0.3** (April 2026) — Gemini-Recherchen: GPE-Kostenbefund (Niskanen), diametrale Manifestation US / DE (Überbehandlung vs. Unterversorgung).
- **v0.2** (März/April 2026) — Copilot-Review 1 eingearbeitet: Sensitivitätsbox, Screening-vs.-Verdachtsprüfung, Eigentumsdogmatik, Public Choice, Drei Reformhebel, Vergleichsfolie Defensivmedizin, Glossar. 28 Seiten.
- **v0.1** (März 2026) — Erstes Skelett mit allen 8 Teilen + Verfassungsrechtskapitel.

KI-Transparenzhinweis

Dieses Dokument wurde unter intensivem Einsatz von KI-Sprachmodellen (u. a. Anthropic Claude, Microsoft Copilot, Google Gemini) erarbeitet. Der Einsatz war notwendig, um diese Analyse mit begrenzten Ressourcen zu ermöglichen. Es wurden mehrere Kontroll- und Reviewzyklen durchgeführt — sowohl KI-gestützt als auch durch menschliche Redaktion.

KI-Sprachmodelle neigen zu Halluzinationen und können sachliche Fehler produzieren. Trotz sorgfältiger Prüfung sind Fehler nicht ausgeschlossen. Wir korrigieren dokumentierte Fehler gerne und veröffentlichen verbesserte Versionen.

Dieses Dokument stellt keine Rechtsberatung dar.

Hinweise auf Fehler bitte an: hallo@um-bruch.org